



SKRIPSI

Judul:

Klasifikasi Topik dan Intensi Ulasan Konsumen
Gojek dan Grab pada Twitter Menggunakan
Metode Stacking Ensemble Xgboost dan Lightgbm

Disusun oleh:

HANS SANTOSO

NIM. 535220129

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TARUMANAGARA
2026

LEMBAR PENGESAHAN SKRIPSI

Pengesahan

Nama : HANS SANTOSO
NIM : 535220129
Program Studi : TEKNIK INFORMATIKA
Judul Skripsi : Klasifikasi Topik dan Intensi Ulasan Konsumen Gojek dan Grab pada Twitter Menggunakan Metode Stacking Ensemble XGBoost dan LightGBM
Title : Topic and Intention Classification of Gojek and Grab Consumer Reviews on Twitter Using Stacking Ensemble Method with XGBoost and LightGBM

Skripsi ini telah dipertahankan di hadapan Dewan Penguji Program Studi TEKNIK INFORMATIKA Fakultas Teknologi Informasi Universitas Tarumanagara pada tanggal 24-November-2025.

Tim Penguji:

1. CHAIRISNI LUBIS, Dra., M.Kom.
2. VINY CHRISTANTI MAWARDI, S.Kom., M.Kom.

Yang bersangkutan dinyatakan: **LULUS.**

Pembimbing:
TRI SUTRISNO, S.Si., M.Sc.
NIK/NIP: 10816004



Jakarta, 24-November-2025

Ketua Program Studi



VINY CHRISTANTI MAWARDI, S.Kom., M.Kom.

LEMBAR PERSETUJUAN SIDANG SKRIPSI

Persetujuan

Nama : HANS SANTOSO
NIM : 535220129
Program Studi : TEKNIK INFORMATIKA
Judul : Klasifikasi Topik dan Intensi Ulasan Konsumen Gojek dan Grab pada Twitter Menggunakan Metode Stacking Ensemble Xgboost dan Lightgbm

Skripsi ini disetujui untuk diuji

Jakarta, 11-November-2025

Pembimbing:
TRI SUTRISNO, S.Si., M.Sc.
NIK/NIP: 10816004



LEMBAR PERNYATAAN SKRIPSI

Pernyataan

Nama : HANS SANTOSO
NIM : 535220129
Program Studi : TEKNIK INFORMATIKA
Judul : Klasifikasi Topik dan Intensi Ulasan Konsumen Gojek dan Grab pada Twitter Menggunakan Metode Stacking Ensemble Xgboost dan Lightgbm

Dengan ini menyatakan bahwa skripsi ini merupakan hasil kerja saya sendiri di bawah bimbingan Tim Pembimbing dan bukan hasil plagiasi dan/atau kegiatan curang lainnya.

Jika saya melanggar pernyataan ini, maka saya bersedia dikenakan sanksi sesuai aturan yang berlaku di Universitas Tarumanagara.

Demikian pernyataan ini saya buat dengan sebenarnya, untuk dipergunakan sebagaimana mestinya.

Jakarta, 11-November-2025
Yang menyatakan



HANS SANTOSO
NIM. 535220129

ABSTRAK

HANS SANTOSO, NPM: 535220129. **KLASIFIKASI TOPIK DAN INTENSI ULASAN KONSUMEN GOJEK DAN GRAB PADA TWITTER MENGGUNAKAN METODE STACKING ENSEMBLE XGBOOST DAN LIGHTGBM**. Skripsi, Jakarta: Program Studi Teknik Informatika, Fakultas Teknologi Informasi, Universitas Tarumanagara, November 2025.

Persaingan Gojek dan Grab di media sosial menciptakan volume ulasan konsumen yang masif namun tidak terstruktur. Penelitian ini merancang *dashboard* interaktif untuk mengolah data tersebut secara otomatis. Sistem dikembangkan untuk mengklasifikasikan ulasan ke dalam dua dimensi agar menangkap konteks secara utuh. Pertama, dimensi Topik Layanan mengidentifikasi objek spesifik yang dibicarakan, yang terdiri dari kelas yaitu Gojek, Grab, GoCar, GrabCar, GoFood, GrabFood, GoSend, GrabExpress, GoPay, dan OVO. Kedua, dimensi Intensi Pengguna mengidentifikasi niat atau dorongan komunikatif di balik teks, yang terdiri dari kelas yaitu Keluhan, Pujian, Pertanyaan, Pernyataan, dan Saran-Kritik. Inti sistem menggunakan arsitektur *Stacking Ensemble*, yang menggabungkan XGBoost dan LightGBM sebagai *base-model* dengan *Logistic Regression* sebagai *meta-model*. Model dilatih menggunakan total 12.000 ulasan Twitter. Hasil evaluasi pada *test set* menunjukkan performa yang andal, di mana Model Topik mencapai *Test Accuracy* 85.94% (skenario *Hyperparameter Tuned* 70/30) dan Model Intensi mencapai 70.75% (skenario *Hyperparameter Tuned* 80/20). Pengujian fungsional *Black Box Testing* mengonfirmasi bahwa seluruh fitur berjalan sesuai rancangan. Hasil akhir penelitian ini adalah prototipe alat bantu analisis bisnis (*business intelligence*) untuk mendukung pengambilan keputusan strategis perusahaan.

Kata Kunci: Klasifikasi Teks, *LightGBM*, *Stacking Ensemble*, Twitter, *XGBoost*

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa, karena berkat rahmat-Nya penulis dapat menyelesaikan skripsi berjudul “Klasifikasi Topik dan Intensi Ulasan Konsumen Gojek dan Grab pada Twitter Menggunakan Metode Stacking Ensemble XGBoost dan LightGBM” dengan baik. Penyusunan skripsi ini tidak lepas dari dukungan berbagai pihak. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Ibu Prof. Dr. Ir. Dyah Erny Herwindiati, M.Si., selaku Dekan Fakultas Teknologi Informasi Universitas Tarumanagara.
2. Ibu Viny Christanti Mawardi, S.Kom., M.Kom., selaku Ketua Program Studi Teknik Informatika Fakultas Teknologi Informasi Universitas Tarumanagara.
3. Ibu Ir. Jeanny Pragantha, M.Eng., selaku Koordinator Skripsi Program Studi Teknik Informatika atas arahan penyusunan skripsi yang diberikan.
4. Bapak Tri Sutrisno, S.Si., M.Sc., selaku Dosen Pembimbing atas bimbingan dan saran selama penyusunan skripsi.
5. Seluruh dosen dan staf FTI Universitas Tarumanagara atas ilmu pengetahuan dan pengalaman selama masa perkuliahan.
6. Keluarga tercinta, khususnya kedua orang tua penulis, yang telah memberikan dukungan moril, materiel, serta doa yang tiada henti selama menempuh pendidikan hingga skripsi ini selesai.

7. Sahabat terbaik, Lekrey Jerel Jacob Laipiopa, yang telah memberikan dukungan dan bantuan yang sangat berarti selama skripsi.
8. Teman-teman seperjuangan dan semua pihak yang telah memberikan semangat, khususnya kepada Marchelino Benediktus Leintan, Angeline Shevenia, Rizky Sugiharto, Naswa Azahra, Matthew Alexander Tjahjadi, Raynaldo Gracia Buntoro, Vincent Alexander, Gabriella Ignatia, Darren Ferdian, Angeline Sandy, Ekin Valent Renaldy, Ivara Sinatria Putri, dan Verlene Angelica Kiarra Blue. Terima kasih atas dukungannya.
9. Seluruh pihak di Universitas Tarumanagara yang telah membantu selama perkuliahan.
10. Seluruh pihak lain yang telah membantu Penulis dalam proses pembuatan skripsi ini yang tidak dapat disebutkan satu persatu.

Penulis menyadari bahwa skripsi ini masih memiliki kekurangan. Kritik dan saran sangat penulis harapkan demi perbaikan di masa mendatang. Semoga karya ini dapat memberikan manfaat bagi pembaca.

Jakarta, 13 November 2025



Hans Santoso

DAFTAR ISI

HALAMAN JUDUL	i
LEMBAR PENGESAHAN SKRIPSI.....	ii
LEMBAR PERSETUJUAN SIDANG SKRIPSI.....	iii
LEMBAR PERNYATAAN SKRIPSI	iv
ABSTRAK.....	v
KATA PENGANTAR.....	vi
DAFTAR ISI	viii
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiv
DAFTAR LAMPIRAN.....	xvii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Rancangan	4
1.3 Komponen Rancangan	6
1.4 Spesifikasi Rancangan	7
1.5 Kegunaan Rancangan	9
1.6 Rancangan yang Sudah Dibuat.....	11
BAB II LANDASAN TEORETIK.....	14
2.1 Sistem yang Dirancang	14
2.2 Komponen yang Dirancang	16

2.2.1 Ulasan Konsumen di Media Sosial	17
2.2.2 Klasifikasi Teks Multi-Label	18
2.2.3 Text Preprocessing.....	20
2.2.4 Ekstraksi Fitur: TF-IDF	22
2.2.5 Ensemble Learning (Stacking Ensemble).....	24
2.2.6 Extreme Gradient Boosting (XGBoost)	27
2.2.7 Light Gradient Boosting Machine (LightGBM)	32
2.2.8 <i>Logistic Regression</i> (Meta-Model)	38
2.2.9 Hyperparameter Tuning	42
2.2.10 Metrik Evaluasi	43
2.2.11 Validasi Data (<i>Inter-Annotator Agreement</i>)	46
2.2.12 Black Box Testing	48
BAB III RANCANGAN DAN PEMBUATAN	50
3.1 Rancangan Sistem	50
3.1.1 Perencanaan Sistem	50
3.1.2 Kebutuhan Data.....	52
3.1.3 Diagram Use Case.....	53
3.1.4 Diagram Alir Pengguna (<i>User Flow</i>)	55
3.1.5 Rancangan Antarmuka Pengguna (<i>User Interface</i>)	57

3.1.6 Rancangan Arsitektur Sistem	65
3.2 Pembuatan Sistem.....	66
3.2.1 Perangkat Keras (Hardware).....	67
3.2.2 Perangkat Lunak (Software)	67
3.2.3 Pengumpulan Data	70
3.2.4 Pembuatan Program	75
BAB IV PENGUJIAN	78
4.1 Cara Pengujian.....	78
4.1.1 Pengujian Validitas Pelabelan Data (Cohen's Kappa)	79
4.1.2 Pengujian Black Box Testing	80
4.1.3 Pengujian Performa Model	80
4.2 Hasil Pengujian	81
4.2.1 Hasil Validitas Pelabelan Data (Cohen's Kappa)	81
4.2.2 Hasil Pengujian Blackbox Testing.....	82
4.2.3 Hasil Evaluasi Model Klasifikasi	87
4.2.4 Hasil Tampilan Dashboard Aplikasi Streamlit.....	99
4.3 Pembahasan	105
4.3.1 Pembahasan Model Klasifikasi Topik	105
4.3.2 Pembahasan Model Klasifikasi Intensi	107

BAB V KESIMPULAN DAN SARAN	110
5.1 Kesimpulan	110
5.2 Saran.....	111
DAFTAR PUSTAKA	113
LAMPIRAN	121
DAFTAR RIWAYAT HIDUP	182

DAFTAR TABEL

Tabel 3. 1 Keyword Tweet Harvest	71
Tabel 3. 2 Atribut Hasil Scrapping.....	71
Tabel 3. 3 <i>Dataset</i> Hasil Pelabelan Manual	74
Tabel 3. 4 Distribusi Label Topik dalam <i>Dataset</i>	75
Tabel 3. 5 Distribusi Label Intensi dalam <i>Dataset</i>	75
Tabel 4. 1 Hasil Blackbox Testing	82
Tabel 4. 2 Evaluasi Model Topik 70/30	88
Tabel 4. 3 Evaluasi Model Topik 80/20	89
Tabel 4. 4 Evaluasi Model Topik 70/30 setelah Hypertuning	90
Tabel 4. 5 Evaluasi Model Topik 80/20 setelah Hypertuning	92
Tabel 4. 6 Evaluasi Model Intensi 70/30.....	93
Tabel 4. 7 Evaluasi Intensi Topik 80/20.....	94
Tabel 4. 8 Evaluasi Model Intensi 70/30 Setelah Hypertuning.....	96
Tabel 4. 9 Evaluasi Model Topik 80/20 setelah Hypertuning	98
Tabel 4. 10 Rangkuman Hasil Evaluasi Model Klasifikasi Topik	106
Tabel 4. 11 Rangkuman Hasil Evaluasi Model Klasifikasi Intensi.....	108
Tabel L1.1 <i>Dataset</i> Tweet Dummy.....	121
Tabel L1.2 <i>Dataset</i> setelah Preprocessing (Tokenized)	123
Tabel L1. 3 Hasil Perhitungan IDF	125
Tabel L1.4 Hasil Perhitungan TF-IDF	126
Tabel L2. 1 <i>Dataset</i> XGBoost	127

Tabel L2. 2 <i>Dataset</i> Biner XGBoost	128
Tabel L2. 3 Prediksi Baru Tree 1 XGBoost	131
Tabel L2. 4 Prediksi Final Setelah Tree 2 XGBoost	134
Tabel L2. 5 Output Probabilitas XGBoost	136
Tabel L3. 1 <i>Dataset</i> Biner LightGBM.....	137
Tabel L3. 2 Gradien dan Hessian Tree 2 LightGBM.....	142
Tabel L3. 3 Output Probabilitas LightGBM	146
Tabel L4. 1 <i>Dataset</i> Input untuk Meta-model (<i>Logistic Regression</i>)	147
Tabel L5. 1 <i>Dataset</i> Akhir.....	153
Tabel L5. 2 Confusion Matriks	154
Tabel L5. 3 Metrik per Kelas	154
Tabel L6. 1 Contoh <i>Dataset</i> Scraping Tweet Harvest.....	157

DAFTAR GAMBAR

Gambar 2.1 Skema Awal Arsitektur Sistem.....	16
Gambar 3. 1 Use Case Diagram Dashboard	53
Gambar 3. 2 Flow Chart Pengguna	56
Gambar 3. 3 Rancangan Modul Prediction 1	58
Gambar 3. 4 Rancangan Modul Prediction 2	58
Gambar 3. 5 Rancangan Modul <i>Dataset</i> 1	59
Gambar 3. 6 Rancangan Modul <i>Dataset</i> 2	60
Gambar 3. 7 Rancangan Tampilan Modul Dashboard 1.....	61
Gambar 3. 8 Rancangan Tampilan Modul Dashboard 2.....	61
Gambar 3. 9 Rancangan Modul About (Tab Informasi).....	62
Gambar 3. 10 Rancangan Tampilan Modul About (Tab Evaluasi Model) 1.....	63
Gambar 3. 11 Rancangan Tampilan Modul About (Tab Evaluasi Model) 2.....	64
Gambar 3. 12 Rancangan Tampilan Modul About (Tab Evaluasi Model) 3.....	64
Gambar 3. 13 Rancangan Tampilan Modul About (Tab Buku Manuall)	65
Gambar 3. 14 Rancangan Arsitektur Sistem.....	65
Gambar 3. 15 <i>Dataset</i> Hasil Tweet Harvest	72
Gambar 4. 1 Parameter Default Model.....	87
Gambar 4. 2 Confusion Matrix Topik 70/30	88
Gambar 4. 3 Confusion Matrix Topic 80/20	89
Gambar 4. 4 Parameter Hypertuning Model Topic Split 70/30	90
Gambar 4. 5 Confusion Matrix Topic 70/30 Setelah Hypertuning	91

Gambar 4. 6 Parameter Hypertuning Model Topic Split 80/20	92
Gambar 4. 7 Confusion Matrix Topic 80/20 Setelah Hypertuning	93
Gambar 4. 8 Confusion Matrix Intensi 70/30.....	94
Gambar 4. 9 Confusion Matrix Intensi 80/20.....	95
Gambar 4. 10 Parameter Hypertuning Model Intensi Split 70/30	96
Gambar 4. 11 Confusion Matrix Intensi 70/30 Setelah Hypertuning	97
Gambar 4. 12 Parameter Hypertuning Model Intensi Split 80/20	98
Gambar 4. 13 Confusion Matrix Topic 80/20 Setelah Hypertuning	99
Gambar 4. 14 Tampilan Halaman Prediction	100
Gambar 4. 15 Tampilan Halaman <i>Dataset</i>	101
Gambar 4. 16 Tampilan Halaman Dashboard	102
Gambar 4. 17 Tab Informasi Pengerjaan	103
Gambar 4. 18 Tab Evaluasi Model	103
Gambar 4. 19 Tab Evaluasi Model 2	104
Gambar 4. 20 Tab Buku Manual	104
Gambar L7. 1 Hasil User Acceptance Testing 1	158
Gambar L7. 2 Hasil User Acceptance Testing 2	160
Gambar L7. 3 Hasil User Acceptance Testing 3	162
Gambar L7. 4 Hasil User Acceptance Testing 4	164
Gambar L7. 5 Hasil User Acceptance Testing 5	166
Gambar L8. 1 Profil Validator 1	168
Gambar L8. 2 Profil Validator 2	169

Gambar L10. 1 Tampilan Halaman Dataset (Tanpa Dataset)	172
Gambar L10. 2 Tampilan Halaman Dataset (Dengan Dataset)	172
Gambar L10. 3 Tampilan Halaman Dataset (Data dan Informasi Kolom)	173
Gambar L11. 1 Tampilan Halaman Dashboard (Tanpa Data)	174
Gambar L11. 2 Tampilan Halaman Dashboard (Dengan Data)	174
Gambar L11. 3 Tampilan Halaman Dataset (WordCloud)	175
Gambar L12. 1 Tampilan Antarmuka Halaman About (Informasi Pengerjaan)...	176
Gambar L12. 2 Tampilan Halaman About (Evaluasi)	176
Gambar L12. 3 Tampilan Halaman About (Confusion Matrix)	177
Gambar L12. 4 Tampilan Halaman Evaluation (Analisis Kesalahan Terbesar).....	177
Gambar L12. 5 Tampilan Halaman About (Buku Manual)	178
Gambar L13. 1 Hasil Turnitin Skripsi 1.....	179
Gambar L13. 2 Hasil Turnitin Skripsi 2.....	179
Gambar L13. 3 Digital Receipt Turnitin	180

DAFTAR LAMPIRAN

LAMPIRAN I PREPROCESSING DAN PERHITUNGAN MANUAL TF-IDF	121
LAMPIRAN II PERHITUNGAN XGBOOST.....	127
LAMPIRAN III PERHITUNGAN LIGHTGBM.....	137
LAMPIRAN IV PERHITUNGAN LOGISTIC REGRESSION	147
LAMPIRAN V PERHITUNGAN METRIK EVALUASI	153
LAMPIRAN VI CONTOH DATASET SCRAPING TWEET HARVEST	157
LAMPIRAN VII USER ACCEPTANCE TEST	158
LAMPIRAN VIII PROFIL VALIDATOR.....	168
LAMPIRAN IX TAMPILAN ANTARMUKA HALAMAN PREDICTION	170
LAMPIRAN X TAMPILAN ANTARMUKA HALAMAN DATASET	172
LAMPIRAN XI TAMPILAN ANTARMUKA HALAMAN DASHBOARD	174
LAMPIRAN XII TAMPILAN ANTARMUKA HALAMAN ABOUT	176
LAMPIRAN XIII HASIL TURNITIN	179
LAMPIRAN XIV LINK GITHUB	181

BAB I

PENDAHULUAN

1.1 Latar Belakang

Cara manusia berkomunikasi dan berinteraksi telah berubah secara fundamental seiring berkembangnya teknologi informasi dan internet. Salah satu dari perubahan ini adalah kemunculan media sosial. Media sosial tidak hanya untuk berhubungan dengan teman, tetapi juga dapat menjadi sarana bagi untuk menyuarakan opini, berbagi pengalaman, dan memberikan ulasan produk atau jasa. Di antara berbagai platform, Twitter (Sekarang X) menonjol karena kemampuannya menampung pertukaran opini secara cepat, *real-time*, dan dalam skala masif. Maka Twitter sering dimanfaatkan untuk mengetahui opini masyarakat terhadap suatu isu, termasuk kesehatan mental [1] hingga respons terhadap kebijakan pemerintah [2].

Di Indonesia kemunculan perusahaan teknologi berbasis aplikasi seperti Gojek dan Grab menciptakan persaingan yang sangat ketat di sektor transportasi daring, pengiriman makanan, dan pembayaran digital. Dalam lingkup bisnis yang kompetitif ini, kepuasan dari pelanggan jadi faktor krusial untuk memenangkan pasar. Ulasan yang tersebar di Twitter merupakan cerminan langsung dari suara konsumen. Setiap hari ribuan ulasan yang berisi keluhan, pujian, pertanyaan, maupun saran terkait layanan Gojek dan Grab diunggah oleh pengguna [3].

Informasi ini merupakan aset strategis yang sangat berharga bagi perusahaan untuk melakukan evaluasi dan pengambilan keputusan.

Dengan adanya masalah seperti volume data ulasan yang masif, tidak terstruktur, dan terus bertambah (*velocity*) telah menghadirkan tantangan tersendiri [4]. Melakukan analisis secara manual terhadap data tersebut sangat tidak efisien dan rentan terhadap bias subjektif. Akibat dari hal tersebut respons perusahaan terhadap keluhan pelanggan bisa menjadi lambat, tren pasar sulit terdeteksi, dan keputusan strategis sering diambil tanpa landasan data yang kuat. Untuk mengatasi masalah ini, perancangan sebuah sistem terotomatisasi menjadi sebuah keharusan. Dengan memanfaatkan *Natural Language Processing* (NLP), sebuah sistem cerdas dapat dirancang untuk mengolah data mentah ini menjadi wawasan yang dapat ditindaklanjuti [5].

Faktor krusial dalam perancangan sistem seperti ini adalah pemilihan model klasifikasi yang tepat. Beberapa pendekatan telah digunakan sebelumnya untuk menganalisis ulasan layanan daring, mulai dari metode klasik seperti *Naive Bayes* hingga metode yang lebih canggih seperti *Support Vector Machine* (SVM) [3][6]. Beberapa penelitian yang lebih baru menunjukkan bahwa algoritma berbasis *boosting* seperti *XGBoost* dan *LightGBM* mampu menghasilkan performa yang lebih unggul untuk data teks dari media sosial yang kompleks [7][8]. Untuk memastikan sistem yang akan dirancang ini memberikan hasil analisis yang akurat dan andal, maka diperlukan arsitektur model yang lebih kuat. Oleh karena itu,

komponen inti dari sistem ini akan dirancang menggunakan pendekatan *Stacking Ensemble*, yang terbukti mampu meningkatkan stabilitas dan akurasi dengan menggabungkan kekuatan dari beberapa model [9]. Arsitektur ini akan menggunakan *XGBoost* karena kemampuannya menangani pola kompleks [10][11] dan *LightGBM* karena efisiensi komputasinya pada data berskala besar [7], yang keduanya sangat sesuai untuk kebutuhan sistem ini.

Menjawab kebutuhan tersebut, maka dirancanglah sebuah sistem *dashboard* interaktif untuk analisis ulasan konsumen Gojek dan Grab. Sistem ini akan ditenagai oleh model klasifikasi *Stacking Ensemble* yang bertugas mengolah dan melabeli ulasan secara otomatis berdasarkan topik layanan dan intensi pengguna. Hasil analisis tersebut kemudian akan disajikan melalui visualisasi data yang intuitif, yang bertujuan untuk memberikan wawasan yang dapat ditindaklanjuti bagi tim produk, layanan pelanggan, dan pemasaran di perusahaan. Secara spesifik, sistem ini akan membantu mereka untuk memprioritaskan perbaikan layanan berdasarkan keluhan yang paling sering muncul, mengukur keberhasilan kampanye pemasaran dengan melihat tren pujian, dan memahami kebutuhan pengguna secara mendalam untuk inovasi produk di masa depan. Perancangan *dashboard* sebagai alat *business intelligence* ini sejalan dengan penelitian sebelumnya yang telah membuktikan bahwa implementasi *Business Intelligence* dapat secara efisien mengubah data mentah menjadi visualisasi yang menghasilkan *insight* untuk mendukung pengambilan keputusan strategis [12][13].

1.2 Rumusan Rancangan

Perancangan ini berfokus pada perancangan sebuah sistem *dashboard* interaktif yang berfungsi mengolah dan memvisualisasikan data ulasan konsumen Gojek dan Grab. Tujuan utamanya adalah menyediakan alat bantu untuk pengambilan keputusan bisnis. Proses perancangan sistem ini dibagi menjadi beberapa tahapan utama yaitu :

1. Pengolahan dan Persiapan Data: Tahap pertama adalah memuat data dari *file* sumber berformat .csv atau .xlsx. Data teks ulasan kemudian melewati serangkaian langkah *preprocessing* untuk menghasilkan data yang bersih dan terstruktur. Alur ini mengikuti praktik standar *Natural Language Processing* (NLP), yang mencakup *case folding*, *cleansing*, *tokenizing*, *normalizing*, *stopword removal*, dan *stemming* untuk meningkatkan kualitas data latih [14]. Data bersih ini kemudian ditransformasikan menjadi representasi vektor numerik menggunakan metode ekstraksi fitur TF-IDF.
2. Perancangan dan Pelatihan Model Klasifikasi: Inti dari sistem ini adalah model klasifikasi. Penelitian ini akan membangun model menggunakan arsitektur *Stacking Ensemble* yang mengombinasikan *XGBoost* dan *LightGBM*. Pendekatan *stacking* ini digunakan karena kemampuannya yang terbukti dalam meningkatkan stabilitas dan akurasi prediksi dengan menggabungkan kekuatan beberapa model [9]. Model ini akan dilatih (*training*) menggunakan

data yang telah disiapkan untuk mempelajari pola klasifikasi topik layanan dan intensi pengguna.

3. Perancangan Sistem *Dashboard*: Model yang telah dilatih akan diintegrasikan ke dalam sebuah sistem aplikasi. Sistem ini diwujudkan dalam bentuk *dashboard* interaktif menggunakan *framework* Streamlit. Pemilihan Streamlit didasarkan pada kemampuannya untuk mempercepat pengembangan aplikasi web interaktif bagi kebutuhan *data science* dan *machine learning* [15]. *Dashboard* ini dirancang untuk mampu menyajikan hasil klasifikasi melalui berbagai komponen visualisasi seperti grafik, tabel, dan *word cloud* yang dapat difilter secara dinamis oleh pengguna.
4. Pengujian dan Validasi Sistem: Untuk menilai kualitas sistem yang dirancang, akan dilakukan dua jenis pengujian. Pertama, pengujian terhadap komponen model klasifikasi menggunakan metrik evaluasi kuantitatif standar seperti *Accuracy*, *Precision*, *Recall*, dan *F1-Score* [16]. Kedua, pengujian fungsional pada aplikasi *dashboard* menggunakan metode *Black-Box Testing*. Metode ini diterapkan untuk memverifikasi fungsionalitas dari sudut pandang pengguna, yakni dengan memberikan masukan dan memeriksa keluaran tanpa perlu mengetahui struktur kode internalnya [17]. Pengujian ini bertujuan untuk memastikan semua fitur seperti filter, tombol, dan visualisasi berjalan sesuai dengan rancangan.

Melalui rumusan rancangan tersebut, diharapkan sistem yang dibangun tidak hanya andal dari sisi teknis, tetapi juga memberikan manfaat praktis sebagai alat bantu analisis bagi perusahaan.

1.3 Komponen Rancangan

Sistem *dashboard* analisis ulasan ini dibangun menggunakan bahasa pemrograman Python, sementara antarmuka (*interface*) yang dibuat dikembangkan dengan *framework* Streamlit. Sistem ini berjalan sebagai aplikasi web mandiri, memungkinkan pengguna berinteraksi langsung melalui antarmuka web untuk melakukan analisis data. Input utama yang diterima oleh sistem adalah sebuah *file* berformat .csv atau .xlsx yang berisi kolom teks ulasan mentah. Setelah pengguna mengunggah *file* tersebut, sistem akan memprosesnya secara internal. Proses ini kemudian ditangani oleh model *Stacking Ensemble* (XGBoost dan LightGBM) yang telah dilatih sebelumnya untuk menganalisis setiap baris ulasan.

Sistem kemudian memberikan *output* berupa *dashboard* interaktif *multi*-halaman yang menampilkan hasil klasifikasi topik dan intensi dalam berbagai bentuk visualisasi. Dengan rancangan ini, pengguna dapat dengan mudah menganalisis data dalam jumlah besar melalui antarmuka web, sementara seluruh proses komputasi, mulai dari *preprocessing* hingga klasifikasi, ditangani secara otomatis dengan Python yang menjadi logika utama dari aplikasi ini.

1.4 Spesifikasi Rancangan

Bagian ini merinci spesifikasi sistem yang dibangun, yang terdiri dari beberapa modul fungsional. Perancangan ini berfokus untuk menyajikan data analisis yang kompleks ke dalam antarmuka (*interface*) yang sederhana dan interaktif. Setiap modul dirancang untuk memenuhi kebutuhan pengguna perusahaan (seperti tim produk dan pemasaran), memudahkan mereka mengeksplorasi dan mendapatkan wawasan dari ulasan konsumen secara efisien. Rincian dari setiap modul fungsional yang akan dibangun adalah sebagai berikut:

1. Modul *Prediction* (Prediksi Topik dan Intensi): Modul ini berfungsi sebagai halaman utama dan langkah pertama alur kerja aplikasi, sekaligus menyediakan antarmuka untuk menerapkan model klasifikasi pada data baru. Halaman ini juga menampilkan panduan alur kerja untuk pengguna baru. Fitur ini mencakup:
 - a. Prediksi Teks Tunggal: Memungkinkan pengguna memasukkan satu ulasan dan mendapatkan prediksi Topik serta Intensi secara langsung, lengkap dengan tingkat keyakinan (probabilitas).
 - b. Prediksi *Batch*: Memungkinkan pengguna mengunggah *file data mentah* (dengan kolom *full_text*) untuk diproses secara keseluruhan oleh model. Modul ini akan menghasilkan *file* baru yang berisi data asli ditambah kolom prediksi, yang kemudian dapat diunduh oleh pengguna untuk dianalisis di modul lain.

2. Modul *Dataset (Dataset Viewer)*: Modul ini berfungsi sebagai langkah kedua (penampil data utama). Setelah pengguna mengunggah file data yang sudah ber-label (baik *file* asli atau *file* hasil dari *Modul Prediction*) melalui *sidebar*, halaman ini menampilkan data dalam bentuk tabel interaktif. Pengguna dapat memfilter data berdasarkan Merek (Gojek/Grab), Topik spesifik, dan Intensi (*Type*) menggunakan *dropdown*. Halaman ini juga menyajikan statistik ringkas (jumlah baris, kelas unik, nilai *null*) dan informasi detail mengenai struktur data asli.
3. Modul *Dashboard (Dashboard Analisis Interaktif)*: Modul ini menjadi langkah ketiga (pusat visualisasi interaktif) untuk mengeksplorasi tren data yang telah diunggah di *sidebar*. Pengguna dapat memfilter data berdasarkan Merek menggunakan tombol *chip* dan memilih dimensi analisis utama (*Topic* atau *Intention*) serta menambahkan filter sekunder. Hasilnya ditampilkan secara dinamis melalui grafik distribusi (batang), grafik proporsi (lingkaran), dan *word cloud* yang mewakili kata-kata kunci dalam ulasan terfilter.
4. Modul *About (Tentang Aplikasi)*: Modul ini berisi informasi latar belakang aplikasi dan fungsionalitas pendukung, terbagi dalam beberapa *tab* berikut:
 - a. Tab Informasi Pengerjaan: Berisi deskripsi aplikasi, identitas pengembang dan dosen pembimbing, serta konteks akademis pengembangan aplikasi sebagai bagian dari tugas akhir Skripsi.

- b. Tab Evaluasi Model: Menyajikan hasil evaluasi performa model *Stacking Ensemble* yang digunakan. Pengguna dapat memilih skenario pelatihan model melalui filter *dropdown*. Halaman ini menampilkan metrik kuantitatif yaitu *Accuracy*, *Classification Report (Precision, Recall, F1-Score)*, dan visualisasi *Confusion Matrix* dari berbagai skenario pelatihan. Penempatan evaluasi di modul ini didasarkan pada standar pelaporan model (*Model Reporting*) yang menegaskan bahwa metrik kinerja adalah bagian dari identitas sistem yang harus diketahui pengguna untuk menilai keandalan prediksi [18].
- c. Tab Buku Manual: Menyediakan akses langsung ke dokumen panduan penggunaan aplikasi dalam format PDF. Fitur ini berfungsi sebagai narasi kepatuhan (*compliance narrative*) yang menjelaskan batasan dan tata cara penggunaan sistem yang benar, memastikan pengguna memahami kapabilitas alat secara utuh[18].

1.5 Kegunaan Rancangan

Perancangan sistem *dashboard* analisis ulasan konsumen ini diharapkan dapat memberikan kontribusi yang signifikan, baik dari segi praktis maupun akademis. Berikut adalah manfaat utama dari sistem yang dikembangkan:

1. Menyediakan Alat Bantu *Business Intelligence* untuk Perusahaan : Secara praktis, rancangan ini menghasilkan sebuah prototipe *dashboard* analisis yang berfungsi sebagai alat bantu bisnis bagi perusahaan seperti Gojek dan Grab.

Berbeda dengan alat analisis umum, *dashboard* interaktif ini menggunakan model yang secara spesifik dilatih untuk mengenali konteks ulasan layanan transportasi daring di Indonesia. Sistem ini memungkinkan tim terkait (produk, pemasaran, layanan pelanggan) untuk memonitor sentimen publik secara otomatis dan efisien, menggantikan proses analisis manual yang lambat dan rentan bias.

2. Mempercepat Identifikasi Masalah dan Pengambilan Keputusan : Dengan kemampuan mengklasifikasikan ulasan berdasarkan topik dan intensi, sistem ini memungkinkan perusahaan untuk mengidentifikasi keluhan pada layanan tertentu secara proaktif. Kemampuan untuk memfilter ulasan berdasarkan kombinasi spesifik memungkinkan tim terkait untuk secara cepat menemukan akar masalah. Sebagai contoh, tim produk dapat langsung memvalidasi keluhan spesifik tentang suatu fitur dan menjadikannya dasar untuk prioritas perbaikan, sehingga mempercepat siklus pengambilan keputusan berbasis data.
3. Menjadi Referensi Akademis untuk Implementasi Model *Ensemble* : Secara akademis, perancangan ini berfungsi sebagai studi kasus implementasi dari arsitektur *machine learning* tingkat lanjut (*Stacking Ensemble* dengan XGBoost dan LightGBM) yang diterapkan secara spesifik untuk menganalisis ulasan konsumen Gojek dan Grab di Twitter. Skripsi ini akan mendokumentasikan secara transparan proses perancangan dan pengujiannya. Hasilnya dapat

menjadi referensi berharga dan memberikan data performa (*benchmark*) awal bagi peneliti lain yang ingin menerapkan arsitektur serupa pada data teks media sosial berbahasa Indonesia yang bersifat *noisy* dan informal.

1.6 Rancangan yang Sudah Dibuat

Terdapat beberapa rancangan dan penelitian sebelumnya yang terkait dengan analisis sentimen pada ulasan layanan transportasi daring di Indonesia. Beberapa di antaranya yang menjadi acuan adalah sebagai berikut:

1. Analisis Sentimen Gojek Menggunakan *Naïve Bayes* dan SVM Penelitian yang dilakukan oleh Yusuf Khoiruddin, dkk. (2023) merancang sebuah sistem untuk klasifikasi sentimen pada ulasan Gojek di Twitter. Sistem tersebut membandingkan dua metode *machine learning* klasik, yaitu *Naïve Bayes* dan *Support Vector Machine* (SVM). Hasil dari perancangan tersebut menunjukkan bahwa model yang dibangun menggunakan SVM mampu memberikan tingkat akurasi yang lebih superior dibandingkan *Naïve Bayes* untuk domain ini [19].
2. Analisis Sentimen Tiga Layanan Transportasi Daring dengan SVM Muhammad Iqrom, dkk. (2025) juga melakukan perancangan sistem analisis sentimen yang mencakup tiga layanan sekaligus: Gojek, Grab, dan Maxim. Sistem ini dibangun menggunakan algoritma *Support Vector Machine* (SVM) dan berhasil menunjukkan bahwa metode tersebut mampu menghasilkan akurasi klasifikasi yang tinggi. Rancangan ini menegaskan bahwa SVM merupakan

benchmark yang kuat untuk analisis sentimen pada domain transportasi daring di Indonesia [20].

3. Klasifikasi Teks Twitter dengan Algoritma *Boosting* (XGBoost) Sebuah penelitian oleh Felix Fernando (2025) merancang sistem klasifikasi untuk data Twitter berbahasa Indonesia dengan membandingkan performa *SVM* dan *Extreme Gradient Boosting* (XGBoost). Hasilnya menunjukkan bahwa model yang menggunakan *XGBoost* memiliki keunggulan performa. Rancangan ini membuktikan efektivitas algoritma berbasis *boosting* seperti *XGBoost* untuk menangani data teks dari media sosial yang kompleks [8].
4. Pendekatan *Ensemble Classifier* untuk Klasifikasi Sentimen *Tweet* Vidyashree KP, dkk. (2024) mengusulkan sebuah pendekatan perancangan yang menggunakan *ensemble classifier* dengan menggabungkan tiga model (*Random Forest*, *SVM*, dan *Decision Tree*). Hasilnya menunjukkan bahwa model gabungan (*ensemble*) yang mereka rancang mampu mencapai akurasi yang lebih tinggi secara signifikan dibandingkan performa masing-masing model tunggal. Rancangan ini menjadi justifikasi pentingnya penggunaan metode *ensemble* untuk meningkatkan performa sistem klasifikasi [21].
5. Perancangan *Website* Prediksi Berbasis *Framework* Streamlit Devalio, dkk. (2025) merancang sebuah sistem berbasis *website* untuk memprediksi jumlah pengeluaran mahasiswa. Sistem ini dirancang menggunakan *framework* Streamlit karena kemudahannya dalam membuat aplikasi web interaktif.

Rancangan ini memungkinkan pengguna untuk mengunggah data dalam format .csv, yang kemudian diproses oleh model prediksi untuk ditampilkan hasilnya pada halaman utama. Untuk memastikan fungsionalitasnya, perancangan ini juga menyertakan tahap pengujian menggunakan metode *BlackBox Testing* [22].

Meskipun rancangan-rancangan di atas telah berhasil menerapkan berbagai metode, belum ada yang secara spesifik merancang sistem analisis interaktif (*dashboard*) yang memanfaatkan arsitektur *Stacking Ensemble* yang menggabungkan dua model *boosting* kuat (*XGBoost* dan *LightGBM*) untuk analisis multidimensi (topik dan intensi) pada ulasan konsumen transportasi daring di Indonesia.

BAB II

LANDASAN TEORETIK

2.1 Sistem yang Dirancang

Sistem yang dirancang dalam skripsi ini adalah sebuah aplikasi web berupa *dashboard* interaktif yang bertujuan untuk melakukan analisis ulasan konsumen terhadap layanan Gojek dan Grab. Konsep utama dari sistem ini adalah mentransformasikan data teks ulasan yang bersifat tidak terstruktur menjadi wawasan visual yang terstruktur dan mudah diinterpretasikan. Alur kerja sistem mengadopsi metodologi standar dalam proyek ilmu data, seperti *Cross-Industry Standard Process for Data Mining* (CRISP-DM), yang mencakup pemahaman data, persiapan data, pemodelan, hingga evaluasi [23].

Seluruh komponen ini bekerja sinergis dalam alur yang telah terdefinisi. Proses diawali saat pengguna mengunggah *file* data mentah berformat .csv atau .xlsx ke dalam aplikasi. Sistem kemudian secara otomatis menjalankan komponen *preprocessing* data untuk membersihkan dan melakukan standarisasi teks ulasan. Tahapan ini sangat krusial mengingat kualitas data akan sangat memengaruhi performa model klasifikasi yang dibangun [14]. Proses ini mencakup beberapa teknik standar dalam *Natural Language Processing* (NLP) seperti *case folding*, *cleansing*, *normalizing*, *tokenizing*, *stopword removal*, dan *stemming* [14].

Setelah data teks bersih, sistem melanjutkan ke komponen ekstraksi fitur. Pada tahap ini, sistem mengubah teks yang telah diproses menjadi representasi


vektor numerik menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF). Metode TF-IDF dipilih karena kemampuannya dalam memberikan bobot pada kata-kata yang dianggap penting dalam sebuah ulasan relatif terhadap keseluruhan data, sehingga menghasilkan fitur yang informatif untuk model [20].

Vektor fitur ini kemudian menjadi masukan bagi komponen inti sistem, yaitu model klasifikasi. Komponen ini menggunakan oleh arsitektur *Stacking Ensemble* yang mengombinasikan dua model *base-learner*, yaitu XGBoost dan LightGBM. Penggunaan metode *ensemble* seperti *stacking* bertujuan untuk menghasilkan prediksi yang lebih kuat dan stabil dengan menggabungkan keunggulan dari beberapa model yang berbeda [9]. Prediksi dari kedua *base-learner* tersebut kemudian menjadi masukan bagi *meta-model* (*Logistic Regression*) untuk menghasilkan keputusan klasifikasi akhir pada dua dimensi: Topik Layanan dan Intensi Pengguna.

Tahap terakhir adalah komponen visualisasi hasil. *Output* model klasifikasi berupa label topik dan intensi ditampilkan kepada pengguna melalui *dashboard* interaktif yang dibangun dengan *framework* Streamlit.. Streamlit merupakan kerangka kerja berbasis Python yang dirancang untuk mempermudah pengembangan aplikasi web interaktif, khususnya dalam bidang *data science* dan *machine learning* [15]. *Dashboard* ini memungkinkan pengguna untuk menganalisis data melalui berbagai elemen visual seperti diagram, tabel, dan *word*

cloud, serta menyediakan fungsionalitas filter untuk eksplorasi data yang lebih mendalam. Dengan demikian, sistem ini secara utuh mengintegrasikan alur kerja pengolahan data, pemodelan *machine learning*, dan penyajian informasi untuk menghasilkan alat bantu analisis yang fungsional.

Untuk memberikan gambaran yang lebih jelas, sebuah skema sistem telah dirancang. Diagram ini memvisualisasikan bagaimana data mengalir dari *input* pengguna, diproses oleh setiap komponen internal sistem, hingga akhirnya disajikan sebagai *output* visual pada *dashboard*. Keseluruhan arsitektur dan alur data sistem tersebut dapat dilihat secara visual pada **Gambar 2.1**.



Gambar 2.1 Skema Awal Arsitektur Sistem

2.2 Komponen yang Dirancang

Kerangka teoretis menjadi landasan untuk setiap aspek dalam perancangan sistem ini. Pembahasan akan diuraikan secara sistematis, dimulai dari pemaparan konsep data yang digunakan, dilanjutkan dengan metodologi teknis untuk

pengolahan dan pemodelan, hingga teori yang mendukung perancangan antarmuka dan evaluasi sistem. Secara spesifik, bagian ini akan membahas teori mengenai ulasan konsumen di media sosial (*User-Generated Content*), teknik *preprocessing* teks dan ekstraksi fitur TF-IDF, arsitektur *machine learning* yang diusulkan termasuk *Stacking Ensemble*, *XGBoost*, *LightGBM*, dan *Logistic Regression* serta justifikasi pemilihan *framework* visualisasi. Dijelaskan juga teori optimasi model melalui *hyperparameter tuning* serta metode evaluasi yang digunakan, baik untuk mengukur performa model maupun untuk menguji fungsionalitas aplikasi. Dengan demikian, setiap keputusan dan implementasi teknis dalam perancangan ini memiliki fondasi teoretis yang kuat dan dapat dipertanggungjawabkan.

2.2.1 Ulasan Konsumen di Media Sosial

Perkembangan media sosial yang masif telah melahirkan fenomena konten yang dibuat oleh pengguna, atau yang lebih dikenal dengan istilah *User-Generated Content* (UGC) [24]. UGC merujuk pada segala bentuk konten terutama teks yang dibuat dan disebarluaskan secara sukarela oleh pengguna di platform daring, bukan oleh entitas komersial. Platform seperti Twitter telah menjadi sumber utama UGC, tempat jutaan pengguna berbagi opini, pengalaman, dan ulasan mereka secara *real-time* [1]. Bagi perusahaan seperti Gojek dan Grab, ulasan-ulasan ini merupakan bentuk UGC yang otentik dan telah menjadi aset strategis yang sangat berharga, karena mencerminkan suara konsumen secara langsung [6].

Konten yang dihasilkan pengguna ini mengandung informasi krusial mengenai kepuasan pelanggan, keluhan spesifik pada layanan, hingga saran untuk inovasi produk, yang secara tidak langsung dapat memengaruhi keputusan pembelian calon pelanggan lainnya [25]. Namun, UGC memiliki karakteristik *Big Data* yang kompleks, yaitu *Volume* (jumlah yang sangat besar), *Velocity* (kecepatan data yang dihasilkan secara terus-menerus), dan *Variety* (data bersifat tidak terstruktur dan informal) [4]. Karakteristik ini membuat analisis manual menjadi tidak efisien, memakan waktu, dan rentan terhadap bias [25]. Karena itu, klasifikasi teks UGC secara *real-time* menjadi sebuah tantangan komputasi yang signifikan, sehingga diperlukan pendekatan analisis sentimen otomatis untuk mengolah data masif ini dan mengekstrak wawasan berharga untuk mendukung pengambilan keputusan yang strategis [4][24].

2.2.2 Klasifikasi Teks Multi-Label

Analisis ulasan konsumen di media sosial sering kali lebih kompleks daripada sekadar mengategorikan sentimen menjadi positif atau negatif [5]. Sebuah ulasan tunggal dapat mengandung beberapa dimensi informasi secara bersamaan. Sebagai contoh, sebuah *tweet* dapat membahas topik seperti "GoFood" sekaligus memiliki intensi seperti "Keluhan".

Perbedaan mendasar antara "Topik" dan "Intensi" perlu dipertegas sebagai penjelasan berikut. Topik merujuk pada objek atau layanan spesifik yang sedang dibicarakan (seperti GoRide, GrabCar, atau OVO). Sementara itu, Intensi berkaitan

dengan dorongan psikologis di balik teks tersebut. Merujuk pada literatur mengenai perilaku, intensi didefinisikan sebagai niat, tekad, atau indikasi seberapa kuat keinginan seseorang untuk mencoba atau melakukan suatu perilaku tertentu [26]. Jika ditarik ke dalam konteks ulasan Gojek dan Grab, Intensi merepresentasikan tujuan komunikatif (*communicative goal*) atau niat yang mendorong pengguna untuk menulis ulasan tersebut. Dengan kata lain, klasifikasi intensi bertujuan untuk menjawab *mengapa* pengguna menulis *tweet* tersebut apakah didasari oleh niat untuk meluapkan kekecewaan (Keluhan), niat untuk mencari tahu sesuatu (Pertanyaan), atau niat untuk memberikan apresiasi (Pujian).

Tugas untuk mengklasifikasikan satu unit data (satu *tweet*) ke dalam beberapa label atau kategori bersamaan dikenal sebagai klasifikasi *multi-label* (*multi-label classification*). Sebagian besar penelitian sebelumnya masih menyederhanakan masalah ini dengan hanya fokus pada satu dimensi, seperti sentimen umum [6][25].

Pendekatan *multi-label* memungkinkan analisis yang jauh lebih mendalam. Daripada hanya mengetahui bahwa sebuah ulasan bernada negatif, perusahaan dapat mengetahui secara spesifik bahwa itu adalah "keluhan tentang layanan GoCar" atau "pujian untuk promo GrabFood". Untuk mengatasi tantangan ini secara teknis, salah satu strategi yang umum digunakan adalah mengubah satu masalah *multi-label* yang kompleks menjadi beberapa masalah klasifikasi biner yang lebih sederhana. Dalam pendekatan ini, model *machine learning* dilatih

secara terpisah untuk setiap kemungkinan label (satu model untuk label topik, satu model untuk label intensi) untuk memutuskan apakah label tersebut relevan atau tidak untuk data yang diberikan.

Pelatihan model untuk klasifikasi *multi-class* memerlukan *dataset* yang memiliki label *ground truth*. Dalam perancangan ini, proses pelabelan berlangsung secara manual (anotasi) terhadap data ulasan Twitter yang telah di *scrapping* melalui Tweet Harvest. Data hasil *scrapping* akan dipilah untuk masing-masing model hingga mencapai sebanyak 6.000 data dengan persebaran distribusi yang seimbang untuk tiap *class*. Setiap ulasan dibaca dan diberi dua label yaitu satu label untuk Topik Layanan (GoFood, GrabCar, OVO, dll.) dan satu label untuk Intensi Pengguna (Keluhan, Pujian, Pertanyaan, Saran-Kritik). Proses anotasi manual ini krusial untuk menghasilkan data latih yang berkualitas dan menjadi dasar bagi model untuk mempelajari pola klasifikasi yang diinginkan.

2.2.3 Text Preprocessing

Text preprocessing adalah tahap penting di dalam proyek NLP yang bertujuan untuk membersihkan dan mentransformasi data teks mentah yang tidak terstruktur menjadi terstruktur, bersih, dan siap untuk bisa diolah oleh algoritma *machine learning* [14]. Proses ini sangat krusial, terutama saat bekerja dengan data dari media sosial seperti Twitter yang bersifat *noisy* (mengandung banyak gangguan), informal, dan tidak konsisten [14]. Kualitas data dari tahap

preprocessing akan sangat memengaruhi performa, akurasi, dan kemampuan generalisasi model klasifikasi [25].

Berdasarkan telaah dari berbagai penelitian relevan, tahapan-tahapan *preprocessing* yang akan diimplementasikan dalam penelitian ini meliputi:

1. *Case Folding*: Proses mengubah semua huruf dalam teks menjadi format seragam, yaitu huruf kecil (*lowercase*). Tujuannya adalah untuk memastikan kata seperti "Gojek", "gojek", dan "GOJEK" dianggap sebagai *token* yang sama oleh model [8].
2. *Cleansing* (Pembersihan Teks): Tahap untuk menghilangkan bagian-bagian dari teks yang tidak relevan (*noise*) dan tidak memberikan informasi signifikan untuk analisis sentimen. Proses ini mencakup penghapusan *username* (contoh: @gojek), *hashtag* (#), *emoji*, URL, angka, dan tanda baca [14].
3. *Normalization* (Normalisasi Kata): Tahap ini berfokus pada pengubahan kata-kata tidak baku, singkatan, atau kesalahan ketik (*typo*) ke dalam bentuk standar dalam Bahasa Indonesia. Proses ini dilakukan dengan menggunakan kamus normalisasi (*slang word dictionary*) yang telah dibuat sebelumnya. Sebagai contoh, kata-kata informal seperti "pke", "yg", atau "ga" akan diubah menjadi bentuk bakunya yaitu "pakai", "yang", dan "tidak". Langkah ini sangat penting untuk mengurangi variasi kata yang tidak perlu dan menyeragamkan kosakata sebelum diproses oleh model.
4. *Tokenizing* (Tokenisasi): Proses memecah kalimat atau dokumen teks menjadi unit-unit yang lebih kecil yang disebut token, yang umumnya berupa kata-kata

tunggal [3]. Proses ini memungkinkan setiap kata dapat dibobotkan secara individual pada tahap ekstraksi fitur [8].

5. *Stopword Removal (Filtering)*: Proses menghilangkan kata-kata umum yang sering muncul namun tidak memiliki makna sentimen yang kuat (*stopwords*), seperti kata sambung (“dan”, “yang”), kata depan (“di”, “ke”), dan kata ganti [14].
6. *Stemming*: Proses mengubah kata-kata berimbuhan ke bentuk kata dasarnya (*root word* atau *stem*) dalam Bahasa Indonesia [3]. Contohnya, kata "pelayanan", "melayani", dan "dilayani" akan diubah menjadi kata dasar "layan". Tujuannya adalah untuk mengurangi jumlah fitur unik dan menyatukan kata-kata yang memiliki makna inti yang sama [14]

2.2.4 Ekstraksi Fitur: TF-IDF

Setelah teks dibersihkan, teks tersebut perlu diubah menjadi representasi numerik agar dapat diproses oleh algoritma *machine learning*. Salah satu metode yang paling populer dan efektif adalah *Term Frequency-Inverse Document Frequency* (TF-IDF) [14]. TF-IDF adalah metode pembobotan statistik yang mengukur seberapa penting sebuah kata dalam suatu dokumen relatif terhadap keseluruhan koleksi dokumen (korpus) [20]. Bobot TF-IDF dihitung dari dua komponen [14]:

1. *Term Frequency* (TF): Mengukur frekuensi kemunculan sebuah kata (*term*) dalam sebuah dokumen [14].

$$TF(t, d) = \frac{f_{t,d}}{n_d} \quad (2.1)$$

Keterangan :

$TF(t, d)$ = *Term Frequency*

$f_{t,d}$ = jumlah kemunculan *term* t dalam dokumen d

n_d = total *term* dalam dokumen d

2. *Inverse Document Frequency* (IDF): Mengukur seberapa informatif sebuah kata. Kata yang sering muncul di banyak dokumen akan memiliki nilai IDF yang rendah, sedangkan kata yang jarang muncul akan memiliki nilai IDF yang tinggi[14].

$$IDF(t) = \log \left(\frac{N}{df_t} \right) \quad (2.2)$$

Keterangan:

$IDF(t)$ = *Inverse Document Frequency*

N = total jumlah dokumen dalam korpus

df_t = jumlah dokumen yang mengandung *term* t

3. Bobot akhir TF-IDF : Bobot akhir yang didapat dari hasil perkalian antara nilai TF dan IDF [14].

$$TF - IDF(t, d) = TF(t, d) \times IDF(t) = \frac{f_{t,d}}{n_d} \times \log \left(\frac{N}{df_t} \right) \quad (2.3)$$

Keterangan:

$TF - IDF(t, d)$ = Bobot gabungan TF dan IDF

t = kata/*term* yang dihitung

d = dokumen yang dihitung

$f_{t,d}$ = jumlah kemunculan term t dalam dokumen d

n_d = total *term* (kata) dalam dokumen d

N = total jumlah dokumen dalam korpus

df_t = jumlah dokumen yang mengandung term t

2.2.5 Ensemble Learning (Stacking Ensemble)

Ensemble learning adalah sebuah pendekatan dalam *machine learning* di mana beberapa model individual, yang juga dikenal sebagai *base learners*, digabungkan untuk menghasilkan satu model prediksi akhir yang lebih kuat, akurat, dan stabil [27]. Tujuan utama dari pendekatan ini adalah untuk mendapatkan performa yang lebih superior dibandingkan jika hanya menggunakan satu model tunggal [28].

Salah satu metode *ensemble* yang paling canggih dan efektif adalah *Stacked Generalization* atau *Stacking*. *Stacking* adalah sebuah teknik yang mengombinasikan prediksi dari beberapa model klasifikasi atau regresi yang berbeda melalui sebuah *meta-model* (juga disebut *generalizer* atau *meta-learner*) [9]. Berbeda dengan metode *ensemble* lain seperti *bagging* atau *boosting* yang umumnya menggunakan model homogen, keunggulan utama *Stacking* adalah

kemampuannya untuk menggabungkan model-model yang heterogen (berbeda jenis) untuk saling melengkapi kekuatan dan menutupi kelemahan masing-masing [11]. Arsitektur *Stacking* bekerja dengan struktur dua tingkat [9]:

1. Level 0 (*Base Layer*): Pada level ini, beberapa model dasar (*base-models*) yang beragam dilatih secara independen pada *dataset training*. Dalam penelitian ini, *base-models* yang digunakan adalah *XGBoost* dan *LightGBM*. Hasil prediksi dari setiap *base-model* ini tidak langsung menjadi output akhir, melainkan dikumpulkan untuk menjadi *dataset* baru. Pemilihan *XGBoost* dan *LightGBM* sebagai *base-model* dalam arsitektur *Stacking* ini didasarkan pada strategi untuk menggabungkan keunggulan masing-masing. *XGBoost* dipilih karena reputasinya dalam mencapai akurasi yang sangat tinggi dan kemampuannya menangani pola data yang kompleks. Sementara itu, *LightGBM* dipilih karena kecepatan pelatihan dan efisiensi komputasi yang superior, terutama pada *dataset* besar. Dengan mengombinasikan keduanya, sistem yang dirancang diharapkan tidak hanya memiliki akurasi prediksi yang andal, tetapi juga responsif dan efisien sebuah syarat penting untuk aplikasi *dashboard* interaktif.
2. Level 1 (*Meta-Layer*): Prediksi-prediksi yang dihasilkan oleh *base-models* dari Level 0 kemudian digunakan sebagai fitur masukan (*meta-features*) untuk melatih sebuah *meta-model*. *Meta-model* inilah yang akan mempelajari pola

dari prediksi *base-models* dan menghasilkan prediksi akhir yang lebih akurat.

Dalam penelitian ini, *Logistic Regression* akan bertindak sebagai *meta-model*.

Secara konseptual, proses ini dapat direpresentasikan dengan rumus berikut [11]:

$$\hat{y}_{stacking} = f_{meta}(f_{xgb}(x), f_{lgbm}(x)) \quad (2.4)$$

Keterangan:

$\hat{y}_{stacking}$ = prediksi akhir dari model *stacking*.

f_{meta} = fungsi dari *meta-model* (*Logistic Regression*).

$f_{xgb}(x)$ = prediksi yang dihasilkan oleh model *XGBoost*.

$f_{lgbm}(x)$ = prediksi yang dihasilkan oleh model *LightGBM*.

x = data masukan awal.

Untuk menghindari *overfitting*, proses pelatihan *meta-model* biasanya menggunakan prediksi dari *base-models* yang dihasilkan melalui prosedur *cross-validation* [9]. Pendekatan *stacking* ini terbukti mampu meningkatkan akurasi secara signifikan karena dapat memanfaatkan kekuatan dari berbagai jenis model dan meminimalkan kelemahan individualnya [28].

2.2.6 Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting (XGBoost) adalah sebuah implementasi algoritma *gradient boosting* yang telah dioptimalkan untuk performa, kecepatan, dan efisiensi tinggi [10]. *XGBoost* termasuk dalam kategori metode *ensemble boosting*, di mana model dibangun secara *sequential* dengan menggabungkan beberapa *weak learners* (umumnya berupa *decision tree*) untuk membentuk satu *strong learner* [11][8]. Pada setiap iterasinya, sebuah *decision tree* baru dilatih untuk memperbaiki kesalahan (*residual*) dari gabungan pohon-pohon sebelumnya, sebuah proses yang dikenal sebagai *additive training* [10][29]. Prediksi akhir dari model *XGBoost* merupakan penjumlahan dari hasil prediksi setiap pohon individual dalam *ensemble* tersebut. Secara matematis, prediksi untuk data ke- i dapat dituliskan sebagai berikut [10].

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), f_k \in F \quad (2.5)$$

Keterangan

$\hat{y}_i$ = prediksi untuk sampel ke- i

K = jumlah total pohon (*decision tree*).

f_k = fungsi dari pohon ke- k .

F = himpunan semua kemungkinan *Classification and Regression Trees* (CART).

Keunggulan utama *XGBoost* terletak pada fungsi objektif (*objective function*) yang canggih. Fungsi ini tidak hanya mengukur seberapa baik model cocok dengan data latih (*training loss*), tetapi juga menyertakan *regularization term* untuk mengontrol kompleksitas model dan mencegah *overfitting* [10][11]. Fungsi objektifnya dapat ditulis sebagai [10] :

$$Obj(\theta) = L(\theta) + \Omega(\theta) \quad (2.6)$$

Keterangan :

$Obj(\theta)$ = fungsi objektif

$L(\theta)$ = *loss function* untuk mengukur selisih label aktual dengan hasil prediksi

$\Omega(\theta)$ = *regularization term* untuk mengontrol kompleksitas model

Pada iterasi ke- t , fungsi objektif dioptimalkan menggunakan pendekatan *second-order Taylor expansion* untuk menemukan pohon f_t terbaik yang akan ditambahkan ke model [9][10]. Untuk tugas klasifikasi biner seperti dalam penelitian ini, *loss function* ($L(\theta)$) yang umum digunakan adalah *Log Loss* atau *Binary Cross-Entropy*, yang mengukur selisih antara label aktual (y_i) dengan hasil prediksi ($\hat{y}_i$). Rumus *Log Loss* untuk satu data adalah [30]:

$$L_i = -[y_i \ln(\hat{y}_i) + (1 - y_i) \ln(1 - \hat{y}_i)] \quad (2.7)$$

Keterangan :

L_i = *Loss function*

y_i : label aktual (0 atau 1)

$\hat{y}_i$: probabilitas hasil prediksi

Optimasi menggunakan pendekatan Taylor membutuhkan turunan pertama dan kedua dari *loss function*, yang dikenal sebagai gradien (g_i) dan hessian (h_i). Keduanya didefinisikan sebagai berikut [10][31]:

$$g_i = \frac{\partial L(y_i, \hat{y}_i^{t-1})}{\partial \hat{y}_i^{t-1}} \quad (2.8)$$

$$h_i = \frac{\partial^2 L(y_i, \hat{y}_i^{t-1})}{\partial \hat{y}_i^{t-1}} \quad (2.9)$$

Keterangan :

g_i = *pseudo-residual* / gradien yang menjadi arah perbaikan

h_i = hessian yang dipakai untuk menghitung bobot daun

$\hat{y}_i^{(t-1)}$ = prediksi data ke- i sebelum pohon ke- t ditambahkan

y_i = label aktual (0 atau 1)

Regularization term pada *XGBoost* secara eksplisit menghukum kompleksitas pohon, yang didefinisikan sebagai [10][11]:

$$\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.10)$$

Keterangan:

$\Omega(f_k)$ = *regularization term* untuk pohon ke- k

T = jumlah daun (*leaf*) pada sebuah pohon.

w_j = skor (bobot) pada daun ke- j .

γ = gamma yaitu parameter penalti untuk jumlah daun.

λ = lambda yaitu parameter penalti untuk L2 *regularization* pada bobot daun.

Proses pertumbuhan pohon dilakukan dengan memilih *split* terbaik pada sebuah node, yang dievaluasi menggunakan *Split Gain*. Rumus gain ditulis sebagai [10]:

$$Gain = \frac{1}{2} \left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} + \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right) - \gamma \quad (2.11)$$

Keterangan:

G_L = Jumlah gradien dari sampel data yang masuk ke cabang kiri setelah *split*.

H_L = Jumlah gradien dari sampel data yang masuk ke cabang kiri setelah *split*.

G_R = Jumlah gradien dari sampel data yang masuk ke cabang kanan setelah *split*.

H_R = Jumlah hessian dari sampel data yang masuk ke cabang kanan setelah *split*.

γ = Gamma yaitu parameter penalti untuk jumlah daun.

λ = Lambda yaitu parameter penalti untuk L2 *regularization* pada bobot daun.

Akhirnya, prediksi diperbarui dengan menambahkan kontribusi pohon baru. Jika dilengkapi dengan *learning rate* η , pembaruan prediksi ditulis sebagai [10]:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta \cdot w_j \quad (2.12)$$

Keterangan:

$\hat{y}_i^{(t)}$: prediksi data ke-i pada iterasi ke-t.

$\hat{y}_i^{(t-1)}$: prediksi data ke-i sebelum iterasi ke-t.

w_j : bobot daun hasil training di iterasi ke-t.

η : learning rate (nilai antara 0 – 1, default biasanya 0.3).

Dengan mekanisme tersebut, *XGBoost* menghasilkan model yang akurat, efisien, serta memiliki kemampuan generalisasi yang baik pada data baru

2.2.7 Light Gradient Boosting Machine (LightGBM)

Light Gradient Boosting Machine (LightGBM) adalah sebuah kerangka kerja *gradient boosting* yang bersifat *open-source* dan berkinerja tinggi, dikembangkan oleh Microsoft dengan menggunakan *decision tree* sebagai model dasarnya [7]. Algoritma ini dirancang secara spesifik untuk menjadi sangat efisien dari segi kecepatan komputasi dan penggunaan memori, terutama saat menangani *dataset* berukuran besar, tanpa mengorbankan akurasi [9]. Seperti model *boosting* lainnya, *LightGBM* membangun model, di mana setiap *decision tree* baru dilatih untuk memperbaiki kesalahan dari pohon-pohon sebelumnya [7].

Keunggulan performa *LightGBM* berasal dari beberapa inovasi teknis yang membedakannya dari implementasi *gradient boosting* lainnya. Tiga inovasi utamanya adalah:

1. *Histogram-based Algorithm*: Berbeda dengan algoritma tradisional yang perlu melakukan *sorting* terhadap semua nilai fitur untuk menemukan titik potong (*split point*) terbaik, *LightGBM* menggunakan pendekatan berbasis histogram. Algoritma ini mengubah nilai-nilai fitur yang kontinu menjadi bin-bin diskrit dan membuat histogram [9]. Dengan demikian, proses pencarian titik potong menjadi jauh lebih cepat dan penggunaan memori menjadi lebih efisien.
2. *Gradient-based One-Side Sampling* (GOSS): Untuk mempercepat proses pelatihan, GOSS adalah sebuah metode sampling data yang cerdas. Teknik ini mempertahankan semua sampel data yang memiliki gradien besar (sampel

yang masih memiliki *error* tinggi dan informatif untuk dipelajari), lalu secara acak mengambil sebagian kecil sampel data dengan gradien kecil (sampel yang sudah diprediksi dengan baik) [7][11]. Dengan cara ini, model dapat lebih fokus belajar dari kesalahan yang signifikan tanpa harus memproses seluruh *dataset* pada setiap iterasi.

3. *Exclusive Feature Bundling* (EFB): Teknik ini dirancang untuk mengurangi dimensi data pada *dataset* yang bersifat *sparse* (memiliki banyak nilai nol). EFB bekerja dengan menggabungkan fitur-fitur yang bersifat saling eksklusif (yaitu fitur-fitur yang jarang sekali memiliki nilai non-nol secara bersamaan) menjadi satu fitur tunggal (*feature bundle*). Proses ini secara efektif mengurangi jumlah fitur yang perlu diproses tanpa kehilangan banyak informasi, sehingga mempercepat pelatihan [7][11].

Selain ketiga teknik di atas, LightGBM juga menggunakan strategi pertumbuhan pohon secara *leaf-wise*, berbeda dengan strategi *level-wise* yang umum digunakan. Pada strategi *leaf-wise*, pohon ditumbuhkan dengan selalu memilih daun (*leaf*) yang akan memberikan penurunan *loss* paling besar saat dipecah. Hal ini memungkinkan model untuk mencapai konvergensi lebih cepat dan sering kali menghasilkan model yang lebih akurat, meskipun berpotensi *overfitting* pada *dataset* yang lebih kecil [7].

Fungsi objektif yang dioptimalkan oleh *LightGBM* secara umum mirip dengan *gradient boosting* lainnya, yang terdiri dari *loss function* dan *regularization term* untuk mengontrol kompleksitas [9]:

$$Obj(t) = L(t) + \Omega(t) + c \quad (2.13)$$

Keterangan

$Obj(t)$ = nilai objektif total pada iterasi/pohon ke- t

$L(t)$ = *Loss function*

$\Omega(t)$ = *Regularization term*

c = Sebuah konstanta.

Loss function mengukur seberapa baik model memprediksi nilai target. Pilihan *loss function* bergantung pada jenis masalah (regresi atau klasifikasi). Untuk tugas regresi, *loss function* yang umum digunakan adalah *Mean Squared Error* [9]:

$$L(t) = \sum_{i=1}^n (y_i(t) - \hat{y}_i(t))^2 \quad (2.14)$$

Keterangan :

$L(t)$ = *Loss function*

y_i = Nilai target aktual (kontinu/numerik)

$\hat{y}_i$ = Nilai prediksi model (kontinu/numerik)

Variabel $y_i(t)$ adalah nilai aktual dan $\hat{y}_i(t)$ adalah nilai prediksi pada iterasi ke- t . Untuk tugas klasifikasi biner, *loss function* yang umum digunakan adalah *Binary Cross-Entropy* atau *Log Loss*. Rumusnya dapat dilihat sebagai berikut [30]:

$$L_i = -[y_i \ln(\hat{y}_i) + (1 - y_i) \ln(1 - \hat{y}_i)] \quad (2.15)$$

Keterangan:

L_i = nilai *loss* untuk sampel ke- i

y_i = label aktual (0 atau 1)

$\hat{y}_i$ = probabilitas prediksi untuk sampel ke- i

Untuk mengoptimalkan *loss function* secara efisien, *LightGBM* menggunakan aproksimasi Taylor orde kedua, yang memanfaatkan *Gradien* (turunan pertama) dan *Hessian* (turunan kedua) dari *loss function*. Gradien (g_i) menunjukkan arah dan besaran kesalahan untuk setiap sampel data. Sedangkan Hessian (h_i) memberikan informasi kelengkungan (*curvature*) dari *loss function*, yang membantu proses optimalisasi. Berikut adalah rumus perhitungannya[10]:

$$g_i = \frac{\partial L(y_i, \hat{y}_i^{t-1})}{\partial \hat{y}_i^{t-1}} \quad (2.16)$$

$$h_i = \frac{\partial^2 L(y_i, \hat{y}_i^{t-1})}{\partial \hat{y}_i^{t-1}} \quad (2.17)$$

Keterangan :

g_i = *pseudo-residual* / gradien yang menjadi arah perbaikan

h_i = *hessian* yang dipakai untuk menghitung bobot daun

$\hat{y}_i^{(t-1)}$ = prediksi data ke- i sebelum pohon ke- t ditambahkan

y_i = label aktual (0 atau 1)

Untuk memastikan model tidak menjadi terlalu rumit dan menyebabkan *overfitting*, *LightGBM* menerapkan sebuah mekanisme kontrol yang disebut istilah regularisasi (*regularization term*). Fungsi ini secara efektif memberikan penalti pada kompleksitas pohon baru yang akan ditambahkan. Penalti ini menargetkan dua aspek yaitu jumlah total daun (*leaf*) pada pohon, dan besaran bobot atau skor prediksi pada setiap daun. Dengan mengontrol kedua elemen ini, model didorong untuk membentuk pohon yang lebih sederhana namun tetap efektif. Secara matematis, fungsi regularisasi ini dinyatakan sebagai berikut[10] :

$$\Omega(fk) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.18)$$

Keterangan:

T = jumlah daun (*leaf*) pada sebuah pohon.

w_j = skor (bobot) pada daun ke- j .

γ = Gamma yaitu parameter penalti untuk jumlah daun.

λ = Lambda yaitu parameter penalti untuk L2 *regularization* pada bobot daun.

Kunci utama dalam proses membangun pohon keputusan adalah bagaimana algoritma memilih titik potong (*split*) terbaik pada setiap langkah. LightGBM melakukan ini dengan proses yang sangat terukur, yaitu menghitung skor yang disebut *Split Gain* untuk setiap kemungkinan *split*. Rumus *gain* ini secara cerdas mengalkulasikan seberapa besar penurunan *loss* (kesalahan model) yang akan diperoleh jika sebuah *split* dilakukan, setelah memperhitungkan penalti regularisasi (γ dan λ). Algoritma kemudian akan memilih *split* yang menawarkan nilai *gain* tertinggi, karena itulah yang paling efektif dalam meningkatkan performa model. Rumus untuk menghitung *gain* adalah [9]:

$$Gain = \frac{1}{2} \left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} + \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right) - \gamma \quad (2.19)$$

Keterangan:

G_L = Jumlah gradien dari sampel data yang masuk ke cabang kiri setelah *split*.

H_L = Jumlah gradien dari sampel data yang masuk ke cabang kiri setelah *split*.

G_R = Jumlah gradien dari sampel data yang masuk ke cabang kanan setelah *split*.

H_R = Jumlah hessian dari sampel data yang masuk ke cabang kanan setelah *split*.

γ = Gamma yaitu parameter penalti untuk jumlah daun.

λ = Lambda yaitu parameter penalti untuk L2 *regularization* pada bobot daun.

Kombinasi dari teknik-teknik inovatif ini menjadikan *LightGBM* sebagai salah satu algoritma yang sangat kuat dan efisien untuk tugas-tugas klasifikasi dan regresi modern.

2.2.8 *Logistic Regression (Meta-Model)*

Logistic Regression adalah salah satu algoritma *machine learning* yang fundamental dan kuat yang digunakan untuk menyelesaikan masalah klasifikasi, terutama klasifikasi biner [29][32]. Meskipun namanya mengandung kata regresi, *Logistic Regression* adalah model klasifikasi yang memprediksi probabilitas sebuah *instance* data termasuk dalam kelas tertentu (biasanya kelas “1” atau “positif”)[11].

Model ini bekerja dengan terlebih dahulu menghitung kombinasi linear dari fitur-fitur masukan, serupa dengan regresi linear. Persamaan linearnya dapat ditulis sebagai berikut [32]:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n \quad (2.20)$$

Keterangan:

Y = hasil perhitungan linear (*logit*).

β_0 = *intercept*.

β_1 = koefisien (bobot) untuk setiap fitur.

X_1 = nilai dari fitur-fitur masukan.

Kemudian, untuk mengubah *output* linear (Y) menjadi sebuah probabilitas yang memiliki rentang nilai antara 0 dan 1, *Logistic Regression* menggunakan fungsi logistik (juga dikenal sebagai fungsi *sigmoid*) [11]. Rumus fungsi *sigmoid* adalah [32]:

$$P(X) = \frac{e^Y}{1 + e^Y} = \frac{1}{1 + e^{-Y}} \quad (2.21)$$

Keterangan:

$P(X)$ = Probabilitas bahwa sebuah data masuk ke kelas positif

Y = Nilai kombinasi linear dari *input*

e = Bilangan eksponensial

Probabilitas ini kemudian dipetakan ke dalam kelas biner menggunakan ambang batas (*threshold*), yang umumnya adalah 0.5. Jika $P(X) \geq 0.5$, maka data diklasifikasikan sebagai kelas positif, dan sebaliknya [29]. Untuk mempelajari bobot β yang optimal, *Logistic Regression* menggunakan metode memaksimalkan *likelihood*. *Likelihood* menggambarkan probabilitas model menghasilkan label aktual y_i berdasarkan probabilitas prediksi P_i [32]:

$$LL(\beta) = \sum_{i=1}^m [y_i \ln(P_i) + (1 - y_i) \ln(1 - p_i)] \quad (2.22)$$

Keterangan:

$LL(\beta)$ = Nilai total log-likelihood total untuk semua data

m = Nilai kombinasi linear dari input

y_i = label aktual untuk instansi ke- i (0 atau 1)

P_i = probabilitas prediksi untuk instansi ke- i

Gradien log-likelihood terhadap masing-masing bobot β dihitung sebagai [32]:

$$\frac{\partial LL(\beta)}{\partial \beta_j} = \sum_{i=1}^m (y_i - P_i) X_{ij} \quad (2.23)$$

Keterangan:

$\frac{\partial LL(\beta)}{\partial \beta_j}$ = Gradien (turunan) dari *Log-Likelihood* terhadap satu bobot spesifik, yaitu

$\beta_j(y_i - P_i)$ = *error* antara label aktual dan probabilitas prediksi untuk data ke- i .

X_{ij} = Nilai fitur ke- j dari data ke- i .

Gradien ini digunakan dalam metode numerik seperti *gradient ascent* atau *gradient descent* untuk memperbarui bobot β agar *log-likelihood* meningkat dan prediksi model semakin akurat. Dalam arsitektur *Stacking Ensemble*, *Logistic Regression* sering dipilih sebagai *meta-model* karena beberapa keunggulannya:

1. Sederhana dan Cepat: *Logistic Regression* memiliki kebutuhan komputasi yang rendah sehingga proses pelatihan *meta-model* menjadi sangat efisien [11].
2. Mudah diinterpretasikan: Model ini relatif mudah diinterpretasikan dibandingkan dengan model yang lebih kompleks, karena koefisien (β) dapat memberikan gambaran tentang pentingnya setiap *base-model* [29].
3. Efektif: Terbukti efektif dalam menemukan hubungan linear antara prediksi dari *base-model* dan hasil akhir yang sebenarnya.

Dalam penelitian ini, *Logistic Regression* akan berfungsi sebagai *generalizer* di Level 1. Model ini akan mengambil probabilitas prediksi dari *XGBoost* dan *LightGBM* sebagai fitur *input* (X_1 dan X_2) untuk menghitung probabilitas akhir,

yang kemudian digunakan untuk menentukan klasifikasi topik dan intensi yang final.

2.2.9 Hyperparameter Tuning

Performa dari sebuah model *machine learning* tidak hanya ditentukan oleh kualitas data atau arsitektur algoritma, tetapi juga sangat dipengaruhi oleh konfigurasi *hyperparameter*-nya. *Hyperparameter* adalah parameter eksternal yang nilainya perlu ditetapkan sebelum proses pelatihan model dimulai, karena pengaturan ini mengontrol perilaku pembelajaran model, seperti seberapa kompleks model yang akan dibangun atau seberapa cepat model tersebut belajar [33]. Proses untuk menemukan kombinasi *hyperparameter* yang optimal untuk sebuah *dataset* dan masalah tertentu disebut *hyperparameter tuning* atau optimasi *hyperparameter*. Tanpa proses *tuning* yang sistematis, sebuah model yang kuat sekalipun mungkin tidak akan mencapai performa maksimalnya, sehingga proses ini menjadi langkah krusial untuk meningkatkan akurasi dan efektivitas model klasifikasi [34].

Salah satu metode *hyperparameter tuning* yang paling umum dan efektif adalah *Grid Search CV (Cross-Validation)*. Metode ini bekerja secara sistematis dengan cara mendefinisikan sebuah *grid* dari semua kemungkinan kombinasi nilai *hyperparameter* yang ingin diuji [33]. Kemudian, model akan dilatih dan dievaluasi untuk setiap kombinasi dalam kisi tersebut menggunakan teknik *n-Fold Cross-Validation*.

Dalam teknik ini, data latih dibagi menjadi n bagian (*folds*) yang sama besar. Proses pelatihan dan validasi dilakukan sebanyak n kali (iterasi), di mana pada setiap iterasi, satu bagian digunakan sebagai data validasi sementara $n - 1$ bagian lainnya digunakan sebagai data latih. Hasil evaluasi dari setiap iterasi kemudian dirata-ratakan untuk mendapatkan estimasi performa yang stabil dan tidak bias.

Kombinasi *hyperparameter* yang menghasilkan skor evaluasi terbaik (misalnya, *F1-Score* tertinggi) akan dipilih sebagai konfigurasi optimal untuk model akhir [34]. Dalam penelitian ini, *Grid Search CV* akan diterapkan pada setiap model XGBoost, LightGBM, dan *meta-model Logistic Regression* untuk memastikan bahwa perbandingan performa dilakukan secara adil dan setiap model telah mencapai potensi terbaiknya.

2.2.10 Metrik Evaluasi

Untuk mengukur kinerja model pada tugas klasifikasi *multi-class* secara kuantitatif, evaluasi dilakukan dengan menggunakan *Confusion Matrix* sebagai dasarnya. Pada kasus *multi-class* dengan N (jumlah kelas), *confusion matrix* akan berbentuk sebuah tabel matriks $N \times N$ yang membandingkan label kelas aktual dengan label kelas prediksi. Elemen pada diagonal utama matriks menunjukkan jumlah prediksi yang benar, sementara elemen di luar diagonal menunjukkan kesalahan klasifikasi antar kelas.

Dari matriks tersebut, metrik performa utama dapat dihitung. Untuk metrik selain akurasi, diperlukan strategi agregasi untuk mendapatkan skor performa model secara keseluruhan. Dua metode agregasi yang umum digunakan adalah *Macro Average*, yang memberikan bobot sama pada setiap kelas, dan *Weighted Average*, yang memberikan bobot berdasarkan jumlah sampel (*support*) di setiap kelas.

Metrik-metrik yang akan digunakan dalam perancangan ini adalah sebagai berikut: [32][16]:

1. Akurasi (*Accuracy*): Mengukur proporsi total prediksi yang benar dari keseluruhan data. Untuk rumus perhitungan *Accuracy* dapat dilihat pada rumus berikut ini[35] :

$$Accuracy = \frac{Jumlah\ Prediksi\ Benar}{Total\ Seluruh\ Data} \quad (2.24)$$

2. Presisi (*Precision*): mengukur kemampuan model untuk tidak salah melabeli sebuah sampel sebagai kelas tertentu. Metrik ini dihitung untuk setiap kelas terlebih dahulu, kemudian diagregasi. Untuk rumus perhitungan *Precision* dapat dilihat pada rumus berikut ini [35]:

$$Precision_{macro} = \frac{1}{N} \sum_{i=1}^N Precision_i \quad (2.25)$$

$$Precision_{weighted} = \sum_{i=1}^N \left(\frac{Support_i}{Total\ Sampel} \times Precision_i \right) \quad (2.26)$$

Keterangan:

N: Jumlah total kelas dalam *dataset*

i: Indeks untuk setiap kelas, dari kelas ke-1 hingga kelas ke-N.

$Precision_i$: Nilai *Precision* kelas ke-i.

$Support_i$: Jumlah sampel (data) aktual yang termasuk dalam kelas ke-i.

Total Sampel: Jumlah keseluruhan data dalam *dataset*.

3. *Recall (Sensitivity)*: Mengukur proporsi data positif aktual yang berhasil diidentifikasi dengan benar oleh model. Untuk rumus perhitungan *Recall* dapat dilihat pada rumus berikut ini [35]:

$$Recall_{macro} = \frac{1}{N} \sum_{i=1}^N Recall_i \quad (2.27)$$

$$Recall_{weighted} = \sum_{i=1}^N \left(\frac{Support_i}{Total\ Sampel} \times Recall_i \right) \quad (2.28)$$

Keterangan:

N: Jumlah total kelas dalam *dataset*

i: Indeks untuk setiap kelas, dari kelas ke-1 hingga kelas ke-N.

$Recall_i$: Nilai *Recall* kelas ke-i.

$Support_i$: Jumlah sampel (data) aktual yang termasuk dalam kelas ke-i.

Total Sampel: Jumlah keseluruhan data dalam *dataset*.

4. *F1-Score*: Rata-rata harmonik dari Presisi dan *Recall*, yang sangat berguna pada kasus data tidak seimbang (*imbalanced data*). Berikut adalah rumusnya [35]:

$$F1 - score_{macro} = \frac{1}{N} \sum_{i=1}^N F1_i \quad (2.29)$$

$$F1 - Score_{weighted} = \sum_{i=1}^N \left(\frac{Support_i}{Total\ Sampel} \times F1_i \right) \quad (2.30)$$

Keterangan:

N: Jumlah total kelas dalam *dataset*

i: Indeks untuk setiap kelas, dari kelas ke-1 hingga kelas ke-N.

$f1_i$: Nilai *F1-Score* yang dihitung secara spesifik untuk kelas ke-i.

$Support_i$: Jumlah sampel (data) aktual yang termasuk dalam kelas ke-i.

Total Sampel: Jumlah keseluruhan data dalam *dataset*.

2.2.11 Validasi Data (*Inter-Annotator Agreement*)

Kualitas dari *dataset* berlabel (*annotated dataset*) sangat bergantung pada konsistensi dan objektivitas para pelabel (*annotator*). Untuk mengukur tingkat kesepakatan antar penilai secara kuantitatif, digunakan metrik *Inter-Annotator Agreement* (IAA). Salah satu metrik IAA yang paling umum digunakan adalah Cohen's Kappa (κ) [36][37].

Cohen's Kappa adalah ukuran statistik yang menyatakan seberapa konsisten dua penilai dalam membuat keputusan, dengan memperhitungkan dan mengoreksi kemungkinan kesepakatan yang terjadi hanya karena kebetulan. Skor Kappa dihitung dengan rumus berikut [37]:

$$k = \frac{P_o - P_e}{1 - P_e} \quad (2.31)$$

Keterangan:

κ (Kappa): Koefisien Kappa yang menunjukkan tingkat kesepakatan.

P_o (*Observed Agreement*): Proporsi kesepakatan yang benar-benar teramati antara dua penilai (jumlah data yang labelnya sama dibagi total data).

P_e (*Expected Agreement*): Proporsi kesepakatan yang diharapkan terjadi secara kebetulan.

Skor Kappa yang dihasilkan berkisar dari -1 hingga 1 dan memberikan indikasi kekuatan kesepakatan. Interpretasi umum untuk nilai Kappa adalah sebagai berikut:

1. < 0 : Kesepakatan lebih buruk dari kebetulan.
2. $0.01 - 0.20$: Sedikit (*Slight*).
3. $0.21 - 0.40$: Cukup (*Fair*).
4. $0.41 - 0.60$: Sedang (*Moderate*).

5. 0.61 – 0.80: Kuat (*Substantial*).
6. 0.81 – 1.00: Sangat Kuat (*Almost Perfect*).

Dalam konteks perancangan ini, perhitungan Cohen's Kappa akan digunakan untuk memvalidasi reliabilitas dari proses anotasi data manual, sehingga memastikan bahwa *dataset* yang digunakan untuk melatih model memiliki kualitas dan konsistensi yang tinggi.

2.2.12 Black Box Testing

Pengujian fungsional merupakan tahap kritis untuk memastikan sebuah sistem berfungsi sesuai dengan spesifikasi dan kebutuhan pengguna [17]. Salah satu metode utama dalam pengujian fungsional adalah *Black-Box Testing*. Metode ini adalah pendekatan pengujian yang berfokus pada evaluasi fungsionalitas sistem tanpa memerlukan pengetahuan tentang struktur kode internal, desain, atau cara kerja di dalamnya [17]. Pengujian *system* dilakukan dengan cara memberikan masukan (*input*) dan melihat apakah sistem memberikan keluaran (*output*) seperti yang diharapkan atau tidak [17].

Prinsip dasar dari *Black-Box Testing* adalah memverifikasi setiap fungsi pada aplikasi dari sudut pandang pengguna [38]. Berbeda dengan metode *White-Box Testing* yang memeriksa kode program, *Black-Box Testing* melakukan pengujian berdasarkan pada detail aplikasi seperti tampilan, fungsi-fungsi yang ada, dan kesesuaian alur [17]. Proses pengujian ini umumnya dilakukan dengan merancang serangkaian Skenario Uji (*Test Cases*). Sebuah *test case* secara

sistematis mendokumentasikan aktivitas pengujian, hasil yang diharapkan, dan hasil aktual yang diperoleh untuk kemudian ditarik kesimpulan statusnya (berhasil atau gagal) [38]. Metode ini bertujuan untuk menemukan berbagai jenis kesalahan, seperti fungsi yang tidak benar, kesalahan antarmuka, hingga kesalahan kinerja (*performance*) [38].

BAB III

RANCANGAN DAN PEMBUATAN

3.1 Rancangan Sistem

Rancangan sistem merupakan tahapan fundamental dalam siklus pengembangan yang bertujuan untuk mendefinisikan arsitektur, komponen, modul, antarmuka, dan data untuk sebuah sistem agar dapat memenuhi kebutuhan yang telah dispesifikasikan [39]. Bagian ini adalah rancangan dari aplikasi *dashboard* analisis ulasan, mulai dari perencanaan awal hingga analisis kebutuhan teknis yang diperlukan untuk merealisasikan sistem tersebut.

3.1.1 Perencanaan Sistem

Tahap perencanaan merupakan langkah awal yang krusial dalam proses pengembangan sistem, di mana tujuan, sasaran, dan lingkup fungsional dari sistem yang akan dibangun didefinisikan secara jelas. Perencanaan yang matang bertujuan untuk memastikan bahwa proses perancangan berjalan sesuai dengan jalur yang telah ditetapkan dan dapat menjawab permasalahan yang diangkat.

1. Tujuan dan Sasaran Rancangan

Tujuan utama dari perancangan ini adalah untuk membangun sebuah prototipe aplikasi *dashboard* interaktif yang fungsional. Sistem ini dirancang untuk mampu mengolah data ulasan konsumen Gojek dan Grab dari Twitter, kemudian menyajikan hasil klasifikasi topik dan intensi dalam bentuk

visualisasi data yang intuitif. Sasaran utama dari sistem yang dirancang adalah sebagai berikut:

- a. Menghasilkan sebuah sistem yang mampu menerima masukan (*input*) data mentah berupa *file* dengan format *.csv* atau *.xlsx* yang diunggah oleh pengguna.
- b. Merancang sistem agar mampu menjalankan seluruh alur pemrosesan data secara otomatis, mulai dari tahap *preprocessing*, ekstraksi fitur, hingga klasifikasi menggunakan model *Stacking Ensemble* yang telah dilatih.
- c. Menyajikan hasil klasifikasi kepada pengguna melalui antarmuka *dashboard* yang interaktif, yang mencakup berbagai elemen visualisasi seperti grafik, tabel ringkasan, dan *word cloud*.

2. Lingkup Fungsional Sistem

Untuk menjaga fokus dan kelayakan implementasi dalam batas waktu pengerjaan skripsi, lingkup fungsional dari sistem yang dirancang dibatasi pada beberapa aspek berikut:

- a. Aplikasi yang dibangun merupakan sebuah prototipe yang dijalankan melalui *Streamlit Cloud*, sehingga dapat diakses secara *online*.
- b. Fungsi utama sistem terbatas pada pengolahan data yang diunggah oleh pengguna. Sistem tidak dirancang untuk melakukan *scraping* data dari Twitter secara *real-time*.

- c. Model klasifikasi yang diintegrasikan ke dalam sistem adalah model yang telah dilatih sebelumnya (*pre-trained*) dan tidak melakukan proses pelatihan ulang (*retraining*) saat aplikasi dijalankan.
- d. Visualisasi data yang ditampilkan berfokus pada hasil klasifikasi dua dimensi utama, yaitu Topik Layanan dan Intensi Pengguna.

3.1.2 Kebutuhan Data


Data Untuk dapat berfungsi sesuai rancangan, sistem ini memiliki beberapa kebutuhan data fundamental:

1. Data *Input* (Untuk Prediksi): Sistem dirancang untuk menerima masukan berupa *file* .csv atau .xlsx dari pengguna. *File* ini wajib memiliki satu kolom *full_text* yang berisi teks ulasan mentah yang akan diprediksi.
2. Data Latih (Untuk Model): Inti dari sistem ini adalah model *machine learning* yang telah dilatih sebelumnya. Untuk melatih model ini, diperlukan sebuah *dataset* historis yang telah dianotasi secara manual dengan dua label target:
 - a. Label Topik: Kategori layanan yang dibicarakan (Gojek, Gocar, Gosend, Gopay, GoFood, Grab, GrabCar, Grab Express, OVO, Grab Food).
 - b. Label Intensi: Maksud atau sentimen dari ulasan (Keluhan, Pujian, pernyataan, pertanyaan, saran-kritik).
3. Data Evaluasi (Untuk Tampilan): Untuk mengisi modul "Evaluasi Model", sistem memerlukan data performa model yang telah dihitung sebelumnya

(*offline*), mencakup metrik seperti *Accuracy*, *Classification Report*, dan *Confusion Matrix* dari berbagai skenario eksperimen.

3.1.3 Diagram Use Case

Perancangan *Use Case Diagram* bertujuan untuk memvisualisasikan interaksi fungsional antara pengguna dengan sistem *dashboard* yang dikembangkan.. Aktor utama dalam sistem ini didefinisikan sebagai Analis Gojek/Grab. Rancangan *Use Case Diagram* sistem secara keseluruhan dapat dilihat pada **Gambar 3.1**.



Gambar 3. 1 Use Case Diagram Dashboard

Berdasarkan *use case dashboard* yang akan dibuat, deskripsi fungsionalitas sistem dan hubungan antar *use case* dijabarkan sebagai berikut:

1. Inisialisasi Sistem (*Startup*) : Proses dimulai dengan *use case* "Memulai Aplikasi". Aktivitas ini memiliki relasi *include* dengan "Memuat Model *Machine Learning*", yang berarti sistem secara otomatis akan memuat model *Stacking Ensemble* dan *Vectorizer* ke dalam memori saat aplikasi dijalankan. Jika model gagal dimuat, fungsi utama lainnya tidak dapat digunakan.
2. Modul Prediksi (*Prediction*) : Pengguna dapat melakukan klasifikasi ulasan melalui dua metode:
 - a. Prediksi Teks Tunggal: Pengguna memasukkan teks secara manual. Fitur ini memiliki relasi *extend* dengan "Melihat Probabilitas Detail", yang merupakan opsi tambahan bagi pengguna untuk melihat grafik keyakinan model.
 - b. Prediksi *Batch* (*File*): Pengguna memproses banyak data sekaligus. *Use case* ini memiliki relasi *include* dengan "Mengunggah *File* Mentah", menandakan bahwa pengguna wajib mengunggah *file* sebelum proses prediksi dimulai. Setelah prediksi selesai, fitur "Mengunduh Hasil Prediksi" (relasi *extend*) menjadi tersedia bagi pengguna untuk menyimpan hasil dalam format CSV.
3. Modul *Dataset* : *Use case* "Melihat Tabel *Dataset*" memungkinkan pengguna meninjau data secara tabular. Fitur ini memiliki relasi *include* dengan


"Mengunggah *Dataset* Berlabel", yang menegaskan bahwa tampilan data tidak akan muncul jika pengguna belum mengunggah file hasil prediksi. Selain itu, terdapat fitur "Menyaring Data" dan "Melihat Statistik" untuk eksplorasi lebih lanjut.

4. Modul Visualisasi (*Dashboard*) : Merupakan pusat analisis yang mencakup "Melihat Grafik Visualisasi" (batang dan lingkaran) serta "Melihat Word Cloud". Sama halnya dengan modul *dataset*, akses ke visualisasi ini mewajibkan (*include*) pengguna untuk mengunggah *dataset* berlabel terlebih dahulu.
5. Modul *About* : Menyediakan transparansi sistem melalui "Melihat Informasi Pengembang", "Melihat Evaluasi Model" untuk tinjauan kinerja teknis, dan "Mengunduh Buku Manual" sebagai panduan operasional.

3.1.4 Diagram Alir Pengguna (*User Flow*)

Untuk memberikan gambaran mengenai pengalaman pengguna saat berinteraksi dengan aplikasi, sebuah diagram alir pengguna (*user flow*) telah dirancang. Diagram ini mengilustrasikan langkah-langkah yang akan dilalui oleh pengguna, mulai dari membuka aplikasi, mengunggah data, hingga mendapatkan hasil analisis.

Tujuan dari diagram ini adalah untuk memastikan bahwa alur penggunaan aplikasi dirancang secara logis, sederhana, dan mudah diikuti. Keseluruhan alur interaksi pengguna dengan sistem dapat dilihat pada **Gambar 3.2**.




Gambar 3. 2 Flow Chart Pengguna

3.1.5 Rancangan Antarmuka Pengguna (*User Interface*)


Rancangan antarmuka pengguna (UI) berfokus pada pengalaman pengguna (*user experience*) dengan menyediakan tampilan yang intuitif, informatif, dan mudah digunakan. Aplikasi *dashboard* ini dirancang dengan beberapa modul atau halaman utama untuk memisahkan fungsionalitas secara logis, yang diakses melalui menu navigasi di *sidebar*. Alur fungsional utama dirancang sebagai berikut

1. Modul *Prediction* (Prediksi Topik dan Intensi) : Modul ini dirancang sebagai halaman utama dan langkah pertama dalam alur kerja aplikasi, yang menyediakan antarmuka untuk menerapkan model klasifikasi pada data baru. Halaman ini juga menampilkan panduan alur kerja untuk pengguna baru di dalam sebuah *expander* yang dapat ditutup. Halaman ini memiliki dua fitur utama dan dapat dilihat rancangan awal pada **Gambar 3.3** dan **Gambar 3.4**:
 - a. Prediksi Teks Tunggal: Pengguna dapat memasukkan satu teks ulasan ke dalam *text area* dan mendapatkan prediksi langsung untuk Topik dan Intensi beserta tingkat keyakinan (probabilitas). Detail probabilitas untuk 5 kelas teratas juga ditampilkan dalam bentuk grafik batang.
 - b. Prediksi *Batch*: Pengguna dapat mengunggah *file* .csv atau .xlsx baru yang berisi kolom *full_text*. Aplikasi akan memproses seluruh baris dalam *file* tersebut, menambahkan kolom prediksi (*topic*, *type*, *topic_probability*, *type_probability*), menampilkan ringkasan hasil prediksi dalam bentuk *pie*

chart, dan menyediakan tombol untuk mengunduh *file* hasil prediksi yang lengkap.



Gambar 3. 3 Rancangan Modul Prediction 1




Gambar 3. 4 Rancangan Modul Prediction 2


2. Modul *Dataset* (*Dataset Viewer*) : Modul ini dirancang untuk memungkinkan pengguna melihat dan melakukan eksplorasi awal pada data ulasan yang

diunggah. Halaman ini berfungsi setelah pengguna mengunggah *file* data yang sudah ber-label (baik *file* asli atau *file* hasil dari Modul *Prediction*) melalui *sidebar*. Tampilan Rancangan Modul *dataset* dapat dilihat pada **Gambar 3.5** dan **Gambar 3.6** Fitur utama meliputi:

- Tampilan Tabel Data: Menampilkan pratinjau data dalam bentuk tabel interaktif. Secara *default* menampilkan 20 baris pertama, dengan opsi untuk menampilkan keseluruhan data.
- Panel Filter Data: Menyediakan opsi *dropdown* untuk memfilter data berdasarkan Merek (Gojek/Grab), Topik spesifik, dan Intensi
- Statistik Ringkas: Menampilkan kartu metrik yang merangkum jumlah baris data (setelah filter), jumlah kelas unik untuk topik dan intensi, serta total nilai kosong.
- Informasi *Dataset* Asli: Menyediakan detail teknis (tipe data, jumlah *null*) dari *dataset* asli sebelum difilter.



Gambar 3. 5 Rancangan Modul *Dataset* 1




Gambar 3. 6 Rancangan Modul *Dataset* 2

3. Modul *Dashboard* (*Dashboard* Analisis Interaktif) : Modul ini dirancang sebagai pusat visualisasi interaktif untuk menganalisis tren dari data yang telah diunggah di *sidebar* dan difilter. Tampilan rancangan dapat dilihat pada


Gambar 3.7 dan **Gambar 3.8** ,Fitur utama mencakup:

- a. Filter Merek: Fitur ini berupa tombol interaktif yang memungkinkan pengguna memilih fokus analisis pada merek tertentu, yaitu “Semua”, “Gojek”, atau “Grab”, sehingga hasil visualisasi dapat menyesuaikan dengan merek yang dipilih.
- b. Filter Dimensi Analisis: Fitur ini memungkinkan pengguna menentukan dimensi utama analisis, yaitu apakah visualisasi akan berfokus pada distribusi “Topic” atau “Intention”. Selain itu, pengguna juga dapat menambahkan filter tambahan untuk melakukan penyaringan sekunder berdasarkan dimensi lain.

- c. Area Visualisasi Dinamis: Bagian ini menampilkan hasil analisis yang diperbarui secara otomatis berdasarkan filter yang aktif. Visualisasi mencakup grafik distribusi berbentuk *bar chart*, grafik proporsi berbentuk *pie chart*, serta *word cloud* yang memperlihatkan kata-kata yang paling sering muncul dari teks ulasan yang relevan




Gambar 3. 7 Rancangan Tampilan Modul Dashboard 1



Gambar 3. 8 Rancangan Tampilan Modul Dashboard 2

4. Modul About (Tentang Aplikasi) : Modul ini berisi informasi latar belakang mengenai aplikasi dan fungsionalitas pendukung, yang disajikan dalam struktur tab untuk menjaga kerapian antarmuka. Berikut adalah penjelasan beserta tampilan rancangan untuk setiap tab yang ada.

- a. Tab Informasi Pengerjaan: Berisi informasi singkat mengenai latar belakang dan tujuan perancangan aplikasi, identitas pembuat (nama dan NIM) serta dosen pembimbing, dan konteks akademis pengerjaan skripsi . Tampilan dapat dilihat pada **Gambar 3.9**.




Gambar 3. 9 Rancangan Modul About (Tab Informasi)


- b. Tab Evaluasi Model: Tab ini menyajikan transparansi mengenai performa model klasifikasi Topik dan Intensi yang digunakan . Fitur di dalamnya meliputi:

- i. *Filter Skenario: Dropdown* untuk memilih Model, Tipe Eksperimen, dan Split Data.
- ii. *Metrik Performa*: Menampilkan *Train Accuracy* dan *Test Accuracy*.
- iii. *Classification Report*: Tabel detail metrik (Precision, Recall, F1-Score) per kelas dengan opsi unduh .
- iv. *Confusion Matrix*: Visualisasi *heatmap* interaktif dengan opsi normalisasi .
- v. *Analisis Kesalahan*: Menampilkan 3 besar kesalahan klasifikasi model.


Tampilannya dapat dilihat pada **Gambar 3.10** , **Gambar 3.11** ,dan **Gambar 3.12** yang mencakup seluruh fitur di Tab Evaluasi Model.



Gambar 3. 10 Rancangan Tampilan Modul About (Tab Evaluasi Model) 1




Gambar 3. 11 Rancangan Tampilan Modul About (Tab Evaluasi Model) 2



Gambar 3. 12 Rancangan Tampilan Modul About (Tab Evaluasi Model) 3


- c. Tab Buku Manual: Menyediakan tautan fungsional untuk mengunduh buku manual aplikasi dalam format PDF. Tampilan Dapat dilihat pada **Gambar 3.13.**



Gambar 3. 13 Rancangan Tampilan Modul About (Tab Buku Manual)

3.1.6 Rancangan Arsitektur Sistem

Arsitektur sistem dirancang untuk menjelaskan bagaimana data mengalir dan diproses di dalam aplikasi *dashboard* saat sedang digunakan oleh pengguna. Diagram arsitektur pada **Gambar 3.14** memvisualisasikan alur kerja internal aplikasi, mulai dari *input* hingga *output*.



Gambar 3. 14 Rancangan Arsitektur Sistem

Proses diawali ketika pengguna mengunggah sebuah *file* data ulasan (.csv atau .xlsx). Data tersebut kemudian diterima oleh aplikasi dan langsung diarahkan ke modul *Preprocessing*, di mana serangkaian proses pembersihan, normalisasi, dan tokenisasi dijalankan. Setelah data teks menjadi bersih dan terstruktur, data tersebut diubah menjadi representasi vektor numerik menggunakan TF-IDF.

Vektor fitur ini kemudian menjadi masukan bagi modul inti, yaitu Model Klasifikasi *Stacking Ensemble*. Di dalam modul ini, prediksi dari dua *base-model* (*XGBoost* dan *LightGBM*) digabungkan dan diproses lebih lanjut oleh *meta-model* (*Logistic Regression*) untuk menghasilkan label klasifikasi akhir. Hasil klasifikasi yang berupa prediksi Topik dan Intensi untuk setiap ulasan kemudian dikirim ke modul Visualisasi untuk ditampilkan kepada pengguna melalui antarmuka *dashboard* interaktif.

3.2 Pembuatan Sistem

Tahap selanjutnya adalah merealisasikan rancangan tersebut ke dalam sebuah prototipe aplikasi yang fungsional. Bagian ini menguraikan secara teknis proses implementasi atau pembuatan sistem, mulai dari penyiapan lingkungan pengembangan hingga menjadi sebuah aplikasi yang dapat diuji. Pembahasan akan mencakup spesifikasi perangkat keras dan perangkat lunak yang digunakan, serta pembuatan rancangan tersebut.

3.2.1 Perangkat Keras (Hardware)

Perangkat keras yang digunakan dalam proses perancangan dan pengujian sistem ini adalah sebagai berikut. Spesifikasi ini merupakan konfigurasi dari perangkat yang digunakan untuk pengembangan, bukan merupakan syarat spesifikasi minimum untuk menjalankan aplikasi.

1. Prosesor (*Processor*): Intel® Core™ i5-12450HX.
2. Unit Pemrosesan Grafis (GPU): NVIDIA GeForce RTX 3050 (6 GB VRAM).
3. Memori (RAM): 20 GB.
4. Penyimpanan (*Storage*): 512 GB *Solid State Drive* (SSD).

3.2.2 Perangkat Lunak (Software)

Perancangan sistem ini bergantung pada ekosistem perangkat lunak yang saling mendukung, mulai dari sistem operasi hingga *library* spesifik untuk pemrosesan bahasa alami dan visualisasi data. Kebutuhan perangkat lunak yang diidentifikasi untuk proyek ini adalah:

1. Sistem Operasi: Windows 11. Sistem operasi ini menyediakan lingkungan yang stabil untuk instalasi dan konfigurasi semua perangkat lunak pengembangan yang diperlukan.
2. Bahasa Pemrograman: Python versi 3.12.8. Python dipilih karena merupakan bahasa standar industri untuk ilmu data dan *machine learning*, serta didukung oleh ekosistem *library* yang sangat kaya dan komunitas yang besar.

3. Lingkungan Pengembangan (*IDE*): Visual Studio Code. Digunakan sebagai editor kode utama untuk menulis, mengelola, dan melakukan *debugging* skrip Python untuk aplikasi Streamlit. Kemudian Google Colab untuk proses *modelling* untuk tugas klasifikasi.
4. Library Utama:
 - a. Streamlit: *Framework* utama yang digunakan untuk membangun dan menjalankan antarmuka pengguna (*user interface*) dari aplikasi *dashboard* interaktif.
 - b. *Streamlit Antd Components* (SAC) : *Library* tambahan untuk Streamlit yang digunakan dalam pembuatan komponen antarmuka kustom, seperti menu navigasi di sidebar (*sac.menu*) dan filter merek berbentuk chip (*sac.chip*).
 - c. Pandas: Digunakan untuk memuat, memanipulasi, dan membersihkan data ulasan dari file *.csv*. *Library* ini menjadi tulang punggung dalam tahap persiapan data.
 - d. NumPy : Berfungsi untuk melakukan operasi numerik, terutama dalam pembuatan dan pengelolaan *array Confusion Matrix* di halaman *Evaluation*, serta untuk penerapan fungsi *np.select* pada filter merek.
 - e. NLTK (*Natural Language Toolkit*): Digunakan untuk melakukan operasi dasar NLP seperti tokenizing (memecah teks menjadi kata) dan stopword removal (menghilangkan kata-kata umum).

- f. Sastrawi: Library khusus untuk Bahasa Indonesia yang digunakan untuk melakukan proses stemming, yaitu mengubah kata berimbuhan menjadi kata dasarnya.
- g. Scikit-learn: Digunakan untuk beberapa fungsi krusial, termasuk implementasi vektorisasi TF-IDF, pembagian *dataset* (data latih dan uji), implementasi model *Logistic Regression* sebagai meta-model, dan perhitungan metrik evaluasi.
- h. *XGBoost*: Library yang menyediakan implementasi dari model *Extreme Gradient Boosting* yang akan digunakan sebagai salah satu base-model dalam arsitektur *Stacking Ensemble*.
- i. *LightGBM*: Library yang menyediakan implementasi dari model *Light Gradient Boosting Machine*, yang juga akan digunakan sebagai *base-model*.
- j. Plotly : Library visualisasi data utama yang digunakan untuk membuat grafik interaktif di dashboard, seperti grafik batang (*px.bar*), diagram lingkaran (*px.pie*), dan *heatmap Confusion Matrix* (*go.Heatmap*).
- k. WordCloud dan Matplotlib : WordCloud digunakan untuk menghasilkan visualisasi berbentuk *word cloud* dari kumpulan kata. Sedangkan Matplotlib digunakan (melalui *st.pyplot*) untuk menampilkan hasil visualisasi tersebut di dalam aplikasi Streamlit.

- I. Pickle : Library standar Python yang digunakan untuk proses serialisasi (penyimpanan) dan deserialisasi (pemanggilan kembali) model seperti TfidfVectorizer dan StackingClassifier ke dalam atau dari file .pkl.

3.2.3 Pengumpulan Data

Data merupakan komponen paling fundamental dalam perancangan sistem ini, karena kualitas dan karakteristik data akan menentukan performa akhir dari model klasifikasi. Proses persiapan data yang dilakukan adalah sebagai berikut:

1. Sumber Data : *Dataset* yang digunakan adalah ulasan konsumen mengenai layanan Gojek dan Grab, yang diperoleh dari platform Twitter menggunakan *tool scrapping* bernama Tweet Harvest. *Dataset* yang digunakan diambil dari *tab Latest* per tanggal 30 Juni 2025. Total data mentah yang berhasil di scrap adalah 25.945 ulasan untuk *keyword* yang digunakan untuk Gojek dan 23.167 ulasan untuk *keyword* yang digunakan untuk Grab. Dari total tersebut, dilakukan pemilahan data dan pelabelan manual secara cermat hingga memenuhi kuota masing-masing 6.000 data (12.000 data dikarenakan terdapat 2 model yaitu model untuk klasifikasi topik dan model untuk klasifikasi intensi) yang persebarannya merata untuk melatih model . Berikut adalah keseluruhan *keyword* yang digunakan untuk tiap brand, dapat dilihat pada **Tabel 3.1** .

Tabel 3. 1 Keyword Tweet Harvest

Brand	Keyword yang Digunakan
Gojek	gojek, go-jek, goride, gocar, gofood, gopay, gosend
Grab	grab, @grabld, grabcar, grabfood, ovo, grabexpress, grab express

2. Format Dan Struktur Data : Data mentah disimpan dan diolah dalam format *.csv (Comma-Separated Values)*. Dari proses *scraping*, data tersebut memiliki 15 atribut yang dapat dilihat pada **Tabel 3.2** sebagai berikut

Tabel 3. 2 Atribut Hasil Scrapping

No.	Nama Field
1	conversation_id_str
2	created_at
3	favorite_count
4	full_text
5	id_str
6	Image_url
7	in_reply_to_screen_name
8	lang
9	Location
10	quote_count
11	reply_count
12	retweet_count
13	tweet_url
14	user_id_str
15	username

Meskipun banyak atribut yang diperoleh, analisis ini akan berfokus pada kolom *full_text* yang berisi teks ulasan asli dari pengguna. Kolom inilah yang akan menjadi *input* utama untuk proses *preprocessing* dan klasifikasi. Untuk contoh hasil data *scrapping* dapat dilihat pada **Gambar 3.15**.

```

"conversation_id_str","created_at","favorite_count","full_text","id_str","image_url","in_reply_to_screen_name","lang","location","quote_count","reply_count","retw
"1939408171837395162","Mon Jun 30 23:57:43 +0000 2025","0","@anomali_lirali @goclo1 Aku kuliah dirantauan kemanaz jalan kaki 5km+ mana kuliah bukan di kampus pus
"193983557282284984","Mon Jun 30 23:56:55 +0000 2025","0","When lu naik gojek tapi abang gojek nya lebih mungil dari lu https://t.co/m2jXGVHRT","19398355728228
"1939835294062350551","Mon Jun 30 23:55:49 +0000 2025","0","chat should i apply to grab/gojek buat mulangin yuzuha yanagi tribbie sparkle https://t.co/q4c0PeeTm8"
"1938944052470391061","Mon Jun 30 23:54:58 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo [ A : GOCARAJA ] Ayo ikutan temanku @mang_aris12 @wo
"1938944052470391061","Mon Jun 30 23:54:33 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo [ A : GOCARAJA ] #PakeGojekPalinghemat @cumirahma @sxcuvy
"1938944052470391061","Mon Jun 30 23:54:08 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo [ A : GOCARAJA ] #PakeGojekPalinghemat @bya_ria @Kisnanti
"1938944052470391061","Mon Jun 30 23:53:55 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo [ A : GOCARAJA ] #PakeGojekPalinghemat @lenny_chan @devie
"1939831103250996244","Mon Jun 30 23:47:25 +0000 2025","0","Wts ls nct ver 1 350k aja yuk angkur aku gratisin pc Gosend bisa Oyen bisa https://t.co/2HabuNGoas","1
"193983114130389748","Mon Jun 30 23:46:22 +0000 2025","0","@gopayindonesia kapan gopay kerjasama dgn transjakarta ? lbh lengkap layanan nya klo bisa bayar tjt pak
"1939832628143051048","Mon Jun 30 23:46:01 +0000 2025","0","@gojekindonesia kasih tau driver lu terutama yang embil gosend kalau gabisa ya konfirmasi bukan diam d
"1939832708206928111","Mon Jun 30 23:45:32 +0000 2025","0","nah abis dari situ aku naik gocar hapanya asik banget serius ngobrolnya juga nyambung dari ota dan sam
"1939832366748623171","Mon Jun 30 23:44:11 +0000 2025","0","WTS JELLY RODOAL 500 Jelly = 15k (IDR) Availabe : 160k Jelly Kalo take all nanti ku kasih bonus Payma
"1939564257898803563","Mon Jun 30 23:37:15 +0000 2025","0","@ojanchooke @UGM_FESS boong jir boro2, w aja kemana2 kl di Jogja digonceng temen2/gojek atau gak elu k
"1939565868100317478","Mon Jun 30 23:34:43 +0000 2025","3","@tanyakanrl Banyak ka bisa pakai bank jago superbank bla bca cuman klo blu bca klo kakak punya tabunga
"1938944052470391061","Mon Jun 30 23:31:10 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo GOCARAJA ! @yanti_Baladjam @hendrayani7711 #PakeGoje
"1939828907961983165","Mon Jun 30 23:30:26 +0000 2025","0","sekarang susah ya promo dm ml a+ reward gopay semalem farming dua akun cuma dapet 420dm, TAPI TTP LUMA
"1938944052470391061","Mon Jun 30 23:20:56 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo GOCARAJA Ikutan yuk @callmedara31 @javashanafi #Pake
"1938944052470391061","Mon Jun 30 23:16:06 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo [ A : GOCARAJA ] Ayo ikutan temanku @eka_win01 @mita
"1938944052470391061","Mon Jun 30 23:10:17 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo [ A : GOCARAJA ] @ssybilaaa @sarahjuliette_ #PakeGoj
"1939823772829458624","Mon Jun 30 23:10:02 +0000 2025","0","dengan kesadaran penuh belum pesan gocar","1939823772829458624","""","in","""","0","0","0","https://x.c
"1938944052470391061","Mon Jun 30 23:09:39 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo ( A : GOCARAJA ) @tauly_lidia @tampu_nunung #PakeGoj
"1939823411137819095","Mon Jun 30 23:08:36 +0000 2025","0","@myxl min ini saya dari kmrn mau beli kuota xtra combo plus 132 GB dengan gopay tidak bisa muli selalu
"1938944052470391061","Mon Jun 30 23:08:25 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo ( A : GOCARAJA ) @er_maulia @farzanaareza #PakeGojekP
"1938944052470391061","Mon Jun 30 23:07:11 +0000 2025","0","@gojekindonesia OTM pake GoCar masukin kode promo [ A : GOCARAJA ] #PakeGojekPalinghemat Yuk ikutan @a

```

Gambar 3. 15 *Dataset* Hasil Tweet Harvest

3. Label Data dan Validasi Anotasi : untuk proses pelatihan model, *dataset* telah dianotasi secara manual untuk menghasilkan dua kolom label target:

- Label Topik: Kategori layanan yang dibicarakan (yaitu Gojek, GoCar, GoPay, GoSend, GoFood, Grab, GrabCar, OVO, GrabExpress, GrabFood).
- Label Intensi: Maksud atau sentimen dari ulasan (yaitu Keluhan, Pujian, Pertanyaan, Pernyataan, Saran-kritik).

Pemilihan kategori topik di atas didasarkan pada karakteristik Gojek dan Grab sebagai *Super App* yang bersaing secara langsung (*head-to-head*) di berbagai sektor layanan vertikal. Oleh karena itu, skema pelabelan topik dirancang untuk memetakan persaingan antar kedua ekosistem tersebut secara komprehensif. Pemetaan ini mencakup perbandingan antara entitas induk merek (Gojek dan Grab), layanan transportasi roda empat (GoCar dan GrabCar), serta layanan pesan-antar makanan (GoFood dan GrabFood). Selain itu, analisis juga mencakup persaingan pada layanan logistik pengiriman barang antara GoSend dan GrabExpress, serta sektor keuangan digital yang

membandingkan GoPay (dompet digital ekosistem Gojek) dengan OVO (mitra pembayaran utama ekosistem Grab).

Perlu ditegaskan bahwa kata kunci (*keywords*) yang tercantum pada **Tabel 3.1** hanya berfungsi sebagai parameter awal untuk penarikan data (*harvesting*). Penentuan Label Topik pada proses anotasi tidak bergantung pada *keyword* yang digunakan untuk menarik data tersebut, melainkan didasarkan sepenuhnya pada konteks layanan yang dibahas dalam isi teks ulasan. Sebagai contoh, sebuah *tweet* yang ditarik menggunakan *keyword* umum "Gojek" dapat diberikan label topik "GoFood" jika konteks kalimatnya secara spesifik membahas layanan pesan-antar makanan, bukan aplikasi secara umum.

Guna memastikan objektivitas dan kualitas dari proses pelabelan, telah diterapkan sebuah prosedur validasi reliabilitas antar-penilai (*inter-rater reliability*). Proses ini diawali dengan pengambilan sampel acak sebanyak 300 ulasan (5% dari total *dataset*). Sampel ini kemudian akan dilabeli ulang secara independen oleh dua validator tambahan dengan latar belakang berbeda, satu validator dari Fakultas Teknologi Informasi (FTI) untuk memahami konteks teknis, dan satu validator dari bidang Psikologi atau HR untuk memberikan perspektif mengenai nuansa intensi pengguna.

Hasil anotasi dari para validator akan dibandingkan dengan hasil anotasi peneliti utama. Tingkat kesepakatan untuk setiap pasangan penilai (Peneliti vs. Validator 1, Peneliti vs. Validator 2) diukur secara kuantitatif menggunakan

statistik Cohen's Kappa. Sebuah set label dianggap reliabel karena mencapai skor Kappa rata-rata yang memadai (di atas 0.60, yang menunjukkan kesepakatan kuat). Jika terjadi ketidaksepakatan pada label tertentu, diskusi dilakukan untuk mencapai konsensus. Prosedur ini menjamin bahwa data latih yang digunakan memiliki *ground truth* yang valid dan konsisten. Untuk contoh hasil *labelling dataset* dapat dilihat pada **Tabel 3.3** berikut.

Tabel 3. 3 *Dataset* Hasil Pelabelan Manual

full_text	topic	type
Driver grabcar nya nerima orderan tp ga gerak 15 menit. di chat cuma di read. woi niat kerja ga si?	grabcar	komplain
min @grabid kalo mau ganti nomer hp yg kedaftar di akun grab gmn caranya ya?	grab	pertanyaan
yaampun abang gofood lama amat	gofood	komplain
terima kasih bapak grabcar yang udah mau ambil orderanku pas hujan (setelah 2x ditolak)	grabcar	pujian
@alfamarl Grab paling nyaman dan murah sih menurutku	grab	pujian

Setelah proses anotasi manual terhadap 6.000 ulasan selesai dilakukan, distribusi data untuk setiap kategori dianalisis untuk memahami karakteristik *dataset*. Penyajian distribusi data ini penting untuk mengidentifikasi potensi adanya kelas yang tidak seimbang (*imbalanced class*), yang dapat memengaruhi cara model dievaluasi. Distribusi data berdasarkan Topik Layanan dan Intensi Pengguna disajikan pada **Tabel 3.4** dan **Tabel 3.5** berikut.

Tabel 3. 4 Distribusi Label Topik dalam *Dataset*

Topik Layanan	Jumlah Ulasan	Persentase (%)
Gojek	600	10%
Grab	600	10%
Gosend	600	10%
GrabExpress	600	10%
GoFood	600	10%
GrabFood	600	10%
GoCar	600	10%
GrabCar	600	10%
GoPay	600	10%
OVO	600	10%
Total	6000	100%

Tabel 3. 5 Distribusi Label Intensi dalam *Dataset*

Intensi Pengguna	Jumlah Ulasan	Persentase (%)
Keluhan	1500	25.00%
Pernyataan	1500	25.00%
Pertanyaan	1000	16.67%
Saran-Kritik	1000	16.67%
Pujian	1000	16.67%
Total	6.000	100.00%

3.2.4 Pembuatan Program

Tahap ini adalah realisasi teknis dari semua analisis dan perancangan yang telah diuraikan sebelumnya. Proses pembuatan program dibagi menjadi tiga komponen utama yaitu pelatihan model klasifikasi, implementasi *dashboard* (antarmuka pengguna), dan integrasi kedua komponen tersebut.

Pelatihan model dilakukan terpisah untuk tugas klasifikasi Topik dan Intensi menggunakan lingkungan *notebook* (Google Colab). *Dataset* (6.000 ulasan per

tugas) dimuat, lalu teks ulasan dibersihkan melalui *preprocessing* (*case folding*, *cleansing*, *tokenizing*, *normalizing*, *stopword removal*, dan *stemming*). Teks bersih ini diubah menjadi fitur numerik menggunakan TF-IDF. Data kemudian dibagi menjadi data latih dan uji (rasio 70:30 untuk Topik, 80:20 untuk Intensi). Model *Stacking Ensemble*, yang menggabungkan *base model* XGBoost dan LightGBM dengan *meta model Logistic Regression*, dilatih dalam beberapa skenario, termasuk menggunakan parameter *default* dan parameter hasil *hyperparameter tuning*. Setelah evaluasi performa, model dengan akurasi tertinggi dipilih yaitu model hasil *tuning* (split 70/30) untuk Topik dan model hasil *tuning* (split 80/20) untuk Intensi. Empat *file* model dan *vectorizer* terpilih ini disimpan dalam format .pkl untuk digunakan aplikasi.

Implementasi *dashboard* dilakukan menggunakan *framework* Streamlit. Antarmuka pengguna dirancang dalam *file* app.py, dengan navigasi *sidebar* untuk mengakses halaman-halaman utama (*Prediction*, *Dataset*, *Dashboard*, dan *About*). Halaman-halaman ini berisi komponen interaktif seperti *dropdown* dan tombol untuk filter data, serta area untuk mengunggah *file*. Hasil analisis dan data disajikan melalui berbagai visualisasi, termasuk tabel, grafik batang, diagram lingkaran, dan *word cloud*, yang dibuat menggunakan *library* visualisasi data Python.

Terakhir, integrasi sistem menghubungkan *dashboard* dengan model-model terpilih. Saat aplikasi dijalankan, keempat *file* .pkl (Vectorizer dan Model

terbaik untuk Topik dan Intensi) dimuat ke memori aplikasi menggunakan mekanisme *caching* Streamlit agar efisien. Integrasi ini memungkinkan fitur seperti halaman *Prediction* untuk memanggil model yang sudah dimuat guna melakukan klasifikasi pada data baru yang diberikan pengguna.

Integrasi sistem adalah proses akhir yang menghubungkan *dashboard* Streamlit dengan model-model yang telah disimpan. Dari berbagai model yang dilatih, model dengan performa terbaik untuk klasifikasi topik dan intensi (berserta *file vectorizer* TF-IDF) akan dipilih untuk implementasi. Saat aplikasi Streamlit dijalankan (*app.py*), aplikasi akan terlebih dahulu memuat keempat *file .pkl* yang mewakili model-model terpilih tersebut ke dalam memori. Ketika pengguna mengunggah *file .csv* baru pada halaman *Prediction*, aplikasi akan memicu alur kerja internal yaitu data dari *file* dibaca, teksnya diproses oleh fungsi *preprocessing*, lalu diubah menjadi vektor oleh *vectorizer* topik dan diklasifikasikan oleh model topik. Proses ini diulangi menggunakan *vectorizer* intensi dan model intensi. Hasil prediksi topik dan intensi kemudian dikirim kembali ke antarmuka *dashboard* untuk ditampilkan kepada pengguna.

BAB IV PENGUJIAN

4.1 Cara Pengujian

Pengujian program aplikasi *dashboard* ini dilaksanakan menggunakan dua metode utama yaitu Pengujian Validitas Pelabelan Data dan Pengujian Fungsionalitas Aplikasi (*Black Box Testing*).

1. Pengujian Validitas Pelabelan Data: Dilakukan untuk mengukur tingkat konsistensi dan kesepakatan antar *annotator* (pemberi label) dalam menentukan kategori topik dan intensi pada sampel data. Metode statistik yang digunakan adalah Cohen's Kappa Coefficient. Pengujian ini penting untuk memastikan bahwa data latih yang digunakan untuk model *machine learning* memiliki kualitas label yang baik.
2. Black Box Testing: Diterapkan untuk memastikan bahwa seluruh fungsi dalam aplikasi *dashboard* beroperasi sesuai dengan yang diharapkan dari sudut pandang pengguna. Metode ini fokus pada *input* dan *output* aplikasi tanpa melihat struktur kode internal, serta untuk mendeteksi adanya kesalahan atau *bug* fungsional.
3. Pengujian Performa Model (Evaluasi Kuantitatif): Dilakukan untuk mengukur kinerja dan efektivitas model *Stacking Ensemble* yang telah dilatih. Pengujian ini fokus pada kemampuan model dalam mengklasifikasikan data uji (*test set*) yang belum pernah dilihat

sebelumnya. Metrik yang digunakan untuk mengukur performa adalah *Accuracy, Precision, Recall, F1-Score*, dan *Confusion Matrix*.

Dengan pendekatan ini, dapat dipastikan bahwa aplikasi tidak hanya berfungsi dengan benar tetapi juga didasarkan pada data pelabelan yang valid dan konsisten.

4.1.1 Pengujian Validitas Pelabelan Data (Cohen's Kappa)

Validitas pelabelan data merupakan aspek krusial dalam pengembangan model klasifikasi teks. Untuk memastikan konsistensi pelabelan intensi pada *dataset*, dilakukan pengujian *inter-annotator agreement* menggunakan Cohen's Kappa. Cohen's Kappa mengukur tingkat kesepakatan antara dua *annotator* (penilai) dengan memperhitungkan kemungkinan kesepakatan yang terjadi secara kebetulan.

Pengujian ini melibatkan tiga *annotator* (Peneliti sebagai Validator 1, Validator 2, dan Validator 3) yang melabeli sampel data sebanyak 300 ulasan. Kedua validator tambahan yang digunakan memiliki latar belakang berbeda, satu validator dari Fakultas Teknologi Informasi (FTI) untuk memahami konteks teknis, dan satu validator dari bidang Psikologi atau HR untuk memberikan perspektif mengenai nuansa intensi pengguna. Perhitungan Cohen's Kappa dilakukan antar pasangan *annotator*. Interpretasi umum nilai Kappa adalah <0 (Buruk), 0.0-0.2 (Sangat Tipis), 0.21-0.4 (Tipis), 0.41-0.6 (Cukup), 0.61-0.8 (Baik), dan 0.81-1.0 (Sangat Baik).

4.1.2 Pengujian Black Box Testing

Black Box Testing adalah metode pengujian *software* di mana mekanisme internal dari aplikasi tidak diketahui oleh penguji. Fokusnya adalah pada hubungan *input* (aksi pengguna) dan *output* (hasil yang ditampilkan aplikasi) untuk memvalidasi fungsionalitas terhadap persyaratan yang telah ditentukan. Pendekatan ini memungkinkan penilaian perangkat lunak tanpa perlu memahami struktur kode internalnya. Pengujian dilakukan dengan cara menjalankan serangkaian kasus uji yang mencakup semua fitur utama aplikasi. Setiap kasus uji mencatat aksi yang dilakukan, hasil yang diharapkan, dan kesimpulan apakah pengujian valid (berhasil) atau tidak.

4.1.3 Pengujian Performa Model

Pengujian performa model dilakukan setelah tahap pelatihan. Pengujian ini bertujuan untuk mengevaluasi seberapa baik model *Stacking Ensemble* dapat melakukan generalisasi terhadap data baru. Proses pengujian dilakukan dengan memberikan *dataset* uji (*test set*) yang berisi data yang tidak pernah dilihat oleh model selama pelatihan ke model yang sudah dilatih. Hasil prediksi dari model kemudian dibandingkan dengan label aktual (*ground truth*) dari *test set* tersebut.

Perbandingan ini diukur secara kuantitatif menggunakan metrik-metrik evaluasi, yaitu:

1. *Accuracy*: Untuk melihat persentase prediksi benar secara keseluruhan.

2. *Precision, Recall*, dan *F1-Score (Macro & Weighted Avg)*: Untuk menganalisis performa model di setiap kelas.
3. *Confusion Matrix*: Untuk memvisualisasikan secara rinci di mana model paling sering melakukan kesalahan klasifikasi antar kelas.

Pengujian ini dilakukan untuk setiap skenario eksperimen (berdasarkan *split data* dan penggunaan *hyperparameter tuning*) untuk menemukan model terbaik.

4.2 Hasil Pengujian

4.2.1 Hasil Validitas Pelabelan Data (Cohen's Kappa)

Pada pengujian validitas pelabelan data (Cohen's Kappa) , Hasil perhitungan Cohen's Kappa antar validator adalah sebagai berikut:

1. Validator 1 vs. Validator 2: $k = 0.9507$
2. Validator 1 vs. Validator 3: $k = 0.9373$
3. Validator 2 vs. Validator 3: $k = 0.9149$

Semua nilai Kappa yang diperoleh berada di atas 0.93, yang termasuk dalam kategori Sangat Baik (*almost perfect agreement*). Hal ini menunjukkan tingkat kesepakatan yang sangat tinggi dan konsisten antar ketiga *annotator* dalam melabeli data intensi, sehingga data pelabelan dianggap valid dan reliabel untuk digunakan dalam pelatihan model.

4.2.2 Hasil Pengujian Blackbox Testing

Hasil pengujian Black Box Testing untuk aplikasi dashboard ini dirangkum pada **Tabel 4.1**.

Tabel 4. 1 Hasil Blackbox Testing

No.	Halaman	Yang akan diuji	Hasil yang diharapkan	Kesimpulan
Umum & Navigasi				
1.1	umum	Memuat aplikasi dan memeriksa tampilan awal sidebar	Aplikasi terbuka di halaman " <i>Prediction</i> ". Sidebar tampil dengan judul, tombol unggah, pilihan menu, dan status model.	Valid
1.2	umum	Klik setiap menu navigasi di sidebar	Konten halaman utama berubah sesuai menu yang diklik. Menu aktif ditandai.	Valid
1.3	<i>Sidebar</i>	Navigasi antar menu	Memilih setiap item pada menu navigasi akan menampilkan halaman konten yang sesuai.	Valid
1.4	<i>Sidebar</i>	Mengunggah file XLSX/XLS valid (kolom: <i>full_text</i> , <i>topic</i> , <i>type</i>)	Pesan sukses " <i>File</i> berhasil dimuat" muncul. Halaman <i>Dataset</i> menampilkan data.	Valid
1.5	<i>Sidebar</i>	Mencoba mengunggah file tipe tidak valid (misal: .txt, .jpg)	<i>File</i> ditolak oleh <i>uploader</i> atau muncul pesan <i>error</i> tipe <i>file</i> .	Valid
1.6	<i>Sidebar</i>	Mengunggah file CSV/Excel tanpa kolom <i>topic/type</i>	<i>File</i> dimuat. Halaman <i>Dataset & Dashboard</i> menampilkan peringatan/status non-aktif pada filter terkait kolom yang hilang.	Valid

Tabel 4.1 (Lanjutan)

No.	Halaman	Yang akan diuji	Hasil yang diharapkan	Kesimpulan
Umum & Navigasi				
1.7	<i>Sidebar</i>	Memeriksa Status Model (asumsi model .pkl ada & valid)	Menampilkan pesan "Model Siap." dengan ikon.	Valid
1.8	<i>Sidebar</i>	Mensimulasikan model gagal dimuat (misal: <i>rename</i> file .pkl)	Menampilkan pesan <i>error file</i> /model tidak ditemukan. Menampilkan status Model Gagal Dimuat. Halaman Prediksi <i>error</i> .	Valid
1.9	Umum	<i>Scroll</i> halaman ke bawah	<i>Footer</i> selalu terlihat menempel di bawah layar.	Valid
Menu: <i>Prediction</i>				
2.1	<i>Prediction</i>	Akses halaman " <i>Prediction</i> " (halaman <i>default</i>)	Menampilkan judul, <i>expander</i> panduan alur kerja (terbuka), "Prediksi Teks Tunggal", dan "Prediksi <i>Batch</i> ".	Valid
2.2	<i>Prediction</i>	Menutup <i>expander</i> panduan alur kerja	<i>Expander</i> tertutup dan menyembunyikan teks panduan.	Valid
2.3	<i>Prediction</i>	Masukkan teks valid, klik "Prediksi Tunggal"	Menampilkan hasil prediksi <i>Topic & Intention</i> + keyakinan. <i>Expander</i> detail probabilitas menampilkan grafik.	Valid
2.4	<i>Prediction</i>	Klik "Prediksi Tunggal" tanpa teks	Menampilkan pesan peringatan	Valid

Tabel 4.1 (lanjutan)

No.	Halaman	Yang akan diuji	Hasil yang diharapkan	Kesimpulan
Menu: <i>Prediction</i>				
2.5	<i>Prediction</i>	Unggah <i>file</i> CSV/Excel valid (hanya <i>full_text</i>) untuk Prediksi Batch	Menampilkan tinjauan data mentah & pesan sukses dan Tombol "Mulai Prediksi <i>Batch</i> " aktif.	Valid
2.6	<i>Prediction</i>	Unggah <i>file</i> tanpa <i>full_text</i> untuk Prediksi Batch	Menampilkan tinjauan data & pesan <i>error</i> "Kolom <i>full_text</i> tidak ditemukan".	Valid
2.7	<i>Prediction</i>	Klik "Mulai Prediksi <i>Batch</i> " setelah unggah <i>file</i> valid	Menampilkan spinner. Setelah selesai, menampilkan tabel hasil prediksi, grafik ringkasan (<i>pie charts</i>), dan tombol unduh.	Valid
2.8	<i>Prediction</i>	Klik "Unduh Hasil Prediksi Lengkap (.csv)"	<i>File</i> CSV hasil prediksi terunduh dengan nama yang benar dan isi sesuai tabel hasil.	Valid
Menu: <i>Dataset</i>				
3.1	<i>Dataset</i>	Akses halaman tanpa unggah <i>file</i>	Menampilkan judul dan pesan informasi awal mengarahkan ke menu " <i>Prediction</i> " atau unggah di <i>sidebar</i> .	Valid
3.2	<i>Dataset</i>	Akses halaman setelah unggah <i>file</i> valid di <i>sidebar</i>	Menampilkan pesan sukses, filter, statistik ringkas, dan tabel tinjauan data (20 baris awal).	Valid
3.3	<i>Dataset</i>	Menerapkan filter (Merek, <i>Topic</i> , <i>Intention</i>)	Memilih opsi pada salah satu atau kombinasi filter akan memperbarui jumlah baris data, statistik ringkas, dan pratinjau tabel.	Valid

Tabel 4.1 (lanjutan)

No.	Halaman	Yang akan diuji	Hasil yang diharapkan	Kesimpulan
Menu: Dataset				
3.4	<i>Dataset</i>	Mengaktifkan/me nonaktifkan opsi "Tampilkan Semua"	Saat aktif, seluruh baris data hasil filter ditampilkan. Saat non-aktif, hanya 20 baris pertama.	Valid
3.5	<i>Dataset</i>	Klik <i>expander</i> "Tampilkan Info Dataset Asli"	Menampilkan informasi kolom (nama, tipe, <i>null</i>) dan memori dari data sebelum difilter.	Valid
Menu: Dashboard				
4.1	Dashboard	Akses halaman tanpa unggah file	Menampilkan judul dan pesan info "silahkan unggah file", mengarahkan ke alur kerja.	Valid
4.2	Dashboard	Akses halaman setelah unggah <i>file</i> valid di <i>sidebar</i>	Menampilkan filter <i>chip</i> Merek, filter Dimensi, grafik Bar, <i>Pie</i> , dan Word Cloud.	Valid
4.3	<i>Dashboard</i>	Memilih Merek spesifik (misal: Gojek) pada filter <i>chip</i>	Semua visualisasi (<i>Bar</i> , <i>Pie</i> , Word Cloud) dan opsi filter tambahan pada Dimensi Analisis diperbarui untuk data merek yang dipilih.	Valid
4.4	<i>Dashboard</i>	Mengubah Dimensi Utama Analisis (misal: dari <i>Topic</i> ke <i>Intention</i>)	Grafik <i>Bar</i> dan <i>Pie</i> diperbarui. Opsi filter tambahan otomatis menyesuaikan (menjadi <i>Topic</i> jika utama <i>Intention</i>).	Valid
4.5	<i>Dashboard</i>	Menerapkan Filter Tambahan pada Dimensi Analisis	Memilih opsi spesifik (selain "Semua") akan memperbarui semua visualisasi (<i>Bar</i> , <i>Pie</i> , Word Cloud) sesuai irisan data.	Valid

Tabel 4.1 (Lanjutan)

No.	Halaman	Yang akan diuji	Hasil yang diharapkan	Kesimpulan
Menu: About				
5.1	<i>About</i>	Akses halaman <i>About</i>	Menampilkan judul, deskripsi, tiga tab yaitu Informasi Pengerjaan , Evaluasi Model, dan Buku Manual.	Valid
5.2	<i>About</i>	Klik Tab "Informasi Pengerjaan" (<i>Default</i>)	Menampilkan info pengembang, pembimbing, dan konteks akademis.	Valid
5.3	<i>About</i>	Klik Tab "Evaluasi Model"	Menampilkan halaman evaluasi dengan filter (Model, Tipe, <i>Split</i>) dan hasil (Akurasi, <i>Report</i> , CM)	Valid
5.4	<i>About</i>	(Tab Evaluasi) Ubah semua filter (misal: <i>Intention</i> , <i>Hyperparameter Tuned</i> , 80/20)	Judul, Akurasi, <i>Report</i> , dan CM di dalam tab diperbarui sesuai data evaluasi untuk kombinasi filter yang dipilih.	Valid
5.5	<i>About</i>	(Tab Evaluasi) Klik " <i>Download Report</i> "	File CSV <i>Classification Report</i> terunduh dengan nama & isi sesuai filter aktif.	Valid
5.6	<i>About</i>	(Tab Evaluasi) Aktifkan <i>checkbox</i> "Aktifkan Normalisasi <i>Confusion Matrix</i> "	<i>Confusion Matrix</i> ternormalisasi (nilai 0-1) tampil di dalam <i>expander</i> .	Valid
5.7	<i>About</i>	Klik Tab "Buku Manual"	Menampilkan teks dan tombol " <i>Download Buku Manual</i> ".	Valid
5.8	<i>About</i>	(Tab Buku Manual) Klik tombol " <i>Download Buku Manual</i> "	Memicu <i>download</i> file pdf buku manual .	Valid

Berdasarkan hasil pengujian *Black Box Testing* pada **Tabel 4.1**, dapat disimpulkan bahwa semua fungsi yang diuji pada aplikasi *dashboard* klasifikasi tweet berjalan sesuai dengan yang diharapkan dan tidak ditemukan kesalahan fungsional atau *bug* selama proses pengujian ini.

4.2.3 Hasil Evaluasi Model Klasifikasi

Evaluasi performa model klasifikasi dilakukan pada *test set* untuk setiap skenario eksperimen. Eksperimen yang dilakukan untuk tiap model masing-masing 4 yaitu pembagian data 70/30 dan 80/20 dengan parameter *default* yang dapat dilihat pada **Gambar 4.1** dan dengan parameter hasil *hypertuning*. Metrik evaluasi yang digunakan adalah *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan *Confusion Matrix*. Metrik ini dihitung untuk mengukur kemampuan model dalam mengklasifikasikan ulasan pada data yang belum pernah dilihat sebelumnya.

```

lgbm = LGBMClassifier(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=7,
    num_leaves=31,
    random_state=42,
    verbose=-1
)

xgb = XGBClassifier(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=7,
    random_state=42,
    eval_metric='mlogloss',
    verbosity=0
)

base_models = [
    ('lgbm', lgbm),
    ('xgb', xgb),
]

meta_model = LogisticRegression(
    max_iter=1000,
    random_state=42,
    multi_class='multinomial',
    solver='lbfgs'
)

stacking_clf = StackingClassifier(
    estimators=base_models,
    final_estimator=meta_model,
    cv=5,
    n_jobs=-1,
)

```

Gambar 4. 1 Parameter Default Model


4.2.3.1 Evaluasi Model Klasifikasi Topik

1. Skenario 1: *split 70/30*

Hasil akurasi dari skenario ini adalah akurasi tes sebesar 85.55% dengan *Precision* sebesar 0.86, *Recall* sebesar 0.85, dan *F1-Score* sebesar 0.86. Untuk hasil lebih detail *evaluation metric* bisa lihat **Tabel 4.2** dan untuk hasil *confusion matrix* dapat lihat pada **Gambar 4.2**

Tabel 4. 2 Evaluasi Model Topik 70/30

Kelas	Precision	Recall	F1-Score	Support
gocar	0,91	0,89	0,9	180
gofood	0,92	0,82	0,86	180
gojek	0,79	0,87	0,83	180
gopay	0,98	0,92	0,95	180
gosend	0,96	0,89	0,93	180
grab	0,62	0,78	0,69	180
grabcar	0,91	0,82	0,87	180
grabexpress	0,94	0,91	0,93	180
grabfood	0,78	0,72	0,75	180
ovo	0,82	0,93	0,87	180
accuracy			0,85	1800
macro avg	0,86	0,86	0,86	1800
weighted avg	0,86	0,85	0,86	1800




Gambar 4. 2 Confusion Matrix Topik 70/30

2. Skenario 2 : *split* 80/20

Hasil akurasi dari skenario ini adalah akurasi tes sebesar 85.55% dengan *Precision* sebesar 0.86, *Recall* sebesar 0.85, dan *F1-Score*=0.86 sama dengan 70/30 . Untuk hasil lebih detail *evaluation metric* bisa lihat **Tabel 4.3** dan untuk hasil *confusion matrix* dapat lihat pada **Gambar 4.3**.

Tabel 4. 3 Evaluasi Model Topik 80/20

Kelas	Precision	Recall	F1-Score	Support
gocar	0,9	0,87	0,88	120
gofood	0,92	0,81	0,86	120
gojek	0,8	0,86	0,83	120
gopay	0,98	0,93	0,95	120
gosend	0,97	0,89	0,93	120
grab	0,64	0,8	0,71	120
grabcar	0,89	0,82	0,86	120
grabexpress	0,96	0,92	0,94	120
grabfood	0,74	0,72	0,73	120
ovo	0,84	0,93	0,88	120
accuracy			0,85	1200
macro avg	0,86	0,85	0,86	1200
weighted avg	0,86	0,85	0,86	1200



Gambar 4. 3 Confusion Matrix Topic 80/20

3. Skenario 3: *split 70/30* dengan *hypertuning*

Hasil akurasi dari skenario ini adalah akurasi *test* sebesar 85,594% dengan *Precision* sebesar 0.87, *Recall* sebesar 0.86, dan *F1-Score* sebesar 0.86.

Parameter yang digunakan didapatkan dari *hypertuning* dapat dilihat pada

Gambar 4.4. Untuk hasil lebih detail *evaluation metric* bisa lihat **Tabel 4.4** dan untuk hasil *confusion matrix* dapat lihat pada **Gambar 4.5.**

```
lgbm = LGBMClassifier(
    learning_rate=0.01,
    max_depth=5,
    n_estimators=300,
    random_state=42,
    verbose=-1
)

xgb = XGBClassifier(
    learning_rate=0.5,
    max_depth=3,
    n_estimators=100,
    eval_metric='mlogloss',
    random_state=42,
    verbosity=0
)

base_models = [
    ('lgbm', lgbm),
    ('xgb', xgb),
]

meta_model = LogisticRegression(
    C=1,
    max_iter=500,
    multi_class='multinomial',
    random_state=42
)

stacking_clf = StackingClassifier(
    estimators=base_models,
    final_estimator=meta_model,
    cv=5,
    n_jobs=-1
)
```


Gambar 4. 4 Parameter Hypertuning Model Topik Split 70/30

Tabel 4. 4 Evaluasi Model Topik 70/30 setelah Hypertuning

Kelas	Precision	Recall	F1-Score	Support
gocar	0,93	0,89	0,91	180
gofood	0,95	0,8	0,87	180
gojek	0,81	0,87	0,84	180
gopay	0,96	0,92	0,94	180
gosend	0,95	0,92	0,93	180
grab	0,63	0,81	0,71	180

Tabel 4.4 (lanjutan)

Kelas	Precision	Recall	F1-Score	Support
grabcar	0,92	0,82	0,86	180
grabexpress	0,96	0,9	0,93	180
grabfood	0,77	0,76	0,76	180
ovo	0,82	0,92	0,87	180
accuracy			0,86	1800
macro avg	0,87	0,86	0,86	1800
weighted avg	0,87	0,86	0,86	1800



Gambar 4. 5 Confusion Matrix Topic 70/30 Setelah Hypertuning

4. Skenario 4: *split* 80/20 dengan *hypertuning*

Hasil akurasi dari skenario ini adalah akurasi *test* sebesar 85,583% dengan *Precision* sebesar 0.87, *Recall* sebesar 0.86, dan *F1-Score* sebesar 0.86. Parameter yang digunakan didapatkan dari *hypertuning* dapat dilihat pada

Gambar 4.6. Untuk hasil lebih detail *evaluation metric* bisa lihat **Tabel 4.5** dan untuk hasil *confusion matrix* dapat lihat pada **Gambar 4.7.**

```
lgbm = LGBMClassifier(
    learning_rate=0.01,
    n_estimators=200,
    random_state=42,
    verbose=-1
)

xgb = XGBClassifier(
    learning_rate=0.01,
    max_depth=10,
    n_estimators=300,
    eval_metric='mlogloss',
    random_state=42,
    verbosity=0
)

base_models = [
    ('lgbm', lgbm),
    ('xgb', xgb),
]


meta_model = LogisticRegression(
    C=10,
    max_iter=500,
    multi_class='multinomial',
    random_state=42
)

stacking_clf = StackingClassifier(
    estimators=base_models,
    final_estimator=meta_model,
    cv=5,
    n_jobs=-1
)
```

Gambar 4. 6 Parameter Hypertuning Model Topic Split 80/20

Tabel 4. 5 Evaluasi Model Topik 80/20 setelah Hypertuning

Kelas	Precision	Recall	F1-Score	Support
gocar	0,94	0,87	0,9	120
gofood	0,93	0,82	0,87	120
gojek	0,8	0,86	0,83	120
gopay	0,98	0,93	0,95	120
gosend	0,96	0,9	0,93	120
grab	0,64	0,81	0,71	120
grabcar	0,93	0,82	0,87	120
grabexpress	0,96	0,9	0,93	120
grabfood	0,75	0,74	0,74	120
ovo	0,81	0,94	0,87	120
accuracy			0,86	1200
macro avg	0,87	0,86	0,86	1200
weighted avg	0,87	0,86	0,86	1200



Gambar 4. 7 Confusion Matrix Topic 80/20 Setelah Hypertuning

4.2.3.2 Evaluasi Model Klasifikasi Intensi

1. Skenario 1: split 70/30

Hasil akurasi dari skenario ini adalah akurasi *test* sebesar 70.28% dengan *Precision* sebesar 0.71, *Recall* sebesar 0.70, *F1-Score* sebesar 0.70. Untuk hasil lebih detail *evaluation metric* bisa lihat **Tabel 4.6** dan untuk hasil *confusion matrix* dapat lihat pada **Gambar 4.8**

Tabel 4. 6 Evaluasi Model Intensi 70/30

Kelas	Precision	Recall	F1-Score	Support
komplain	0,73	0,76	0,74	450
pernyataan	0,58	0,71	0.64	450
pertanyaan	0,76	0,68	0,71	300
pujian	0,76	0,69	0,72	300
saran-kritik	0,80	0,64	0,71	300
accuracy			0,70	1800
macro avg	0,73	0,70	0,71	1800
weighted avg	0,71	0,70	0,70	1800



Gambar 4. 8 Confusion Matrix Intensi 70/30

2. Skenario 2 : split 80/20

Hasil akurasi dari skenario ini adalah akurasi *test* sebesar 71.08% dengan Precision sebesar 0.72, Recall sebesar 0.71, F1-Score sebesar 0.71. Untuk hasil lebih detail *evaluation metric* bisa lihat **Tabel 4.7** dan untuk hasil *confusion matrix* dapat lihat pada **Gambar 4.9**.

Tabel 4. 7 Evaluasi Intensi Topik 80/20

Kelas	Precision	Recall	F1-Score	Support
komplain	0,73	0,77	0,75	300
pernyataan	0,61	0,74	0,67	300
pertanyaan	0,76	0,70	0,73	200
pujian	0,78	0,68	0,73	200
saran-kritik	0,77	0,62	0,69	200
accuracy			0,71	1200
macro avg	0,73	0,70	0,71	1200
weighted avg	0,72	0,71	0,71	1200



Gambar 4. 9 Confusion Matrix Intensi 80/20

3. Skenario 3: *split 70/30* dengan *hypertuning*

Hasil akurasi dari skenario ini adalah akurasi *test* sebesar 69.72% dengan *Precision* sebesar 0.71, *Recall* sebesar 0.70, *F1-Score* sebesar 0.70. Parameter yang digunakan didapatkan dari *hypertuning* dapat dilihat pada **Gambar 4.10**. Untuk hasil lebih detail *evaluation metric* bisa lihat **Tabel 4.8** dan untuk hasil *confusion matrix* dapat lihat pada **Gambar 4.11**.

```

lgbm = LGBMClassifier(
    learning_rate=0.05,
    random_state=42,
    verbose=-1
)

xgb = XGBClassifier(
    learning_rate=0.05,
    max_depth=7,
    n_estimators=300,
    eval_metric='mlogloss',
    random_state=42,
    verbosity=0
)

base_models = [
    ('lgbm', lgbm),
    ('xgb', xgb),
]

# --- Meta Model ---
meta_model = LogisticRegression(
    C=10,
    max_iter=500,
    multi_class='multinomial',
    random_state=42
)

# --- Stacking Classifier ---
stacking_clf = StackingClassifier(
    estimators=base_models,
    final_estimator=meta_model,
    cv=5,
    n_jobs=-1
)

```

Gambar 4. 10 Parameter Hypertuning Model Intensi Split 70/30

Tabel 4. 8 Evaluasi Model Intensi 70/30 Setelah Hypertuning

Kelas	Precision	Recall	F1-Score	Support
komplain	0,73	0,75	0,74	450
pernyataan	0,58	0,72	0,64	450
pertanyaan	0,75	0,64	0,69	300
pujian	0,75	0,71	0,73	300
saran-kritik	0,77	0,63	0,69	300
accuracy			0,70	1800
macro avg	0,72	0,69	0,70	1800
weighted avg	0,71	0,70	0,70	1800



Gambar 4. 11 Confusion Matrix Intensi 70/30 Setelah Hypertuning

4. Skenario 4: *split 80/20 dengan hypertuning*

Hasil akurasi dari skenario ini adalah akurasi *test* sebesar 70.75% dengan *Precision* sebesar 0.72, *Recall* sebesar 0.71, *F1-Score* sebesar 0.71. Parameter yang digunakan didapatkan dari *hypertuning* dapat dilihat pada **Gambar 4.12**. Untuk hasil lebih detail *evaluation metric* bisa lihat **Tabel 4.9** dan untuk hasil *confusion matrix* dapat lihat pada **Gambar 4.13**. Ini adalah skenario dengan hasil akurasi terbaik dibandingkan dengan skenario lainnya.

```

# --- Base Models ---
lgbm = LGBMClassifier(
    learning_rate=0.05,
    random_state=42,
    verbose=-1
)

xgb = XGBClassifier(
    learning_rate=0.05,
    max_depth=7,
    n_estimators=300,
    eval_metric='mlogloss',
    random_state=42,
    verbosity=0
)

base_models = [
    ('lgbm', lgbm),
    ('xgb', xgb),
]

# --- Meta Model ---
meta_model = LogisticRegression(
    C=10,
    max_iter=500,
    multi_class='multinomial',
    solver='saga',
    random_state=42
)


# --- Stacking Classifier ---
stacking_clf = StackingClassifier(
    estimators=base_models,
    final_estimator=meta_model,
    cv=5,
    n_jobs=-1
)

```

Gambar 4. 12 Parameter Hypertuning Model Intensi Split 80/20

Tabel 4. 9 Evaluasi Model Topik 80/20 setelah Hypertuning

Kelas	Precision	Recall	F1-Score	Support
komplain	0,74	0,76	0,75	300
pernyataan	0,59	0,75	0,66	300
pertanyaan	0,76	0,69	0,72	200
pujian	0,80	0,70	0,74	200
saran-kritik	0,78	0,60	0,68	200
accuracy			0,71	1200
macro avg	0,73	0,70	0,71	1200
weighted avg	0,72	0,71	0,71	1200




Gambar 4. 13 Confusion Matrix Topic 80/20 Setelah Hypertuning

4.2.4 Hasil Tampilan Dashboard Aplikasi Streamlit

Untuk mengimplementasikan model yang telah dilatih sebelumnya menggunakan *stacking ensemble* dan menyajikan hasil analisis secara interaktif, aplikasi *dashboard* dikembangkan menggunakan *framework* Streamlit. Aplikasi ini dirancang sebagai antarmuka pengguna yang mengintegrasikan fungsionalitas utama untuk prediksi model, analisis data eksploratif, dan presentasi hasil evaluasi.


Aplikasi ini memiliki empat menu navigasi utama yang dapat diakses melalui *sidebar*, yaitu *Prediction*, *Dataset*, *Dashboard*, dan *About*, yang mencerminkan alur kerja yang direkomendasikan. Halaman *Prediction* pada **Gambar 4.14** adalah langkah pertama dan halaman utama aplikasi. Halaman ini adalah inti fungsional yang memanfaatkan model klasifikasi yang telah dilatih untuk memproses data baru. Halaman ini juga menyajikan panduan alur kerja di dalam *expander* untuk pengguna baru. Halaman ini terbagi menjadi dua mode:

1. **Prediksi Teks Tunggal:** Pengguna dapat memasukkan satu kalimat ulasan ke dalam *text area*. Model kemudian akan memprediksi Topik dan Intensi secara *real-time*, menampilkannya dalam kartu metrik yang menyertakan skor keyakinan (probabilitas). Pengguna juga dapat melihat grafik batang probabilitas penuh untuk 5 besar prediksi teratas .
2. **Prediksi *Batch*:** Mode ini dirancang untuk data dalam jumlah besar. Pengguna dapat mengunggah *file* data mentah (.csv/.xlsx) yang hanya memerlukan satu kolom bernama *full_text*. Aplikasi akan memproses seluruh baris dalam *file* tersebut dan menghasilkan *file* .csv baru untuk diunduh, yang berisi data asli ditambah kolom-kolom baru: *topic* (prediksi), *topic_probability* (keyakinan), *type* (prediksi), dan *type_probability* (keyakinan) .



Gambar 4. 14 Tampilan Halaman Prediction


Halaman *Dataset* dapat dilihat pada **Gambar 4.15** berfungsi sebagai modul peninjauan data (langkah kedua). Pengguna diharuskan mengunggah *file* data (.csv atau .xlsx) baik *file* yang sudah ber-label atau *file* hasil dari menu "*Prediction*" melalui *sidebar*. Setelah data dimuat, halaman ini akan menampilkan empat kartu metrik yang merangkum data yang telah difilter: Total Baris, Jumlah Topik Unik, Jumlah Intensi Unik, dan Total Nilai Kosong. Pengguna dapat melakukan filter data secara interaktif berdasarkan Merek (Gojek/Grab), Topik spesifik, dan Intensi (tipe). Halaman ini juga menyediakan penampil *DataFrame* untuk meninjau 20 baris pertama atau keseluruhan data, serta *expander* yang berisi informasi teknis *dataset* asli.



Gambar 4. 15 Tampilan Halaman *Dataset*

Halaman *Dashboard* dapat dilihat pada **Gambar 4.16** merupakan modul visualisasi analitis utama (langkah ketiga) yang beroperasi pada data yang telah diunggah di *sidebar*. Halaman ini memungkinkan pengguna untuk menganalisis distribusi data melalui serangkaian filter. Fitur utamanya adalah filter dimensi


primer (Topik atau Intensi) dan filter dimensi sekunder (satu sama lain, misalnya menganalisis Topik *untuk* Intensi Komplain). Hasil data yang telah difilter kemudian divisualisasikan secara dinamis dalam tiga komponen yaitu Diagram Batang untuk melihat distribusi jumlah, Diagram Lingkaran untuk melihat proporsi persentase, dan *Word Cloud* yang dihasilkan dari kolom *full_text* untuk menganalisis frekuensi kata kunci yang relevan dengan filter.



Gambar 4. 16 Tampilan Halaman Dashboard


Terakhir pada halaman *About* yang dapat dilihat pada **Gambar 4.17**, **Gambar 4.18**, dan **Gambar 4.19**, berfungsi sebagai halaman informasi dan fungsionalitas pendukung yang disajikan dalam struktur tab.

1. Tab Informasi Pengerjaan (Gambar 4.17) menyajikan deskripsi singkat mengenai tujuan aplikasi, konteks pengerjaan Skripsi, serta identitas pengembang (Hans Santoso, 535220129) dan Dosen Pembimbing (Tri Sutrisno, S.Si., M.Sc.).




Gambar 4. 17 Tab Informasi Pengerjaan

2. Tab Evaluasi Model (**Gambar 4.18, 4.19**) berfungsi sebagai tampilan interaktif untuk semua hasil. Halaman ini tidak melakukan pelatihan ulang, melainkan menyajikan data performa yang telah di-*hardcode*. Pengguna dapat menggunakan filter untuk memilih Model (Topik/Intensi), Tipe Eksperimen, dan *Split* Data. Berdasarkan pilihan tersebut, *tab* ini menampilkan Akurasi *Train* dan *Test*, tabel *Classification Report*, visualisasi *Confusion Matrix* interaktif, dan analisis teks kesalahan klasifikasi.




Gambar 4. 18 Tab Evaluasi Model



Gambar 4. 19 Tab Evaluasi Model 2

3. Tab Buku Manual (**Gambar 4.20**) menyediakan tautan fungsional bagi pengguna untuk mengunduh buku manual aplikasi dalam format PDF.



Gambar 4. 20 Tab Buku Manual

4.3 Pembahasan

4.3.1 Pembahasan Model Klasifikasi Topik

Dari Seluruh eksperimen yang dilakukan untuk model klasifikasi topik , hasil Skenario 3 (*Hyperparameter Tuned 70/30*) menghasilkan performa model klasifikasi topik terbaik di antara semua skenario yang diuji, dengan *Test Accuracy* mencapai 85.94% dan *Weighted F1-Score* 0.86. Analisis dari *Classification Report* pada **Tabel 4.4** menunjukkan bahwa model ini memiliki performa sangat tinggi untuk kelas-kelas layanan yang spesifik, seperti gopay ($F1=0.94$), gosend ($F1=0.93$), dan grabexpress ($F1=0.93$).

Dapat dilihat juga bahwa performa model paling lemah terlihat pada kelas grab ($F1=0.71$). *Confusion Matrix* pada **Tabel 4.7** menjelaskan kelemahan ini secara rinci: model mengalami kesulitan signifikan dalam membedakan antara *brand* umum grab dan layanan spesifik di bawahnya. Terdapat 28 kasus di mana grabfood (aktual) salah diklasifikasikan sebagai grab, dan 21 kasus grabcar (aktual) juga salah diklasifikasikan sebagai grab. Selain itu, matriks juga menunjukkan adanya kebingungan antar-layanan sejenis, seperti 18 kasus gofood yang salah diprediksi sebagai grabfood, dan 8 kasus grabcar yang salah diprediksi sebagai gocar. Untuk rangkuman keseluruhan hasil evaluasi model klasifikasi Topik dapat dilihat pada **Tabel 4.10** di bawah.

Tabel 4. 10 Rangkuman Hasil Evaluasi Model Klasifikasi Topik

Skenario Eksperimen	<i>Split Data</i>	<i>Test Accuracy</i>	<i>Weighted Precision</i>	<i>Weighted Recall</i>	<i>Weighted F1-Score</i>
<i>Parameter Default</i>	70/30	85.50%	0.86	0.85	0.86
<i>Parameter Default</i>	80/20	85.50%	0.86	0.85	0.86
<i>Hyperparameter Tuned</i>	70/30	85.94%	0.87	0.86	0.86
<i>Hyperparameter Tuned</i>	80/20	85.83%	0.87	0.86	0.86

Maka model klasifikasi topik pada skenario terbaik mengungkap beberapa pola yang jelas:

1. Performa Tinggi pada Kelas Spesifik: Model menunjukkan akurasi yang sangat tinggi untuk kelas-kelas layanan dengan terminologi yang unik dan jelas, seperti gopay ($F1=0.94$), gosend ($F1=0.93$), dan grabexpress ($F1=0.93$). Ini mengindikasikan model berhasil menangkap kata kunci spesifik yang membedakan layanan-layanan tersebut.
2. Kelemahan pada Kelas Umum (Brand): Performa model paling lemah terlihat pada kelas grab ($F1=0.71$). *Confusion matrix* menjelaskan bahwa model mengalami kesulitan signifikan dalam membedakan antara *brand* umum (grab) dan layanan spesifik di bawahnya (grabfood, grabcar). Terdapat 28 kasus grabfood (aktual) dan 21 kasus grabcar (aktual) yang salah diklasifikasikan sebagai grab.

3. Kebingungan Antar Pesaing: Teramati pula adanya misklasifikasi yang logis antar layanan pesaing yang sejenis. Contohnya, 18 kasus gofood salah diprediksi sebagai grabfood, dan 8 kasus grabcar salah diprediksi sebagai gocar.

4.3.2 Pembahasan Model Klasifikasi Intensi

Berbeda signifikan dengan model topik, performa model klasifikasi intensi berada pada level baik namun moderat. Dari keempat skenario yang diuji, skenario Parameter *Default (Split 80/20)* sebenarnya mencapai *Test Accuracy* tertinggi yaitu 71.08%. Namun, skenario ini juga menunjukkan selisih yang cukup besar antara akurasi latih (91.85%) dan akurasi uji, mengindikasikan potensi *overfitting* yang lebih tinggi.

Oleh karena itu, skenario *Hyperparameter Tuned (Split 80/20)* dipilih sebagai model terbaik meskipun *Test Accuracy*-nya sedikit lebih rendah (70.75%). Pemilihan ini didasarkan pada kemampuan generalisasi yang lebih baik, terlihat dari selisih yang lebih kecil antara akurasi latih (88.29%) dan akurasi uji, yang menunjukkan model ini tidak terlalu *overfit* terhadap data latih.

Classification Report untuk model terbaik ini menunjukkan bahwa model relatif lebih berhasil mengidentifikasi kelas komplain ($F1=0.75$), pujian ($F1=0.74$), dan pertanyaan ($F1=0.72$). Sebaliknya, performa terlemah ada pada kelas pernyataan ($F1=0.66$) dan saran-kritik ($F1=0.68$).

Confusion matrix menunjukkan bahwa misklasifikasi paling sering terjadi ketika pertanyaan (aktual) salah diklasifikasikan sebagai pernyataan (46 kali) dan komplain (aktual) salah diklasifikasikan sebagai pernyataan (43 kali). Selain itu, pernyataan (aktual) juga cukup sering salah diklasifikasikan sebagai komplain (30 kali) atau saran-kritik (25 kali). Hal ini menunjukkan bahwa batasan semantik antara menanyakan sesuatu (pertanyaan), membuat pernyataan netral (pernyataan), menyampaikan keluhan (komplain), dan memberi masukan (saran-kritik) sering kali bingung dalam konteks ulasan singkat di media sosial, sehingga model kesulitan menemukan pola pembeda yang konsisten.

Tabel 4. 11 Rangkuman Hasil Evaluasi Model Klasifikasi Intensi

Skenario Eksperimen	<i>Split Data</i>	<i>Test Accuracy</i>	<i>Weighted Precision</i>	<i>Weighted Recall</i>	<i>Weighted F1-Score</i>
<i>Parameter Default</i>	70/30	70.28%	0.71	0.70	0.70
<i>Parameter Default</i>	80/20	71.08%	0.72	0.71	0.71
<i>Hyperparameter Tuned</i>	70/30	69.72%	0.71	0.70	0.70
<i>Hyperparameter Tuned</i>	80/20	70.75%	0.72	0.71	0.71

Maka ringkasan dari hasil pembahasan model klasifikasi intensi pada skenario terbaik mengungkap beberapa pola yang jelas:

1. Kemampuan Membedakan Intensi yang Relatif Jelas: Model menunjukkan performa yang cukup baik dalam mengidentifikasi intensi seperti komplain ($F1=0.75$), pujian ($F1=0.74$), dan pertanyaan ($F1=0.72$). Kelas-kelas ini

cenderung memiliki pola bahasa atau kata kunci yang lebih spesifik sehingga lebih mudah dikenali oleh model.

2. Tumpang Tindih Kelas Ambigu: Performa terlemah terlihat pada kelas pernyataan ($F1=0.66$) dan saran-kritik ($F1=0.68$). Tantangan utama model terkonfirmasi oleh *confusion matrix*, yang menunjukkan adanya tumpang tindih (*overlap*) signifikan, terutama pada kelas pernyataan yang sering tertukar dengan kelas lainnya.
3. Analisis Misklasifikasi: Terdapat 60 data pertanyaan (aktual) yang salah diklasifikasikan sebagai pernyataan. Selain itu, 58 data komplain (aktual) juga salah diklasifikasikan sebagai pernyataan. Hal ini menunjukkan bahwa batasan semantik antara menanyakan sesuatu (pertanyaan), membuat pernyataan netral (pernyataan), dan menyampaikan keluhan (komplain) sangat kabur dalam data, sehingga model kesulitan menemukan pola yang jelas untuk membedakannya.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat ditarik tiga kesimpulan utama yaitu:

1. Model *Stacking Ensemble* (*XGBoost* dan *LightGBM*) telah berhasil dirancang, dilatih, dan dievaluasi untuk dua tugas klasifikasi. Untuk model Topik, skenario terbaik adalah *Hyperparameter Tuned (split 70/30)* yang mencapai *Test Accuracy* 85.94%. Untuk model Intensi, skenario terbaik yang dipilih adalah *Hyperparameter Tuned (split 80/20)* yang mencapai *Test Accuracy* 70.75%. Model Intensi ini dipilih karena memiliki kemampuan generalisasi yang lebih baik (selisih akurasi *train-test* lebih kecil) dibandingkan skenario *default*.
2. Sebuah prototipe aplikasi *dashboard* telah berhasil diimplementasikan menggunakan *framework* Streamlit. Aplikasi ini berhasil menerapkan alur kerja pengguna yang logis dan baik, serta mengintegrasikan fungsionalitas untuk prediksi (tunggal dan *batch*), peninjauan data (*Dataset*), dan visualisasi interaktif (*Dashboard*).
3. Pengujian fungsional dan evaluasi performa telah berhasil dilakukan. Pengujian *Black Box Testing* yang mencakup skenario uji dari aplikasi menunjukkan bahwa semua fitur aplikasi dapat berjalan sesuai rancangan. Selain itu, seluruh hasil evaluasi metrik model (Akurasi, *Classification Report*,

Confusion Matrix) berhasil disajikan secara transparan di dalam Tab Evaluasi Model pada halaman *About*

5.2 Saran

Berdasarkan temuan selama penelitian, khususnya pada keterbatasan model dan lingkup aplikasi, berikut adalah beberapa saran untuk pengembangan di masa depan yang bersifat fundamental dan di luar cakupan penelitian ini:

1. Implementasi Model *Deep Learning* Berbasis *Transformer* untuk Mengatasi Ambiguitas: Sebagaimana telah diuraikan pada pembahasan evaluasi model, arsitektur saat ini (TF-IDF + *Stacking Ensemble*) terbukti memiliki keterbatasan dalam membedakan kelas intesi yang ambigu (seperti antara 'Pernyataan' dan 'Pertanyaan' informal) serta gagal menangkap nuansa sarkasme. Hal ini terjadi karena pendekatan *Bag-of-Words* pada TF-IDF tidak merekam urutan dan konteks kata. Oleh karena itu, penelitian selanjutnya sangat disarankan untuk beralih menggunakan arsitektur *Deep Learning* berbasis Transformer, seperti IndoBERT atau BERT Multilingual. Model ini memiliki mekanisme *self-attention* yang mampu memahami konteks semantik kalimat secara utuh, sehingga diharapkan dapat meminimalisir kesalahan klasifikasi pada teks yang memiliki makna implisit
2. Implementasi Arsitektur *Streaming Data Real-Time*: Aplikasi ini masih bersifat prototipe yang bergantung pada unggahan *file .csv* secara manual. Untuk implementasi industri yang sesungguhnya, disarankan merancang ulang

arsitektur sistem menggunakan arsitektur *streaming data*. Ini melibatkan integrasi langsung dengan API Twitter, penggunaan *message broker* untuk mengelola antrian ulasan yang masuk, dan *deploy* model sebagai *microservice* untuk melakukan inferensi secara *real-time*.

3. Pengembangan *Pipeline* MLOps (*Machine Learning Operations*): Model yang digunakan saat ini bersifat statis (dilatih sekali) dan bahasa di media sosial (slang, topik baru) berkembang sangat cepat. Disarankan untuk pengembangan selanjutnya menerapkan *pipeline* MLOps penuh. Ini mencakup penerapan *Model Monitoring* (sistem otomatis untuk mendeteksi *data drift* dan *model drift* seiring waktu) serta *Continuous Training* (CT) (membangun mekanisme untuk melakukan pelatihan ulang model secara periodik) untuk memastikan relevansi dan akurasi model tetap terjaga.

DAFTAR PUSTAKA

- [1] K. Yan, D. Arisandi, and T. Tony, "Analisis Sentimen Komentar Netizen Twitter Terhadap Kesehatan Mental Masyarakat Indonesia," *J. Ilmu Komput. dan Sist. Inf.*, vol. 10, no. 1, 2022, doi: 10.24912/jiksi.v10i1.17865.
- [2] M. A. Rosari, W. Wasino, and T. Tony, "Analisis Sentimen Tanggapan Masyarakat Terhadap bantuan Sosial pemerintah Di Masa Pandemi Covid-19 Pada Platform Twitter," *J. Ilmu Komput. dan Sist. Inf.*, vol. 10, no. 1, pp. 1–9, 2022, doi: 10.24912/jiksi.v10i1.17867.
- [3] S. Mandasari, B. H. Hayadi, and R. Gunawan, "Analisis Sentimen Pengguna Transportasi Online Terhadap Layanan Grab Indonesia Menggunakan Multinomial Naive Bayes Classifier," *J-SISKO TECH (Jurnal Teknol. Sist. Inf. dan Sist. Komput. TGD)*, vol. 5, no. 2, p. 118, 2022, doi: 10.53513/jsk.v5i2.5635.
- [4] R. Paluvi and M. I. P. Nasution, "Pemrosesan Dan Analisis Big Data: Peluang Dan Tantangan Dalam Dunia Industri," *J. Sains Student Res.*, vol. 3, no. 3, pp. 341–350, 2025, [Online]. Available: <https://doi.org/10.61722/jssr.v3i3.4744>
- [5] R. Mursyid and A. D. Indriyanti, "Perbandingan Akurasi Metode Analisis Sentimen Untuk Evaluasi Opini Pengguna Pada Platform Media Sosial (Studi Kasus: Twitter)," *J. Informatics Comput. Sci.*, vol. 6, no. 02, pp. 371–383, 2024, doi: 10.26740/jinacs.v6n02.p371-383.

- [6] A. Rahmatulloh, R. N. Shofa, I. Darmawan, and Ardiansah, "Sentiment Analysis of Ojek Online User Satisfaction Based on the Naïve Bayes and Net Brand Reputation Method," *2021 9th Int. Conf. Inf. Commun. Technol. ICoICT 2021*, pp. 337–341, 2021, doi: 10.1109/ICoICT52021.2021.9527466.
- [7] K. Nisa, "Klasifikasi Penyakit Gangguan Mental dengan Algoritma LightGBM," *J. Ris. Sist. Inf. Dan Tek. Inform.*, vol. 9, no. 2, pp. 1086–1094, 2024, [Online]. Available: <https://tunasbangsa.ac.id/ejurnal/index.php/jurasik>
- [8] Felix Fernando, "Klasifikasi Tweet Cyberbullying Dengan Menggunakan Algoritma Svm Dan Xgboost," *J. Ilmu Komput. dan Sist. Inf.*, vol. 13, no. 1, 2025, doi: 10.24912/jiksi.v13i1.32857.
- [9] M. Massaoudi, S. S. Refaat, I. Chihi, M. Trabelsi, F. S. Oueslati, and H. Abu-Rub, "A novel stacked generalization ensemble-based hybrid LGBM-XGB-MLP model for Short-Term Load Forecasting," *Energy*, vol. 214, no. March 2022, 2021, doi: 10.1016/j.energy.2020.118874.
- [10] Y. Rombe, "Penggunaan Metode Xgboost Untuk Klasifikasi Status Obesitas Di Indonesia," *Pharmacogn. Mag.*, vol. 75, no. 17, pp. 399–405, 2021.
- [11] G. Airlangga, "Enhancing Medical Diagnostics with Ensemble Machine Learning: A Comparative Study of Gradient Boosting, XGBoost, LightGBM, and Blended Models," *J. Ris. Sist. Inf. Dan Tek. Inform.*, vol. 9, no. 2, pp. 1117–1132, 2024, [Online]. Available:

<https://tunasbangsa.ac.id/ejurnal/index.php/jurasik>

- [12] Y. Wicaksono, A. Akbar Harahap, and T. Rochmadi, "Implementasi Business Intelligence untuk Visualisasi Data Pengembangan Kompetensi Aparatur Sipil Negara Di Kabupaten Lebak," *J. Teknol. dan Ilmu Komput.*, vol. 1, no. 2, pp. 49–58, 2025, doi: 10.35134/Jutekom.v9i2.1.
- [13] A. Putri, A. A. Adhisti, and I. R. Putri, "Pengembangan Dashboard Interaktif Saham LQ45 Menggunakan Pendekatan Business Intelligence Berbasis Tableau," vol. 12, no. 02, 2025.
- [14] F. Rustam, M. Khalid, W. Aslam, V. Rupapara, A. Mehmood, and G. S. Choi, "A performance comparison of supervised machine learning models for Covid-19 tweets sentiment analysis," *PLoS One*, vol. 16, no. 2, pp. 1–23, 2021, doi: 10.1371/journal.pone.0245909.
- [15] Y. Yati, M. Ainol Yaqin, and A. Yusrotun Nadhiroh, "Application of The Support Vector Machine Algorithm for Timely Student Graduation Prediction Based on Streamlit Web at The Faculty of Informatics Engineering Nurul Jadid University," *J. Comput. Networks, Archit. High Perform. Comput.*, vol. 6, no. 3, pp. 1066–1070, 2024, doi: 10.47709/cnahpc.v6i3.3918.
- [16] Ž. Vujović, "Classification Model Evaluation Metrics," *Int. J. Adv. Comput. Sci. Appl.*, vol. 12, no. 6, pp. 599–606, 2021, doi: 10.14569/IJACSA.2021.0120670.

- [17] Muhammad Jibril, Zulrahmadi, and 3Muhammad Amin, "Pengujian Sistem Informasi E-Modul Pada Smpn 1 Tempuling Menggunakan Black Box Testing," *J. Perangkat Lunak*, vol. 6, no. 2, pp. 327–332, 2024, doi: 10.32520/jupel.v6i2.3326.
- [18] S. Khalid, R. Sharma, D. Science, and C. C. Wisdom, "Building Explainable AI Dashboards for Compliance Auditors Publication Date : Dec , 2024 Regulatory Imperatives for Explainability," 2024.
- [19] Y. Khoiruddin, A. Fauzi, and A. M. Siregar, "Analisis Sentimen Gojek Indonesia Pada Twitter Menggunakan Algoritme Naïve Bayes Dan Support Vector Machine," *Progresif J. Ilm. Komput.*, vol. 19, no. 1, p. 391, 2023, doi: 10.35889/progresif.v19i1.1173.
- [20] M. Iqrom, M. Afdal, Rice Novita, Medyantiwi Rahmawita, and Tengku Khairil Ahsyar, "Sentiment Analysis of Gojek, Grab, Maxim Applications Using Support Vector Machine Algorithm," *INOVTEK Polbeng - Seri Inform.*, vol. 10, no. 1, pp. 237–248, 2025, doi: 10.35314/52fycr56.
- [21] V. KP, R. AB, G. HL, V. Ravi, and M. Krichen, "A tweet sentiment classification approach using an ensemble classifier," *Int. J. Cogn. Comput. Eng.*, vol. 5, no. May, pp. 170–177, 2024, doi: 10.1016/j.ijcce.2024.04.001.
- [22] D. Devalio, A. Anisya, A. Syahrani, I. Warman, and B. Busran, "Perancangan Website Untuk Prediksi Jumlah Pengeluaran Mahasiswa Berbasis Framework Streamlit," *J. Inform. dan Tek. Elektro Terap.*, vol. 13, no. 2,

2025, doi: 10.23960/jitet.v13i2.6451.

- [23] A. Massahiro *et al.*, “The evolution of CRISP-DM for Data Science : Methods , Processes and Frameworks,” 2024, doi: 10.5753/reviews.2024.3757.
- [24] D. Rogers, A. Preece, M. Innes, and I. Spasić, “Real-Time Text Classification of User-Generated Content on Social Media: Systematic Review,” *IEEE Trans. Comput. Soc. Syst.*, vol. 9, no. 4, pp. 1154–1166, 2022, doi: 10.1109/TCSS.2021.3120138.
- [25] V. G. Shintarani, R. Mayasari., “Analisis Sentimen Ulasan Konsumen Pada Produk Ponsel Pintar Menggunakan Metode Naïve Bayes,” ... *Mandalika ISSN 2721*, pp. 771–781, 2023, [Online]. Available: <https://ojs.cahayamandalika.com/index.php/JCM/article/view/2101%0Ahttps://ojs.cahayamandalika.com/index.php/JCM/article/download/2101/1662>
- [26] I. Gunawan and R. Nurrachmi, “Analisis Faktor-Faktor Yang Memengaruhi Intensi Investor Untuk Berinvestasi Kembali Pada Platform Securities Crowdfunding Syariah,” vol. 3, no. 2, pp. 352–390, 2024.
- [27] M. A. Muslim and Y. Dasril, “Company bankruptcy prediction framework based on the most influential features using XGBoost and stacking ensemble learning,” *Int. J. Electr. Comput. Eng.*, vol. 11, no. 6, pp. 5549–5557, 2021, doi: 10.11591/ijece.v11i6.pp5549-5557.

- [28] M. Mohammed, H. Mwambi, I. B. Mboya, M. K. Elbashir, and B. Omolo, "A stacking ensemble deep learning approach to cancer type classification based on TCGA data," *Sci. Rep.*, vol. 11, no. 1, pp. 1–22, 2021, doi: 10.1038/s41598-021-95128-x.
- [29] U. A. Wizza and A. Rahmi, "Classification Of KIP-K Scholarship Using *Logistic Regression*, Classification Trees, and Boosting Based On Decision Support System," *Mathline J. Mat. dan Pendidik. Mat.*, vol. 10, no. 1, pp. 221–235, 2025, doi: 10.31943/mathline.v10i1.837.
- [30] A. Painsky and G. Wornell, "On the Universality of the Logistic Loss Function," *IEEE Int. Symp. Inf. Theory - Proc.*, vol. 2018-June, no. 0, pp. 936–940, 2018, doi: 10.1109/ISIT.2018.8437786.
- [31] Z. Zhang, Y. Zhang, Y. Wen, and Y. Ren, "Data-driven XGBoost model for maximum stress prediction of additive manufactured lattice structures," *Complex Intell. Syst.*, vol. 9, no. 5, pp. 5881–5892, 2023, doi: 10.1007/s40747-023-01061-z.
- [32] A. Desiani, D. A. Zayanti, I. Ramayanti, F. F. Ramadhan, and G. Giovillando, "Perbandingan Algoritma Support Vector Machine (Svm) Dan Comparison of Support Vector Machine (Svm) and Logistic," *J. Kecerdasan Buatan dan Teknol. Inf. Vol.*, vol. 4, no. 1, pp. 33–42, 2025.
- [33] J. A. Nurcahyo and T. B. Sasongko, "Hyperparameter Tuning Algoritma Supervised Learning untuk Klasifikasi Keluarga Penerima Bantuan Pangan

- Beras,” vol. 12, no. 1, pp. 1351–1365, 2023.
- [34] A. H. Nababan and M. Y. Hutagalung, “Hyperparameter Tuning Pada Model Stance Detection Menggunakan GridSearchCV,” vol. 5, no. 1, pp. 205–209, 2023.
- [35] X. Yang, *Lecture Notes in Networks and Systems 216 Proceedings of Sixth International Congress on Information and Communication Technology*, vol. 464. 2022.
- [36] K. Du *et al.*, “Inter-rater reliability in labeling quality and pathological features of retinal OCT scans: A customized annotation software approach,” *PLoS One*, vol. 19, no. 12, pp. 1–15, 2024, doi: 10.1371/journal.pone.0314707.
- [37] D. Ayuhan and W. Bunawan, “Performance Profile of Students in High School Physics Practicum on Temperature and Heat Material,” *Holist. Sci.*, vol. 4, no. 2, pp. 283–287, 2024, doi: 10.56495/hs.v4i2.641.
- [38] H. Hendra and R. P. Kristianto, “Pengujian Aplikasi Game Puzzle Indonesia Berbasis Android Dengan Teknik Black-Box Testing,” *Infotech J. Technol. Inf.*, vol. 10, no. 1, pp. 1–10, 2024, doi: 10.37365/jti.v10i1.224.
- [39] D. Prasetyo, “RANCANG BANGUN SISTEM INFORMASI MANAJEMEN PERSEDIAAN BARANG MENGGUNAKAN METODE SYSTEM DEVELOPMENT LIFE CYCLE (SDLC) DI SMA NEGERI 1 SoE,” *J. Digit*, vol. 14, no. 2, p. 100, 2024,

doi: 10.51920/jd.v14i2.400.

LAMPIRAN I

PREPROCESSING DAN PERHITUNGAN MANUAL TF-IDF

Lampiran ini bertujuan untuk mengilustrasikan alur kerja pengolahan data secara lengkap, mulai dari teks ulasan mentah, melalui berbagai tahapan *preprocessing*, hingga diubah menjadi representasi vektor numerik menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF). Seluruh proses menggunakan satu *dataset dummy* yang konsisten.

1. Dataset Awal

Berikut contoh perhitungan ini menggunakan 5 data ulasan mentah yang mengandung kata tidak baku dan singkatan, relevan dengan konteks klasifikasi "Keluhan".

Tabel L1.1 *Dataset Tweet Dummy*

ID	Teks Ulasan Awal
1	"Makanan cpt sampai, tp mahal"
2	"Ongkir murah, driver ramah"
3	"Pesanan salah, kecewa bgt"
4	"Apk lancar, pengiriman cpt"
5	"Biaya ongkir mahal, kualitas krg"

Dataset tersebut akan melalui *preprocessing* sederhana dengan dilakukan *case folding* dan penghapusan tanda baca. Jumlah kata juga akan di hitung untuk digunakan pada perhitungan TF-IDF. Untuk Hasil dapat dilihat pada **Tabel L1.2.**

2. Tahap Preprocessing

Setiap ulasan akan melalui serangkaian tahapan *preprocessing*. Sebagai contoh, berikut adalah proses yang terjadi pada ulasan D1: "Makanan cpt sampai, tp mahal".

- a. Case Folding: Semua huruf diubah menjadi huruf kecil.

"makanan cpt sampai, tp mahal"

- b. Cleansing: Tanda baca dan karakter yang tidak relevan dihilangkan.

"makanan cpt sampai tp mahal"

- c. Normalization: Kata tidak baku diubah ke bentuk standar menggunakan kamus normalisasi. {"cpt": "cepat", "tp": "tapi", "bgt": "banget", "apk":

"aplikasi", "krng": "kurang"}

"makanan cepat sampai tapi mahal"

- d. Tokenizing: Teks dipecah menjadi token (kata-kata individual).

["makanan", "cepat", "sampai", "tapi", "mahal"]

- e. Stopword Removal: Kata-kata umum yang tidak memiliki makna signifikan (misal: "tapi", "sampai") dihilangkan.

["makanan", "cepat", "mahal"]

- f. Stemming: Kata-kata berimbuhan diubah menjadi kata dasar.

["makan", "cepat", "mahal"]

Tabel L1.2 *Dataset setelah Preprocessing (Tokenized)*

ID	Teks Ulasan Awal	Jumlah Kata
1	["makan", "cepat", "mahal"]	3
2	["ongkir", "murah", "ramah"]	3
3	["pesan", "salah", "kecewa"]	3
4	["aplikasi", "lancar", "kirim", "cepat"]	4
5	["biaya", "ongkir", "mahal", "kualitas", "kurang"]	5

3. Perhitungan *Term Frequency* (TF)

$$TF(t, d) = \frac{f_{t,d}}{n_d} \quad (\text{merujuk pada Persamaan 2.1 di Bab II})$$

a. ID1 (n_d (total kata) = 3)

i. $TF(\text{"makan"}, \text{ID1}) = \frac{1}{3} = 0.333$

ii. $TF(\text{"cepat"}, \text{ID1}) = \frac{1}{3} = 0.333$

iii. $TF(\text{"mahal"}, \text{ID1}) = \frac{1}{3} = 0.333$

b. ID2 (n_d (total kata) = 3)

i. $TF(\text{"ongkir"}, \text{ID2}) = \frac{1}{3} = 0.333$

ii. $TF(\text{"murah"}, \text{ID2}) = \frac{1}{3} = 0.333$

iii. $TF(\text{"ramah"}, \text{ID2}) = \frac{1}{3} = 0.333$

c. ID3 (n_d (total kata) = 3)

i. $TF(\text{"aplikasi"}, \text{ID3}) = \frac{1}{3} = 0.333$

ii. $TF(\text{"lancar"}, \text{ID3}) = \frac{1}{3} = 0.333$

$$\text{iii. } TF(\text{"mantap"}, ID3) = \frac{1}{3} = 0.333$$

d. ID4 (n_d (total kata) = 4)

$$\text{i. } TF(\text{"aplikasi"}, ID4) = \frac{1}{4} = 0.25$$

$$\text{ii. } TF(\text{"lancar"}, ID4) = \frac{1}{4} = 0.25$$

$$\text{iii. } TF(\text{"kirim"}, ID4) = \frac{1}{4} = 0.25$$

$$\text{iv. } TF(\text{"cepat"}, ID4) = \frac{1}{4} = 0.25$$

e. ID5 (n_d (total kata) = 5)

$$\text{i. } TF(\text{"biaya"}, ID5) = \frac{1}{5} = 0.2$$

$$\text{ii. } TF(\text{"ongkir"}, ID5) = \frac{1}{5} = 0.2$$

$$\text{iii. } TF(\text{"mahal"}, ID5) = \frac{1}{5} = 0.2$$

$$\text{iv. } TF(\text{"kualitas"}, ID5) = \frac{1}{5} = 0.2$$

$$\text{v. } TF(\text{"kurang"}, ID5) = \frac{1}{5} = 0.2$$

4. Perhitungan *Inverse Document Frequency* (IDF)

$$IDF(t) = \log\left(\frac{N}{df_t}\right) \text{ (merujuk pada Persamaan 2.2 di Bab II)}$$

a. cepat (muncul di D1, D4)

$$df_{cepat} = 2, IDF(cepat) = \log\left(\frac{5}{2}\right) = 0.916$$

b. mahal (muncul di D1, D5)

$$df_{mahal} = 1, IDF(mahal) = \log\left(\frac{5}{1}\right) = 0.916$$

c. kecewa (muncul di D3)

$$df_{kecewa} = 1, IDF(kecewa) = \log\left(\frac{5}{1}\right) = 1.609$$

Untuk hasil perhitungan IDF bisa dilihat pada **Tabel L1.3** di bawah.

Tabel L1. 3 Hasil Perhitungan IDF

Text	IDF
aplikasi	1.609
biaya	1.609
cepat	0.916
kecewa	1.609
kirim	1.609
kualitas	1.609
kurang	1.609
lancar	1.609
makan	1.609
mahal	0.916
murah	1.609
ongkir	0.916
pesan	1.609
ramah	1.609
salah	1.609

5. Perhitungan TF-IDF

$$TF - IDF(t, d) = TF(t, d) \times IDF(t) = \frac{f_{t,d}}{n_d} \times \log\left(\frac{N}{df_t}\right) \text{ (merujuk pada}$$

Persamaan 2.1 di Bab II)

$$a. TF - IDF(cepat, D1) = 0.333 \times 0.916$$

$$TF - IDF(cepat, D1) = 0.305$$

$$b. TF - IDF(lancar, D4) = 0.25 \times 1.609$$

$$TF - IDF(lancar, D4) = 0.402$$

$$c. TF - IDF(mahal, D5) = 0.2 \times 0.916$$

$$TF - IDF(mahal, D5) = 0.183$$

Untuk hasil perhitungan TF-IDF dapat dilihat pada **Tabel L1.4**

Tabel L1.4 Hasil Perhitungan TF-IDF

Text	ID 1	ID 2	ID 3	ID 4	ID 5
aplikasi	0	0	0	0.402	0
biaya	0	0	0	0	0.322
cepat	0.305	0	0	0.229	0
kecewa	0	0	0.536	0	0
kirim	0	0	0	0.402	0
kualitas	0	0	0	0	0.322
kurang	0	0	0	0	0.322
lancar	0	0	0	0.402	0
makan	0.536	0	0	0	0
mahal	0.305	0	0	0	0.183
murah	0	0.536	0	0	0
ongkir	0	0.305	0	0	0.183
pesan	0	0	0.536	0	0
ramah	0	0.536	0	0	0
salah	0	0	0.536	0	0

LAMPIRAN II

PERHITUNGAN XGBOOST

Proses kerja algoritma XGBoost diilustrasikan menggunakan *dataset* dummy dari Lampiran I yang dapat dilihat pada **Tabel L2.1**. Pada sistem sebenarnya, input model adalah keseluruhan matriks TF-IDF yang telah dihitung sebelumnya, di mana setiap kata menjadi sebuah fitur, namun untuk memudahkan perhitungan manual, ilustrasi ini tidak menggunakan semua 15 fitur kata, perhitungan ini akan fokus pada satu fitur yang paling representatif dari hasil TF-IDF tersebut, yaitu skor TF-IDF untuk kata "mahal". Kata ini dipilih karena kuat menunjukkan kelas *Keluhan*.

Tabel L2. 1 *Dataset* XGBoost

ID	Tweet Ulasan	Label (Keluhan)
1	"Makanan cepat sampai, tapi mahal"	1
2	"Ongkir murah, driver ramah"	0
3	"Pesanan salah, kecewa banget"	1
4	"Aplikasi lancar, pengiriman cepat"	0
5	"Biaya ongkir mahal, kualitas kurang"	1

Fitur "mahal" disederhanakan menjadi biner, bernilai 1 jika kata muncul dalam ulasan ($TF-IDF > 0$), dan 0 jika tidak ada. Hasil transformasi ditunjukkan pada **Tabel L2.2**, di mana fitur biner ini menjadi input XGBoost untuk menghitung gradien, hessian, dan bobot pohon.

Tabel L2. 2 *Dataset* Biner XGBoost

ID	Tweet Ulasan	Mengandung kata "mahal" (x)	Label (y)
1	"Makanan cepat sampai, tapi mahal"	1	1
2	"Ongkir murah, driver ramah"	0	0
3	"Pesanan salah, kecewa banget"	0	1
4	"Aplikasi lancar, pengiriman cepat"	0	0
5	"Biaya ongkir mahal, kualitas kurang"	1	1

Transformasi teks menjadi numerik diperlukan karena XGBoost hanya dapat memproses fitur numerik. Fitur ini akan menjadi input x untuk menghitung gradien, hessian, dan bobot pohon.

1. *Base Score* (Inisialisasi Prediksi Awal)

Prediksi awal sebelum ada pohon:

$$\hat{y}_i^{(0)} = \text{base score} = \text{rata rata label}$$

$$\hat{y}_i^{(0)} = \frac{1 + 0 + 1 + 0 + 1}{5}$$

$$\hat{y}_i^{(0)} = 0.6$$

semua data diprediksi awal = 0.6, sebagai *starting point* XGBoost.

2. *Tree 1* (Iterasi Pertama)

a. Hitung Gradien dan Hessian (Pseudo-Residual)

$$g_i = \hat{y}_i^{(0)} - y_i, \quad h_i = \hat{y}_i^{(0)}(1 - \hat{y}_i^{(0)}) \text{ (sesuai dengan Persamaan 2.8}$$

dan 2.9 di Bab II)

$$\text{i. ID 1: } y_1 = 1, \hat{y}_1^{(0)} = 0.6$$

$$g_1 = 0.6 - 1 = -0.4, \quad h_1 = 0.6 \times (1 - 0.6) = 0.24$$

ii. ID 2: $y_2 = 0, \hat{y}_2^{(0)} = 0.6$

$$g_2 = 0.6 - 0 = 0.6, h_2 = 0.6 \times (1 - 0.6) = 0.24$$

iii. ID 3: $y_3 = 1, \hat{y}_3^{(0)} = 0.6$

$$g_3 = 0.6 - 1 = -0.4, h_3 = 0.6 \times (1 - 0.6) = 0.24$$

iv. ID 4: $y_4 = 0, \hat{y}_4^{(0)} = 0.6$

$$g_4 = 0.6 - 0 = 0.6, h_4 = 0.6 \times (1 - 0.6) = 0.24$$

v. ID 5: $y_5 = 1, \hat{y}_5^{(0)} = 0.6$

$$g_5 = 0.6 - 1 = -0.4, h_5 = 0.6 \times (1 - 0.6) = 0.24$$

b. Split berdasarkan Fitur (mahal)

Leaf kiri ($x=0$): ID 2,3,4

i. $\sum g_i = g_2 + g_3 + g_4 = 0.6 + (-0.4) + 0.6 = 0.8$

ii. $\sum h_i = h_2 + h_3 + h_4 = 0.24 + 0.24 + 0.24 = 0.72$

Leaf kanan ($x=1$): ID 1,5

i. $\sum g_i = g_1 + g_5 = -0.4 + (-0.4) = -0.8$

ii. $\sum h_i = h_1 + h_5 = 0.24 + 0.24 = 0.48$

c. Hitung Bobot Daun

$$w_j = -\frac{\sum g_i}{\sum h_i + \lambda}, \lambda = 1$$

i. Leaf Kiri: $w_L = -\frac{0.8}{0.72+1} = -0.465$

ii. Leaf Kanan: $w_R = -\frac{-0.8}{0.48+1} = 0.541$

d. Regularisasi :

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \text{ (merujuk pada Persamaan 2.10 di Bab II)}$$

$$\Omega(f) = 0 + 0.5((-0.465)^2 + 0.541^2)$$

$$\Omega(f) = 0.2545$$

e. Update Prediksi

$$\hat{y}_i^{(1)} = \hat{y}_i^{(0)} + \eta \cdot w_j, \eta = 0.5 \text{ (Persamaan 2.12 di Bab II)}$$

i. ID 1 = Leaf Kanan

$$\hat{y}_i^{(1)} = 0.6 + 0.5 \times 0.541$$

$$\hat{y}_i^{(1)} = 0.8705$$

ii. ID 2 = Leaf Kiri

$$\hat{y}_2^{(1)} = 0.6 + 0.5 \times (-0.465)$$

$$\hat{y}_2^{(1)} = 0.3675$$

iii. ID 3 = Leaf Kiri

$$\hat{y}_3^{(1)} = 0.6 + 0.5 \times (-0.465)$$

$$\hat{y}_3^{(1)} = 0.3675$$

iv. ID 4 = Leaf Kiri

$$\hat{y}_4^{(1)} = 0.6 + 0.5 \times (-0.465)$$

$$\hat{y}_4^{(1)} = 0.3675$$

v. ID 5 = Leaf Kanan

$$\hat{y}_5^{(1)} = 0.6 + 0.5 \times 0.541$$

$$\hat{y}_5^{(1)} = 0.8705$$

Tabel L2. 3 Prediksi Baru Tree 1 XGBoost

ID	Leaf	w _j	$\hat{y}_i^{(1)}$
1	R	0.541	0.8705
2	L	-0.465	0.3675
3	L	-0.465	0.3675
4	L	-0.465	0.3675
5	R	0.541	0.8705

3. Tree 2 (Iterasi kedua)

Kondisi awal Iterasi 2: kita gunakan prediksi setelah Tree 1 (hasil bagian tabel prediksi)

$$\hat{y}^{(1)} = [0.8705, 0.3675, 0.3675, 0.3675, 0.8705]$$

a. Hitung gradien & hessian baru

$$g_i = \hat{y}_i^{(1)} - y_i, h_i = \hat{y}_i^{(1)}(1 - \hat{y}_i^{(1)})$$

$$\text{i. ID 1: } y_1 = 1, \hat{y}_1^{(1)} = 0.8705$$

$$g_1 = 0.8705 - 1 = -0.1295$$

$$h_1 = 0.8705 \times (1 - 0.8705) = 0.1129$$

$$\text{ii. ID 2: } y_2 = 0, \hat{y}_2^{(1)} = 0.3675$$

$$g_2 = 0.3675 - 0 = 0.3675$$

$$h_2 = 0.3675 \times (1 - 0.3675) = 0.2327$$

$$\text{iii. ID 3: } y_3 = 1, \hat{y}_3^{(1)} = 0.3675$$

$$g_3 = 0.3675 - 1 = -0.6325$$

$$h_3 = 0.3675 \times (1 - 0.3675) = 0.2327$$

iv. ID 4: $y_4 = 0, \hat{y}_4^{(1)} = 0.3675$

$$g_4 = 0.3675 - 0 = 0.3675$$

$$h_4 = 0.3675 \times 0.6325 = 0.2327$$

v. ID 5: $y_5 = 1, \hat{y}_5^{(1)} = 0.8705$

$$g_5 = 0.8705 - 1 = -0.1295$$

$$h_5 = 0.8705 \times (1 - 0.8705) = 0.1129$$

b. Split berdasarkan Fitur (mahal)

Leaf kiri ($x=0$): ID 2,3,4

i. $\sum g_i = g_2 + g_3 + g_4$

$$\sum g_i = 0.3675 + (-0.6325) + 0.3675 = 0.1025$$

ii. $\sum h_i = h_2 + h_3 + h_4$

$$\sum h_i = 0.2327 + 0.2327 + 0.2327 = 0.6981$$

Leaf kanan ($x=1$): ID 1,5

i. $\sum g_i = g_1 + g_5$

$$\sum g_i = -0.1295 + (-0.1295) = -0.2590$$

ii. $\sum h_i = h_1 + h_5$

$$\sum h_i = 0.1129 + 0.1129 = 0.2258$$

c. Hitung bobot daun untuk tree 2

$$w_j = -\frac{\sum g_i}{\sum h_i + \lambda}, \lambda = 1$$

i. Leaf Kiri: $w_L = -\frac{0.1025}{0.6981+1} = -0.0604$

ii. Leaf Kanan: $w_R = -\frac{-0.2590}{0.2258+1} = 0.2114$

d. Update Prediksi setelah Tree 2

$$\hat{y}_i^{(2)} = \hat{y}_i^{(1)} + \eta \cdot w_j, \eta = 0.5$$

i. ID 1 = Leaf Kanan

$$\hat{y}_1^{(2)} = 0.8705 + 0.5 \times 0.2114$$

$$\hat{y}_1^{(2)} = 0.9762$$

ii. ID 2 = Leaf Kiri

$$\hat{y}_2^{(2)} = 0.3675 + 0.5 \times (-0.0604)$$

$$\hat{y}_2^{(2)} = 0.3373$$

iii. ID 3 = Leaf Kiri

$$\hat{y}_3^{(2)} = 0.3675 + 0.5 \times (-0.0604)$$

$$\hat{y}_3^{(2)} = 0.3373$$

iv. ID 4 = Leaf Kiri

$$\hat{y}_4^{(2)} = 0.3675 + 0.5 \times (-0.0604)$$

$$\hat{y}_4^{(2)} = 0.3373$$

v. ID 5 = Leaf Kanan

$$\hat{y}_5^{(2)} = 0.8705 + 0.5 \times 0.2114$$

$$\hat{y}_5^{(2)} = 0.9762$$

Tabel L2. 4 Prediksi Final Setelah Tree 2 XGBoost

ID	Leaf	w _j	$\hat{y}_i^{(2)}$
1	R	0.2114	0.9762
2	L	-0.0604	0.3373
3	L	-0.0604	0.3373
4	L	-0.0604	0.3373
5	R	0.2114	0.9762

e. Regularisasi Tree 2

$$\Omega(f2) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \text{ (Persamaan 2.18 di Bab II)}$$

$$\Omega(f2) = 0 + 0.5((-0.0604)^2 + 0.2114^2)$$

$$\Omega(f2) = 0.0242$$

f. Hitung Loss (L) dan Objektif Akhir (Obj)

Loss Total $L = \sum_i L_i$ dengan logistic loss per-sample

$$L_i = -[y_i \ln(\hat{y}_i^{(2)}) + (1 - y_i) \ln(1 - \hat{y}_i^{(2)})]$$

Regularisasi total: $\Omega(f1) + \Omega(f2)$.

Dari perhitungan sebelumnya:

$$\Omega(f1) = 0.2545, \quad \Omega(f2) = 0.0242$$

Hitung loss per baris (menggunakan $\hat{y}_i^{(2)}$)

i. ID 1: $y = 1, p = 0.9762$

$$L1 = -[1 \cdot \ln(0.9762) + 0 \cdot \ln(1 - 0.9762)] = 0.02409$$

ii. ID 2: $y = 0, p = 0.3373$

$$L2 = -[0 \cdot \ln(0.3373) + 1 \cdot \ln(1 - 0.3373)] = 0.41143$$

iii. ID 3: $y = 1, p = 0.3373$

$$L2 = -[1 \cdot \ln(0.3373) + 0 \cdot \ln(1 - 0.3373)] = 1.08678$$

iv. ID 4: $y = 0, p = 0.3373$

$$L2 = -[0 \cdot \ln(0.3373) + 1 \cdot \ln(1 - 0.3373)] = 0.41143$$

v. ID 5: $y = 1, p = 0.9762$

$$L1 = -[1 \cdot \ln(0.9762) + 0 \cdot \ln(1 - 0.9762)] = 0.02409$$

Jumlah loss total:

$$L = L1 + L2 + L3 + L4 + L5$$

$$L = 0.02409 + 0.41143 + 1.08678 + 0.41143 + 0.02409$$

$$L = 1.95782$$

g. Objektif Akhir

$$Obj(\theta) = L(\theta) + \Omega(\theta)$$

$$L = 1.95782$$

$$\Omega(f1) = 0.2545$$

$$\Omega(f2) = 0.242$$

$$Obj(\theta) = 1.95782 + 0.25450 + 0.02420 = 2.23652$$

angka ini adalah nilai fungsi objektif yang XGBoost coba minimalkan

4. Output setelah tree 2 sebagai input meta model

Setelah seluruh proses iterasi XGBoost selesai, hasil akhir yang paling penting adalah probabilitas prediksi untuk setiap ulasan. Probabilitas inilah yang akan menjadi *meta-feature* untuk *meta-model* (*Logistic Regression*).

Tabel L2. 5 Output Probabilitas XGBoost

ID	Tweet Ulasan	Probabilitas Keluhan
1	Makanan cepat sampai, tapi mahal	0.9762
2	Ongkir murah, driver ramah	0.3373
3	Pesanan salah, kecewa banget	0.3373
4	Aplikasi lancar, pengiriman cepat	0.3373
5	Biaya ongkir mahal, kualitas kurang	0.9762

LAMPIRAN III

PERHITUNGAN LIGHTGBM

Bagian ini mengilustrasikan proses kerja algoritma LightGBM secara konseptual. Perhitungan ini akan menggunakan *dataset dummy* yang sama dengan contoh XGBoost untuk menunjukkan perbedaan fundamental dalam proses pembangunan pohon, yaitu penggunaan metode berbasis histogram untuk menemukan titik pemisahan (*split point*) yang optimal. *Dataset* tersebut dapat dilihat pada **Tabel L3.1** .

Tabel L3. 1 *Dataset* Biner LightGBM

ID	Tweet Ulasan	Mengandung kata "mahal" (x)	Label (y)
1	"Makanan cepat sampai, tapi mahal"	1	1
2	"Ongkir murah, driver ramah"	0	0
3	"Pesanan salah, kecewa banget"	0	1
4	"Aplikasi lancar, pengiriman cepat"	0	0
5	"Biaya ongkir mahal, kualitas kurang"	1	1

Keterangan :

Label 1 = Keluhan

Label 0 = Bukan Keluhan.

1. Prediksi Awal (Base Score)

$$\hat{y}_i^{(0)} = \text{base score} = \text{rata rata label}$$

$$\hat{y}_i^{(0)} = \frac{1 + 0 + 1 + 0 + 1}{5}$$

$$\hat{y}_i^{(0)} = 0.6$$

semua data diprediksi awal = 0.6, sebagai starting point LightGBM.

2. Tree 1 (Iterasi Pertama)

a. Hitung Gradien dan Hessian (Pseudo- Residual)

$$g_i = \hat{y}_i^{(0)} - y_i, h_i = \hat{y}_i^{(0)}(1 - \hat{y}_i^{(0)})$$

Maka untuk tiap data perhitungannya sebagai berikut :

i. ID 1: $y_1 = 1, \hat{y}_1^{(0)} = 0.6$

$$g_1 = 0.6 - 1 = -0.4, h_1 = 0.6 \times (1 - 0.6) = 0.24$$

ii. ID 2: $y_2 = 0, \hat{y}_2^{(0)} = 0.6$

$$g_2 = 0.6 - 0 = 0.6, h_2 = 0.6 \times (1 - 0.6) = 0.24$$

iii. ID 3: $y_3 = 1, \hat{y}_3^{(0)} = 0.6$

$$g_3 = 0.6 - 1 = -0.4, h_3 = 0.6 \times (1 - 0.6) = 0.24$$

iv. ID 4: $y_4 = 0, \hat{y}_4^{(0)} = 0.6$

$$g_4 = 0.6 - 0 = 0.6, h_4 = 0.6 \times (1 - 0.6) = 0.24$$

v. ID 5: $y_5 = 1, \hat{y}_5^{(0)} = 0.6$

$$g_5 = 0.6 - 1 = -0.4, h_5 = 0.6 \times (1 - 0.6) = 0.24$$

b. Histogram Binning

Karena fitur akan di biner (0/1) histogramnya sederhana, LightGBM

biasanya membuat histogram per bin yang berisi jumlah gradien/hessian:

i. Bin $x = 0$ (tidak ada "mahal"): ID 2,3,4

$$G_{bin0} = \sum g$$

$$G_{bin0} = g_2 + g_3 + g_4 = 0.6 + (-0.4) + 0.6 = 0.8$$

$$H_{bin0} = \sum h$$

$$H_{bin0} = h_2 + h_3 + h_4 = 0.24 + 0.24 + 0.24 = 0.72$$

ii. Bin $x = 1$ (ada "mahal"): ID 1,5

$$G_{bin1} = \sum g$$

$$G_{bin1} = g_1 + g_5 = -0.4 + (-0.4) = -0.8$$

$$H_{bin1} = \sum h_i$$

$$H_{bin1} = h_1 + h_5 = 0.24 + 0.24 = 0.48$$

Root totals:

$$G = G_{bin1} + G_{bin2} = 0.8 + (-0.8) = 0$$

$$H = H_{bin1} + H_{bin2} = 0.72 + 0.48 = 1.20$$

c. Hitung Gain split ($x=0$ dan $x=1$)

$$Gain = \frac{1}{2} \left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} + \frac{G^2}{H + \lambda} \right) - \gamma \text{ (merujuk pada Persamaan 2.19 di}$$

Bab II)

$$Gain = \frac{1}{2} \left(\frac{0.8^2}{0.72 + 1} + \frac{(-0.8)^2}{0.48 + 1} - \frac{0^2}{1.2 + 1} \right) - \gamma$$

$$Gain = \frac{1}{2} (0.3721 + 0.4324 - 0)$$

$$Gain = 0.40225$$

Karena gain > 0 , split dipilih (left-wise LightGBM akan membuat 2 daun)

d. Tree 1 (Hitung Bobot Daun)

Rumus :

$$w_j = \frac{\sum_{i \in leaf} g_i}{\sum_{i \in leaf} h_{i+\lambda}}$$

Perhitungan :

$$\begin{aligned} \text{i.} \quad w_L^{(1)} &= \frac{G_{bin0}}{H_{bin0} + \lambda} \\ w_L^{(1)} &= \frac{0.8}{0.72 + 1} \\ w_L^{(1)} &= -0.4651162791 \end{aligned}$$

$$\begin{aligned} \text{ii.} \quad w_R^{(1)} &= \frac{G_{bin1}}{H_{bin1} + \lambda} \\ w_R^{(1)} &= \frac{-0.8}{0.48 + 1} \end{aligned}$$

$$w_R^{(1)} = 0.5405405405$$

e. Update prediksi setelah Tree 1

Rumus:

$$\hat{y}_i^{(1)} = \hat{y}_i^{(0)} + \eta \cdot w_j, \eta = 0.5$$

Perhitungan

$$\begin{aligned} \text{i.} \quad \text{ID 1} &= \text{Leaf Kanan} \\ \hat{y}_i^{(1)} &= 0.6 + 0.5 \times 0.541 \\ \hat{y}_i^{(1)} &= 0.8705 \\ \text{ii.} \quad \text{ID 2} &= \text{Leaf Kiri} \end{aligned}$$

$$\hat{y}_2^{(1)} = 0.6 + 0.5 \times (-0.465)$$

$$\hat{y}_2^{(1)} = 0.3675$$

iii. ID 3 = Leaf Kiri

$$\hat{y}_3^{(1)} = 0.6 + 0.5 \times (-0.465)$$

$$\hat{y}_3^{(1)} = 0.3675$$

iv. ID 4 = Leaf Kiri

$$\hat{y}_4^{(1)} = 0.6 + 0.5 \times (-0.465)$$

$$\hat{y}_4^{(1)} = 0.3675$$

v. ID 5 = Leaf Kanan

$$\hat{y}_5^{(1)} = 0.6 + 0.5 \times 0.541$$

$$\hat{y}_5^{(1)} = 0.8705$$

f. Tree 2 (iterasi 2)

Hitung Gradient dan Hessian dari $\hat{y}^{(1)}$

$$g_i = \hat{y}_i^{(1)} - y_i, h_i = \hat{y}_i^{(1)}(1 - \hat{y}_i^{(1)})$$

i. ID 1: $y_1 = 1, \hat{y}_1^{(1)} = 0.8705$

$$g_1 = 0.8705 - 1 = -0.1295$$

$$h_1 = 0.8705 \times (1 - 0.8705) \approx 0.1129$$

ii. ID 2: $y_2 = 0, \hat{y}_2^{(1)} = 0.3675$

$$g_2 = 0.3675 - 0 = 0.3675$$

$$h_2 = 0.3675 \times (1 - 0.3675) = 0.2327$$

- iii. ID 3: $y_3 = 1, \hat{y}_3^{(1)} = 0.3675$
 $g_3 = 0.3675 - 1 = -0.6325$
 $h_3 = 0.3675 \times (1 - 0.3675) = 0.2327$
- iv. ID 4: $y_4 = 0, \hat{y}_4^{(1)} = 0.3675$
 $g_4 = 0.3675 - 0 = 0.3675$
 $h_4 = 0.3675 \times 0.6325 = 0.2327$
- v. ID 5: $y_5 = 1, \hat{y}_5^{(1)} = 0.8705$
 $g_5 = 0.8705 - 1 = -0.1295$
 $h_5 = 0.8705 \times (1 - 0.8705) = 0.1129$

Tabel L3. 2 Gradien dan Hessian Tree 2 LightGBM

ID	y	$\hat{y}^{(1)}$	g_i	h_i	$ g_i $
1	1	0.8705	-0.1295	0.1129	-0.1295
2	0	0.3675	0.3675	0.2327	0.3675
3	1	0.3675	-0.6325	0.2327	-0.6325
4	0	0.3675	0.3675	0.2327	0.3675
5	1	0.8705	-0.1295	0.1129	-0.1295

g. Pilih Sampel via GOS

- i. Parameter: $a = 40\%, b = 50\%$

$$Skala\ s = \frac{1 - a}{b}$$

$$Skala\ s = \frac{0.6}{0.5} = 1.2.$$

- ii. Top-a: Pilih $[5 \times 0.4] = 2$ data dengan $|g_i|$ terbesar: ID 3, ID 2.
- iii. Sampel-b: Pilih $[(5-2) \times 0.5] = 2$ data dari sisa {1, 4, 5}: ID 1, ID 4.
- iv. Sampel Dikecualikan: ID 5.

h. Gradien & Hessian yang Dipakai (Setelah Skala GOSS)

ID 3 , ID 2 (Top-a, tanpa skala):

i. $g_3 = -0.6326, h_3 = 0.2324$

ii. $g_2 = 0.3674, h_2 = 0.2324$

ID 1, ID 4 (Sampel-b, dikali skala s=1.2):

i. $g'_1 = -0.1297 \times 1.2 = -0.15564$

$$h'_1 = 0.1129 \times 1.2 = 0.13548$$

ii. $g'_4 = 0.3674 \times 1.2 = 0.44088$

$$h'_4 = 0.2324 \times 1.2 = 0.27888$$

i. Agregasi Histogram (GOSS) dan Hitung Bobot Daun (Tree 2)

Bin x=0 (ID 2, 3, 4):

i. $G_L = g_2 + g_3 + g'_4$

$$G_L = 0.3674 + (-0.6326) + 0.44088$$

$$G_L = 0.17568$$

ii. $H_L = h_2 + h_3 + h'_4$

$$H_L = 0.2324 + 0.2324 + 0.27888$$

$$H_L = 0.74368$$

Bin x=1 (ID 1):

i. $G_R = g'_1 = -0.15564$

ii. $H_R = h'_1 = -0.13548$

j. Perhitungan Bobot (dengan $\lambda=1$):

i. Daun Kiri (x=0): $w_L^{(2)} = -\frac{0.17568}{0.74368+1} = 0.1007524$

ii. Daun Kiri ($x=1$): $w_R^{(2)} = -\frac{0.15564}{0.13548+1} = 0.137092$

k. Update Prediksi Setelah Tree 2

$$\hat{y}_i^{(2)} = \hat{y}_i^{(1)} + \eta \cdot w_j, \eta = 0.5$$

i. ID 1 = Leaf Kanan

$$\hat{y}_1^{(2)} = 0.8727 + 0.5 \times 0.137092$$

$$\hat{y}_1^{(2)} = 0.938816$$

ii. ID 2 = Leaf Kiri

$$\hat{y}_2^{(2)} = 0.36744 + 0.5 \times (-0.1007524)$$

$$\hat{y}_2^{(2)} = 0.3170638$$

iii. ID 3 = Leaf Kiri

$$\hat{y}_3^{(2)} = 0.36744 + 0.5 \times (-0.1007524)$$

$$\hat{y}_3^{(2)} = 0.3170638$$

iv. ID 4 = Leaf Kiri

$$\hat{y}_4^{(2)} = 0.36744 + 0.5 \times (-0.1007524)$$

$$\hat{y}_4^{(2)} = 0.3170638$$

v. ID 5 = Leaf Kanan

$$\hat{y}_5^{(2)} = 0.87027 + 0.5 \times 0.137092$$

$$\hat{y}_5^{(2)} = 0.938816$$

l. Perhitungan Objektif Akhir

Regularisasi Tiap Pohon

$$\Omega(fk) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

$$\Omega(f_1) = \frac{1}{2} (1) \times [(-0.465116)^2 + (0.54054)^2] = 0.254258$$

$$\Omega(f_2) = \frac{1}{2} (1) \times [(-0.1007524)^2 + (0.137092)^2] = 0.254258$$

m. Hitung Loss Akhir (Binary Log-Loss)

$$L_i = -[y_i \ln(\hat{y}_i^{(2)}) + (1 - y_i) \ln(1 - \hat{y}_i^{(2)})]$$

i. ID 1 :

$$y = 1, p = 0.9388$$

$$L1 = -[1 \times \ln(0.9388) + 0] = 0.0631$$

ii. ID 2 :

$$y = 0, p = 0.3171$$

$$L2 = -[0 + 1 \times \ln(1 - 0.3171)] = 0.3813$$

iii. ID 3 :

$$y = 1, p = 0.3171$$

$$L3 = -[1 \times \ln(0.3171) + 0] = 1.1488$$

iv. ID 4 :

$$y = 0, p = 0.3171$$

$$L4 = -[0 + 1 \times \ln(1 - 0.3171)] = 0.3813$$

v. ID 5 :

$$y = 1, p = 0.9388$$

$$L5 = -[1 \cdot \ln(0.9388) + 0] = 0.0631$$

Total Loss:

$$\sum L_i = 0.0631 + 0.3813 + 1.1488 + 0.3813 + 0.0631$$

$$\sum L_i = 2.0376$$

n. Objektif Akhir (Loss + Regularisasi Semua Pohon)

$$Obj(\theta) = L(f_1) + \Omega(f_2)$$

$$Obj = 2.0376 + 0.254258 + 0.01448$$

$$Obj = 2.3063$$

3. Output setelah tree 2 sebagai input meta model

Sama seperti XGBoost, output penting dari LightGBM adalah probabilitas prediksi yang akan menjadi *meta-feature* kedua untuk *Logistic Regression*.

Tabel L3. 3 Output Probabilitas LightGBM

ID	Tweet Ulasan	Probabilitas Keluhan
1	Makanan cepat sampai, tapi mahal	0.9282
2	Ongkir murah, driver ramah	0.3373
3	Pesanan salah, kecewa banget	0.3373
4	Aplikasi lancar, pengiriman cepat	0.3373
5	Biaya ongkir mahal, kualitas kurang	0.9282

LAMPIRAN IV

PERHITUNGAN *LOGISTIC REGRESSION*

Bagian ini mengilustrasikan proses kerja algoritma *Logistic Regression* sebagai *meta-model* dalam arsitektur Stacking. *Logistic Regression* akan dilatih menggunakan prediksi dari model-model dasar (*base models*) sebagai fitur masukan untuk menghasilkan klasifikasi final.

1. *Dataset* dan Inisialisasi

Perhitungan *Logistic Regression* ini akan menggunakan *dataset dummy* yang merepresentasikan output probabilitas dari dua *base model* (misalnya, XGBoost dan LightGBM). *Dataset* tersebut dapat dilihat pada **Tabel L4.1**.

Tabel L4. 1 *Dataset* Input untuk Meta-model (*Logistic Regression*)

ID	Prediksi XGBoost (X_1)	Prediksi LightGBM (X_2)	Label Aktual (y)
1	0.9762	0.9282	1
2	0.3373	0.3373	0
3	0.3373	0.3373	1
4	0.3373	0.3373	0
5	0.9762	0.9282	1

2. Inisialisasi Parameter

Model dimulai dengan bobot (koefisien) awal. Untuk kesederhanaan, semua bobot dimulai dari nol. Kita juga menetapkan *learning rate* (η) untuk mengontrol seberapa besar bobot diperbarui di setiap iterasi.

- Intercept: $\beta_0 = 0$
- Bobot untuk x_1 : $\beta_1 = 0$

c. Bobot untuk x_2 : $\beta_2 = 0$

d. Learning Rate: $\eta = 0.1$

3. Hitung Kombinasi Linear (Logit)

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2$$

$$Y = 0 + (0 \times X_1) + (0 \times X_2)$$

a. ID 1: $Y_1 = 0 + (0 \times 0.9762) + (0 \times 0.9282) = 0$

b. ID 2: $Y_2 = 0 + (0 \times 0.3373) + (0 \times 0.3373) = 0$

c. ID 3: $Y_3 = 0 + (0 \times 0.3373) + (0 \times 0.3373) = 0$

d. ID 4: $Y_4 = 0 + (0 \times 0.3373) + (0 \times 0.3373) = 0$

e. ID 5: $Y_5 = 0 + (0 \times 0.9762) + (0 \times 0.9282) = 0$

4. Konversi ke Probabilitas (Fungsi Sigmoid)

Output linear (Y) diubah menjadi probabilitas (P) antara 0 dan 1.

$$P = \frac{e^Y}{1 + e^Y} = \frac{1}{1 + e^{-Y}}$$

$$P = \frac{1}{1 + e^{-0}} = \frac{1}{1 + 1} = 0.5$$

5. Hitung Log-likelihood Awal

$$\ell(\beta) = \sum_{i=1}^5 [y_i \ln(P_i) + (1 - y_i) \ln(1 - p_i)]$$

a. ID 1:

$$y_1 = 1, p_1 = 0.5$$

$$\ell_1 = 1 \times \ln(0.5) + (1 - 1) \cdot \ln(1 - 0.5) = \ln(0.5) = -0.6931$$

b. ID 2:

$$y_2=0, p_2=0.5$$

$$\ell_2 = 0 \times \ln(0.5) + (1 - 0) \cdot \ln(1 - 0.5) = \ln(0.5) = -0.6931$$

c. ID 3:

$$y_3=1, p_3=0.5$$

$$\ell_3 = 1 \times \ln(0.5) + (1 - 1) \cdot \ln(1 - 0.5) = \ln(0.5) = -0.6931$$

d. ID 4:

$$y_4=0, p_4=0.5$$

$$\ell_4 = 0 \times \ln(0.5) + (1 - 0) \cdot \ln(1 - 0.5) = \ln(0.5) = -0.6931$$

e. ID 5:

$$y_5=1, p_5=0.5$$

$$\ell_5 = 1 \times \ln(0.5) + (1 - 0) \cdot \ln(1 - 0.5) = \ln(0.5) = -0.6931$$

$$\text{Total log-likelihood awal: } \ell_{total} = -0.6931 \times 5 = -3.4655$$

6. Hitung Gradien Log-Likelihood

$$\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^m (y_i - P_i) X_{ij}$$

a. $\beta_0 (X_0 = 1)$

$$\text{i. } (y_1 - P_1) \times 1 = 1 - 0.5 = 0.5$$

$$\text{ii. } (y_2 - P_2) \times 0 = 0 - 0.5 = -0.5$$

$$\text{iii. } (y_3 - P_3) \times 1 = 1 - 0.5 = 0.5$$

$$\text{iv. } (y_4 - P_4) \times 0 = 0 - 0.5 = -0.5$$

$$\text{v. } (y_5 - P_5) \times 0 = 1 - 0.5 = 0.5$$

$$\text{Gradien } \beta_0 = 0.5 - 0.5 + 0.5 - 0.5 + 0.5 = 0.5$$

b. $\beta_1 (X_1)$

$$\text{i.} \quad (y_1 - P_1) \times X_{11} = (1 - 0.5) \times 0.9762 = 0.4881$$

$$\text{ii.} \quad (y_2 - P_2) \times X_{12} = (0 - 0.5) \times 0.3373 = -0.1687$$

$$\text{iii.} \quad (y_3 - P_3) \times X_{13} = (1 - 0.5) \times 0.3373 = 0.1687$$

$$\text{iv.} \quad (y_4 - P_4) \times X_{14} = (0 - 0.5) \times 0.3373 = -0.1687$$

$$\text{v.} \quad (y_5 - P_5) \times X_{15} = (0 - 0.5) \times 0.9762 = 0.4881$$

$$\text{Gradien } \beta_1 = 0.4881 - 0.1687 + 0.1687 - 0.1687 + 0.4881 = 0.8075$$

c. $\beta_2 (X_2)$

$$\text{i.} \quad (y_1 - P_1) \times X_{21} = (1 - 0.5) \times 0.9282 = 0.4641$$

$$\text{ii.} \quad (y_2 - P_2) \times X_{22} = (0 - 0.5) \times 0.3373 = -0.1687$$

$$\text{iii.} \quad (y_3 - P_3) \times X_{23} = (1 - 0.5) \times 0.3373 = 0.1687$$

$$\text{iv.} \quad (y_4 - P_4) \times X_{24} = (1 - 0.5) \times 0.3373 = 0.1687$$

$$\text{v.} \quad (y_5 - P_5) \times X_{25} = (0 - 0.5) \times 0.9282 = 0.4641$$

$$\text{Gradien } \beta_2 = 0.4641 - 0.1687 + 0.1687 - 0.1687 + 0.4641 = 0.7595$$

7. Hitung Logit

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

a. ID 1:

$$Y_1 = 0.05 + (0.0808 \times 0.9762) + (0.0760 \times 0.9282)$$

$$Y_1 = 0.1994$$

b. ID 2:

$$Y_2 = 0.05 + (0.0808 \times 0.3373) + (0.0760 \times 0.3373)$$

$$Y_2 = 0.1028$$

c. ID 3:

$$Y_3 = 0.05 + (0.0808 \times 0.3373) + (0.0760 \times 0.3373)$$

$$Y_3 = 0.1028$$

d. ID 4:

$$Y_4 = 0.05 + (0.0808 \times 0.3373) + (0.0760 \times 0.3373)$$

$$Y_4 = 0.1028$$

e. ID 5:

$$Y_5 = 0.05 + (0.0808 \times 0.9762) + (0.0760 \times 0.9282)$$

$$Y_5 = 0.1994$$

8. Hitung Probabilitas Final

$$P = \frac{1}{1 + e^{-Y_i}}$$

a. ID 1

$$P_1 = \frac{1}{1 + e^{-0.1994}} = 0.5497$$

b. ID 2:

$$P_2 = \frac{1}{1 + e^{-0.1028}} = 0.5257$$

c. ID 3:

$$P_3 = \frac{1}{1 + e^{-0.1028}} = 0.5257$$

d. ID 4:

$$P_4 = \frac{1}{1 + e^{-0.1028}} = 0.5257$$

e. ID 5:

$$P_5 = \frac{1}{1 + e^{-0.1994}} = 0.5497$$

Maka jika di labelkan secara prediksi (threshold 0.5) :

- a. ID 1: $P_1 = 0.5497 > 0.5$, Prediksi kelas = 1 (Benar)
- b. ID 2: $P_2 = 0.5257 > 0.5$, Prediksi kelas = 1 (Salah)
- c. ID 3: $P_3 = 0.5257 > 0.5$, Prediksi kelas = 1 (Benar)
- d. ID 4: $P_4 = 0.5257 > 0.5$, Prediksi kelas = 1 (Salah)
- e. ID 5: $P_5 = 0.5497 > 0.5$, Prediksi kelas = 1 (Benar)

setelah iterasi pertama, model berhasil memprediksi 3 dari 5 data dengan benar.

Proses ini akan terus diulang untuk mengoptimalkan bobot

LAMPIRAN V

PERHITUNGAN METRIK EVALUASI

Lampiran ini mengilustrasikan cara menghitung metrik evaluasi untuk kasus *multi-kelas*, sesuai dengan rumus yang dijelaskan pada Bab II. Untuk contoh ini, kita akan menggunakan hasil prediksi *dummy* untuk 3 kelas Intensi: 0 (Pernyataan), 1 (Pujian), 2 (Keluhan), 3 (Pertanyaan), dan 4 (Saran-kritik).

1. Data Hasil Akhir

Tabel L5. 1 *Dataset* Akhir

ID	Teks Ulasan	Label Aktual (y)	Prediksi Kelas ($\hat{y}$)
D1	"Makanan cepat sampai, tapi mahal"	1 (Keluhan)	1 (Keluhan)
D2	"Ongkir murah, driver ramah"	2 (Pujian)	2 (Pujian)
D3	"Pesanan salah, kecewa banget"	1 (Keluhan)	1 (Keluhan)
D4	"Aplikasi lancar, pengiriman cepat"	2 (Pujian)	0 (Netral)
D5	"Biaya ongkir mahal, kualitas kurang"	1 (Keluhan)	1 (Keluhan)
D6	Saya pakai GoPay kemarin	0 (Pernyataan)	0 (Pernyataan)
D7	Apakah promonya masih ada?	3 (Pertanyaan)	3 (Pertanyaan)
D8	Tolong perbaiki rute di peta	4 (Saran-kritik)	4 (Saran-kritik)
D9	Kenapa drivernya jauh sekali?	3 (Pertanyaan)	2 (Keluhan)
D10	Saran, adakan promo lagi	4 (Saran-kritik)	1 (Pujian)

2. Membuat Confusion Matrix

Tabel L5. 2 Confusion Matriks

Aktual \ Prediksi	Pernyataan (0)	Pujian (1)	Keluhan (2)	Pertanyaan (3)	Saran- kritik (4)
Pernyataan (0)	1	0	0	0	0
Pujian (1)	1	1	0	0	0
Keluhan (2)	0	0	3	0	0
Pertanyaan (3)	0	0	1	1	0
Saran-kritik (4)	0	1	0	0	1

3. Metrik per Kelas

Tabel L5. 3 Metrik per Kelas

Kelas	TP	FP	FN	Precision	Recall	F1-Score	Support
0 (Pernyataan)	1	1	0	0.500	1.000	0.667	1
1 (Pujian)	1	1	1	0.500	0.500	0.500	2
2 (Keluhan)	3	1	0	0.750	1.000	0.857	3
3 (Pertanyaan)	1	0	1	1.000	0.500	0.667	2
4 (Saran-kritik)	1	0	1	1.000	0.500	0.667	2

4. Perhitungan Metrik Evaluasi Akhir

a. Akurasi (Accuracy)

$$Accuracy = \frac{Jumlah\ Prediksi\ Benar}{Total\ Seluruh\ Data}$$

$$Accuracy = \frac{1 + 1 + 3 + 1 + 1}{10} = \frac{7}{10} = 0.7$$

$$Accuracy = 70\%$$

b. Presisi (Precision)

$$Precision_{macro} = \frac{1}{N} \sum_{i=1}^N Precision_i$$

$$Precision_{macro} = \frac{0.5+0.5+0.75+1.0+1.0}{5} = 0.75$$

$$Precision_{weighted} = \sum_{i=1}^N (Support_i \times Precision_i)$$

$$Precision_{weighted} = \frac{(1 \times 0.5) + (2 \times 0.5) + (3 \times 0.75) + (2 \times 1.0) + (2 \times 1.0)}{10}$$

$$Precision_{weighted} = \frac{7.75}{10} = 0.775$$

c. Recall (Sensitivity)

$$Recall_{macro} = \frac{1}{N} \sum_{i=1}^N Recall_i$$

$$Recall_{macro} = \frac{1.0 + 0.5 + 1.0 + 0.5 + 0.5}{5} = 0.7$$

$$Recall_{weighted} = \sum_{i=1}^N \left(\frac{Support_i}{Total\ Sampel} \times Recall_i \right)$$

$$Recall_{weighted} = \frac{(1 \times 1.0) + (2 \times 0.5) + (3 \times 1.0) + (2 \times 0.5) + (2 \times 0.5)}{10}$$

$$Recall_{weighted} = \frac{7}{10} = 0.7$$

d. F1-Score

$$F1 - score_{macro} = \frac{1}{N} \sum_{i=1}^N F1_i$$

$$F1 - score_{macro} = \frac{0.667 + 0.5 + 0.857 + 0.667 + 0.667}{5}$$

$$F1 - score_{macro} = 0.672$$

$$F1 - Score_{weighted} = \sum_{i=1}^N \left(\frac{Support_i}{Total\ Sampel} \times F1_i \right)$$

$$F1 - score_{weighted} = \frac{(1 \times 0.667) + (2 \times 0.5) + (3 \times 0.857) + (2 \times 0.667) + (2 \times 0.667)}{10}$$

$$F1 - Score_{weighted} = \frac{6.905}{10}$$

$$F1 - Score_{weighted} = 0.6905$$

LAMPIRAN VI
CONTOH DATASET SCRAPING TWEET HARVEST

Tabel L6. 1 Contoh *Dataset* Scraping Tweet Harvest

conversati on_id_str	created_at	favorite_c ount	full_text	id_str	image_url	in_reply_to_ screen_nam e	lang	locat ion	quote _count	reply _cou nt	retwe et_co unt	tweet_url	user_id_str	usern ame
1,93941E+18	Mon Jun 30 23:57:43 +0000 2025	0	@anomali_lirali @orqclol Aku kuliah dirantauan kemana2 jalan kaki 5km+ mana kuliah bukan di kampus pusat dan bukan di pusat kota jadi mau beli makan harus jalan jauh. Pas ke kampus pusat naik gojek PP 50k wkwk. Tapi kalau bisa motoran gabakal bawa motor juga si soalnya motor cuma 1 dan dipake bapak	1,93984E+18		anomali_lirali	in		0	1	0	https://x.com/undefined/status/1939835773391614314	1,49309E+18	
1,93984E+18	Mon Jun 30 23:56:55 +0000 2025	0	When lu naik gojek tapi abang gojek nya lebih mungil dari lu https://t.co/m2JiXGYhRT	1,93984E+18	https://pbs.twimg.com/media/GuuuKvSX0AAN1YC.jpg		in		0	0	0	https://x.com/undefined/status/1939835572782284984	1,87585E+18	
1,93984E+18	Mon Jun 30 23:55:49 +0000 2025	0	chat should i apply to grab/gojek buat mulangin yuzuha yanagi tribbie sparkle https://t.co/qHc0PEeTmB	1,93984E+18	https://pbs.twimg.com/media/Guut6pUXYAAZkHV.png		in		0	0	0	https://x.com/undefined/status/1939835294062350551	1,3283E+18	
1,93894E+18	Mon Jun 30 23:54:58 +0000 2025	0	@gojekindonesia OTW pake GoCar masukin kode promo [A : GOCARAJA] Ayo ikutan temanku @mang_aris12 @wocfemed #PakeGojekPalingHemat	1,93984E+18		gojekindonesia	in		0	0	0	https://x.com/undefined/status/1939835083030241748	1,8877E+18	
1,93894E+18	Mon Jun 30 23:54:33 +0000 2025	0	@gojekindonesia OTW Pake GoCar masukin kode promo A. GOCARAJA #PakeGojekPalingHemat @cumirahma @sxcurvy	1,93983E+18		gojekindonesia	in		0	0	0	https://x.com/undefined/status/1939834975937077312	59785067	
1,93894E+18	Mon Jun 30 23:54:08 +0000 2025	0	@gojekindonesia OTW Pake GoCar masukin kode promo A. GOCARAJA #PakeGojekPalingHemat @bya_ria @Kisnanti	1,93983E+18		gojekindonesia	in		0	0	0	https://x.com/undefined/status/1939834871092019620	59785067	

LAMPIRAN VII USER ACCEPTANCE TEST

FORMULIR USER ACCEPTANCE TESTING (UAT)

Aplikasi : Dashboard Klasifikasi Tweet Gojek & Grab
 Nama Penguji : Angelina Shevenia Tanggal Pengujian : 07 / 11 / 2025
 Pekerjaan : MAHASISWA (UNTAR)

Petunjuk Pengujian:

1. Jalankan aplikasi dashboard sesuai instruksi.
2. Lakukan setiap skenario uji dalam tabel, bandingkan hasil aktual dengan hasil yang diharapkan.
3. Berikan Penilaian (✓) pada salah satu kolom: **SB (Sangat Baik)**, **B (Baik)**, **C (Cukup)**, **K (Kurang)**, atau **SK (Sangat Kurang)**.
4. Wajib isi kolom Catatan/Komentar jika penilaian C, K, atau SK, atau jika ada bug dan saran.
5. Berikan rekomendasi keseluruhan di bagian akhir formulir.
6. Tanda tangani formulir setelah selesai.

No.	Halaman	Skenario Uji	Hasil yang Diharapkan	Penilaian					Catatan/ Komentar
				SB	B	C	K	SK	
1	Umum / Sidebar	Memuat Aplikasi & Navigasi Awal	Halaman 'Prediction' terbuka, sidebar tampil benar.	✓					sidebar sudah muncul.
2	Umum / Sidebar	Navigasi antar menu	Pindah halaman antar menu (Prediction, Dataset, Dashboard, About) berhasil.	✓					Berhasil pindah halaman.
3	Sidebar	Unggah File Valid (sudah ber-label)	Pesan sukses muncul, data tampil di Dataset & Dashboard. (Alur pintas)	✓					Data dan pesan sukses sudah tampil.
4	Sidebar	Unggah File Tidak Valid (Tipe .txt)	File ditolak / muncul error tipe file.	✓					error sudah muncul.
5	Sidebar	Cek Status Model (File .pkl ada)	Tampil status "Model Siap."	✓					status sudah muncul.
6	Prediction	Lihat Halaman Awal	Tampil panduan (expander), prediksi tunggal, dan prediksi batch.		✓				Semua muncul, namun panduan terlalu panjang, untuk ada expander
7	Prediction	Prediksi Tunggal Valid	Hasil prediksi (Topic & Intention) dan probabilitas muncul.	✓					Hasil sudah muncul.
8	Prediction	Prediksi Tunggal Kosong	Muncul pesan peringatan "Harap masukkan teks..."	✓					Peringatan sudah muncul.
9	Prediction	Prediksi Batch Invalid (Tanpa full_text)	Muncul pesan error "Kolom full_text tidak ditemukan".	✓					Pesan sudah muncul.
10	Prediction	Prediksi Batch Valid & Unduh	Hasil prediksi batch (tabel, ringkasan) tampil & file CSV terunduh.	✓					Hasil sudah muncul dan terunduh.
11	Dataset	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓					sudah muncul
12	Dataset	Akses halaman (Setelah unggah file)	Tampil pesan sukses, filter, statistik, dan tabel data.	✓					sudah tampil

Gambar L7. 1 Hasil User Acceptance Testing 1

13	Dataset	Filter Data (Merek, Topic, Intention)	Tabel & statistik ter-update sesuai filter.	✓					sudah update.
14	Dataset	Toggle "Tampilkan Semua"	Tabel menampilkan semua baris (saat aktif) / 20 baris (saat non-aktif).	✓					toggle berhasil.
15	Dashboard	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓					sudah tampil
16	Dashboard	Akses halaman (Setelah unggah file)	Tampil filter Merek, Dimensi, dan semua grafik (Bar, Pie, WC).	✓					sudah tampil
17	Dashboard	Filter Merek & Dimensi	Visualisasi (Bar, Pie, WC) ter-update sesuai filter.	✓					Filter berhasil
18	About	Navigasi Tab	Halaman "About" tampil dengan 3 tab (Informasi, Evaluasi, Manual).	✓					semua tab sudah tampil.
19	About	(Tab Evaluasi) Filter Skenario	Hasil (Akurasi, Report, CM) ter-update sesuai skenario yang dipilih.	✓					Hasil sudah update.
20	About	(Tab Evaluasi) Download Report	File CSV Classification Report terunduh.	✓					sudah terunduh
21	About	(Tab Buku Manual) Download PDF	File PDF buku manual terunduh.	✓					PDF berhasil diunduh

Penjelasan Kolom Penilaian:

- **SB (Sangat Baik):** Fitur berfungsi sempurna, mudah digunakan, tampilan sangat baik.
- **B (Baik):** Fitur berfungsi sesuai harapan, mudah digunakan, ada saran perbaikan tampilan minor.
- **C (Cukup):** Fitur berfungsi, namun ada kesulitan penggunaan atau hasil/tampilan kurang optimal. Perlu perbaikan.
- **K (Kurang):** Fitur sulit digunakan, hasil tidak sesuai, atau berfungsi sebagian. Perlu perbaikan signifikan.
- **SK (Sangat Kurang):** Fitur gagal total, menghasilkan *error* fatal atau tidak berfungsi sama sekali.

Penilaian Keseluruhan:

(Berikan komentar umum mengenai kemudahan penggunaan, tampilan visual, dan fungsionalitas secara keseluruhan)
 semua sudah sangat baik, hanya kurang di panduan tapi sudah di akali dengan expander.

Rekomendasi: (Pilih salah satu)

- ☒ Aplikasi disetujui tanpa perubahan.
- ☐ Aplikasi disetujui dengan catatan perbaikan minor (lihat kolom Catatan/Komentar).
- ☐ Aplikasi perlu perbaikan signifikan sebelum disetujui (lihat kolom Catatan/Komentar).
- ☐ Aplikasi ditolak.

Tanda Tangan:

Tanggal: 07 / 11 / 2025

Nama Penguji (Angeline Shaveria...)

Gambar L7.1 (Lanjutan)

FORMULIR USER ACCEPTANCE TESTING (UAT)

Aplikasi : Dashboard Klasifikasi Tweet Gojek & Grab
 Nama Penguji : Leurey Jerry Jacob Lajipora Tanggal Pengujian : 10 / 11 / 2025
 Pekerjaan : Mahasiswa / IT Developer

Petunjuk Pengujian:

1. Jalankan aplikasi dashboard sesuai instruksi.
2. Lakukan setiap skenario uji dalam tabel, bandingkan hasil aktual dengan hasil yang diharapkan.
3. Berikan Penilaian (✓) pada salah satu kolom: SB (Sangat Baik), B (Baik), C (Cukup), K (Kurang), atau SK (Sangat Kurang).
4. Wajib isi kolom Catatan/Komentar jika penilaian C, K, atau SK, atau jika ada bug dan saran.
5. Berikan rekomendasi keseluruhan di bagian akhir formulir.
6. Tanda tangani formulir setelah selesai.

No.	Halaman	Skenario Uji	Hasil yang Diharapkan	Penilaian					Catatan/ Komentar
				SB	B	C	K	SK	
1	Umum / Sidebar	Memuat Aplikasi & Navigasi Awal	Halaman 'Prediction' terbuka, sidebar tampil benar.	✓					
2	Umum / Sidebar	Navigasi antar menu	Pindah halaman antar menu (Prediction, Dataset, Dashboard, About) berhasil.	✓					
3	Sidebar	Unggah File Valid (sudah ber-label)	Pesan sukses muncul, data tampil di Dataset & Dashboard. (Alur pintas)	✓					
4	Sidebar	Unggah File Tidak Valid (Tipe .txt)	File ditolak / muncul error tipe file.	✓					
5	Sidebar	Cek Status Model (File .pkl ada)	Tampil status "Model Siap."	✓					
6	Prediction	Lihat Halaman Awal	Tampil panduan (expander), prediksi tunggal, dan prediksi batch.	✓					
7	Prediction	Prediksi Tunggal Valid	Hasil prediksi (Topic & Intention) dan probabilitas muncul.	✓					
8	Prediction	Prediksi Tunggal Kosong	Muncul pesan peringatan "Harap masukkan teks..."	✓					
9	Prediction	Prediksi Batch Invalid (Tanpa full_text)	Muncul pesan error "Kolom full_text tidak ditemukan".	✓					
10	Prediction	Prediksi Batch Valid & Unduh	Hasil prediksi batch (tabel, ringkasan) tampil & file CSV terunduh.	✓					
11	Dataset	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓					
12	Dataset	Akses halaman (Setelah unggah file)	Tampil pesan sukses, filter, statistik, dan tabel data.	✓					

Gambar L7. 2 Hasil User Acceptance Testing 2

13	Dataset	Filter Data (Merek, Topic, Intention)	Tabel & statistik ter-update sesuai filter.	✓						
14	Dataset	Toggle "Tampilkan Semua"	Tabel menampilkan semua baris (saat aktif) / 20 baris (saat non-aktif).	✓						
15	Dashboard	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓						
16	Dashboard	Akses halaman (Setelah unggah file)	Tampil filter Merek, Dimensi, dan semua grafik (Bar, Pie, WC).	✓						
17	Dashboard	Filter Merek & Dimensi	Visualisasi (Bar, Pie, WC) ter-update sesuai filter.	✓						
18	About	Navigasi Tab	Halaman "About" tampil dengan 3 tab (Informasi, Evaluasi, Manual).	✓						
19	About	(Tab Evaluasi) Filter Skenario	Hasil (Akurasi, Report, CM) ter-update sesuai skenario yang dipilih.	✓						
20	About	(Tab Evaluasi) Download Report	File CSV Classification Report terunduh.	✓						
21	About	(Tab Buku Manual) Download PDF	File PDF buku manual terunduh.	✓						

Penjelasan Kolom Penilaian:

- **SB (Sangat Baik):** Fitur berfungsi sempurna, mudah digunakan, tampilan sangat baik.
- **B (Baik):** Fitur berfungsi sesuai harapan, mudah digunakan, ada saran perbaikan tampilan minor.
- **C (Cukup):** Fitur berfungsi, namun ada kesulitan penggunaan atau hasil/tampilan kurang optimal. Perlu perbaikan.
- **K (Kurang):** Fitur sulit digunakan, hasil tidak sesuai, atau berfungsi sebagian. Perlu perbaikan signifikan.
- **SK (Sangat Kurang):** Fitur gagal total, menghasilkan *error* fatal atau tidak berfungsi sama sekali.

Penilaian Keseluruhan:

(Berikan komentar umum mengenai kemudahan penggunaan, tampilan visual, dan fungsionalitas secara keseluruhan)

Sudah jalan sepenuhnya, Tweet sudah bisa diprediksi dan download CSV

Rekomendasi: (Pilih salah satu)

- ☒ Aplikasi disetujui tanpa perubahan.
- ☐ Aplikasi disetujui dengan catatan perbaikan minor (lihat kolom Catatan/Komentar).
- ☐ Aplikasi perlu perbaikan signifikan sebelum disetujui (lihat kolom Catatan/Komentar).
- ☐ Aplikasi ditolak.

Tanda/Tangan:
Tanggal: 10 / 11 / 2025

Nama Penguji (Nama) : Jaelani

Gambar L7.2 (Lanjutan)

FORMULIR USER ACCEPTANCE TESTING (UAT)

Aplikasi : Dashboard Klasifikasi Tweet Gojek & Grab
 Nama Penguji : Vincent Alkando Tanggal Pengujian : 07 / 11 / 2025
 Pekerjaan : Mahasiswa

Petunjuk Pengujian:

1. Jalankan aplikasi dashboard sesuai instruksi.
2. Lakukan setiap skenario uji dalam tabel, bandingkan hasil aktual dengan hasil yang diharapkan.
3. Berikan Penilaian (✓) pada salah satu kolom: **SB (Sangat Baik)**, **B (Baik)**, **C (Cukup)**, **K (Kurang)**, atau **SK (Sangat Kurang)**.
4. Wajib isi kolom Catatan/Komentar jika penilaian C, K, atau SK, atau jika ada bug dan saran.
5. Berikan rekomendasi keseluruhan di bagian akhir formulir.
6. Tanda tangani formulir setelah selesai.

No.	Halaman	Skenario Uji	Hasil yang Diharapkan	Penilaian					Catatan/ Komentar
				SB	B	C	K	SK	
1	Umum / Sidebar	Memuat Aplikasi & Navigasi Awal	Halaman 'Prediction' terbuka, sidebar tampil benar.	✓					sidebar tampil
2	Umum / Sidebar	Navigasi antar menu	Pindah halaman antar menu (Prediction, Dataset, Dashboard, About) berhasil.	✓					dapat pindah halaman
3	Sidebar	Unggah File Valid (sudah ber-label)	Pesan sukses muncul, data tampil di Dataset & Dashboard. (Alur pintas)	✓					pesan dan data tampil
4	Sidebar	Unggah File Tidak Valid (Tipe .txt)	File ditolak / muncul error tipe file.	✓					File ditolak
5	Sidebar	Cek Status Model (File .pkl ada)	Tampil status "Model Siap."	✓					Status tampil
6	Prediction	Lihat Halaman Awal	Tampil panduan (expander), prediksi tunggal, dan prediksi batch.	✓					Sesuai tampil
7	Prediction	Prediksi Tunggal Valid	Hasil prediksi (Topic & Intention) dan probabilitas muncul.	✓					Hasil tampil
8	Prediction	Prediksi Tunggal Kosong	Muncul pesan peringatan "Harap masukkan teks..."	✓					Pesan tampil
9	Prediction	Prediksi Batch Invalid (Tanpa full_text)	Muncul pesan error "Kolom full_text tidak ditemukan".	✓					Pesan tampil
10	Prediction	Prediksi Batch Valid & Unduh	Hasil prediksi batch (tabel, ringkasan) tampil & file CSV terunduh.	✓					Hasil tampil dan terunduh
11	Dataset	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓					Pesan tampil
12	Dataset	Akses halaman (Setelah unggah file)	Tampil pesan sukses, filter, statistik, dan tabel data.	✓					Pesan tampil

Gambar L7. 3 Hasil User Acceptance Testing 3

13	Dataset	Filter Data (Merek, Topic, Intention)	Tabel & statistik ter-update sesuai filter.	✓					tabel dan statistik ter-filter
14	Dataset	Toggle "Tampilkan Semua"	Tabel menampilkan semua baris (saat aktif) / 20 baris (saat non-aktif).	✓					Seluruh baris tampil
15	Dashboard	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓					Pesan pesan tampil
16	Dashboard	Akses halaman (Setelah unggah file)	Tampil filter Merek, Dimensi, dan semua grafik (Bar, Pie, WC).	✓					Semua tampil
17	Dashboard	Filter Merek & Dimensi	Visualisasi (Bar, Pie, WC) ter-update sesuai filter.	✓					Visualisasi ter-filter
18	About	Navigasi Tab	Halaman "About" tampil dengan 3 tab (Informasi, Evaluasi, Manual).	✓					tab tampil
19	About	(Tab Evaluasi) Filter Skenario	Hasil (Akurasi, Report, CM) ter-update sesuai skenario yang dipilih.	✓					Hasil ter-update
20	About	(Tab Evaluasi) Download Report	File CSV Classification Report terunduh.	✓					File terunduh
21	About	(Tab Buku Manual) Download PDF	File PDF buku manual terunduh.	✓					File terunduh

Penjelasan Kolom Penilaian:

- **SB (Sangat Baik):** Fitur berfungsi sempurna, mudah digunakan, tampilan sangat baik.
- **B (Baik):** Fitur berfungsi sesuai harapan, mudah digunakan, ada saran perbaikan tampilan minor.
- **C (Cukup):** Fitur berfungsi, namun ada kesulitan penggunaan atau hasil/tampilan kurang optimal. Perlu perbaikan.
- **K (Kurang):** Fitur sulit digunakan, hasil tidak sesuai, atau berfungsi sebagian. Perlu perbaikan signifikan.
- **SK (Sangat Kurang):** Fitur gagal total, menghasilkan *error* fatal atau tidak berfungsi sama sekali.

Penilaian Keseluruhan:

(Berikan komentar umum mengenai kemudahan penggunaan, tampilan visual, dan fungsionalitas secara keseluruhan)

Aplikasi dapat berjalan dengan baik, fitur-fitur sudah dapat dijalankan sesuai harapan

Rekomendasi: (Pilih salah satu)

- [✓] Aplikasi disetujui tanpa perubahan.
- [] Aplikasi disetujui dengan catatan perbaikan minor (lihat kolom Catatan/Komentar).
- [] Aplikasi perlu perbaikan signifikan sebelum disetujui (lihat kolom Catatan/Komentar).
- [] Aplikasi ditolak.

Tanda Tangan:
Tanggal: 07 / 11 / 2025

Astut

Nama Penguji (.....)

Gambar L7.3 (Lanjutan)

FORMULIR USER ACCEPTANCE TESTING (UAT)

Aplikasi : Dashboard Klasifikasi Tweet Gojek & Grab
 Nama Penguji : Gabriella Angelene Tanggal Pengujian : 10 / 11 / 2025
 Pekerjaan : HR / Mahasiswa Psikologi ST.

Petunjuk Pengujian:

1. Jalankan aplikasi dashboard sesuai instruksi.
2. Lakukan setiap skenario uji dalam tabel, bandingkan hasil aktual dengan hasil yang diharapkan.
3. Berikan Penilaian (✓) pada salah satu kolom: SB (Sangat Baik), B (Baik), C (Cukup), K (Kurang), atau SK (Sangat Kurang).
4. Wajib isi kolom Catatan/Komentar jika penilaian C, K, atau SK, atau jika ada bug dan saran.
5. Berikan rekomendasi keseluruhan di bagian akhir formulir.
6. Tanda tangani formulir setelah selesai.

No.	Halaman	Skenario Uji	Hasil yang Diharapkan	Penilaian					Catatan/ Komentar
				SB	B	C	K	SK	
1	Umum / Sidebar	Memuat Aplikasi & Navigasi Awal	Halaman 'Prediction' terbuka, sidebar tampil benar.	✓					Sudah baik
2	Umum / Sidebar	Navigasi antar menu	Pindah halaman antar menu (Prediction, Dataset, Dashboard, About) berhasil.	✓					Sudah baik
3	Sidebar	Unggah File Valid (sudah ber-label)	Pesan sukses muncul, data tampil di Dataset & Dashboard. (Alur pintas)	✓					Sudah baik
4	Sidebar	Unggah File Tidak Valid (Tipe .txt)	File ditolak / muncul error tipe file.	✓					Sudah baik
5	Sidebar	Cek Status Model (File .pkl ada)	Tampil status "Model Siap."	✓					Sudah baik
6	Prediction	Lihat Halaman Awal	Tampil panduan (expander), prediksi tunggal, dan prediksi batch.	✓					Sudah baik
7	Prediction	Prediksi Tunggal Valid	Hasil prediksi (Topic & Intention) dan probabilitas muncul.	✓					Sudah baik
8	Prediction	Prediksi Tunggal Kosong	Muncul pesan peringatan "Harap masukkan teks..."	✓					Sudah baik
9	Prediction	Prediksi Batch Invalid (Tanpa full_text)	Muncul pesan error "Kolom full_text tidak ditemukan".	✓					Sudah baik
10	Prediction	Prediksi Batch Valid & Unduh	Hasil prediksi batch (tabel, ringkasan) tampil & file CSV terunduh.	✓					Sudah baik
11	Dataset	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓					Sudah baik
12	Dataset	Akses halaman (Setelah unggah file)	Tampil pesan sukses, filter, statistik, dan tabel data.	✓					Sudah baik

Gambar L7. 4 Hasil User Acceptance Testing 4

13	Dataset	Filter Data (Merek, Topic, Intention)	Tabel & statistik ter-update sesuai filter.	✓						Sudah baik
14	Dataset	Toggle "Tampilkan Semua"	Tabel menampilkan semua baris (saat aktif) / 20 baris (saat non-aktif).	✓						Sudah baik
15	Dashboard	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓						Sudah baik
16	Dashboard	Akses halaman (Setelah unggah file)	Tampil filter Merek, Dimensi, dan semua grafik (Bar, Pie, WC).	✓						Sudah baik
17	Dashboard	Filter Merek & Dimensi	Visualisasi (Bar, Pie, WC) ter-update sesuai filter.	✓						Sudah baik
18	About	Navigasi Tab	Halaman "About" tampil dengan 3 tab (Informasi, Evaluasi, Manual).	✓						Sudah baik
19	About	(Tab Evaluasi) Filter Skenario	Hasil (Akurasi, Report, CM) ter-update sesuai skenario yang dipilih.	✓						Sudah baik
20	About	(Tab Evaluasi) Download Report	File CSV Classification Report terunduh.	✓						Sudah baik
21	About	(Tab Buku Manual) Download PDF	File PDF buku manual terunduh.	✓						Sudah baik

Penjelasan Kolom Penilaian:

- **SB (Sangat Baik):** Fitur berfungsi sempurna, mudah digunakan, tampilan sangat baik.
- **B (Baik):** Fitur berfungsi sesuai harapan, mudah digunakan, ada saran perbaikan tampilan minor.
- **C (Cukup):** Fitur berfungsi, namun ada kesulitan penggunaan atau hasil/tampilan kurang optimal. Perlu perbaikan.
- **K (Kurang):** Fitur sulit digunakan, hasil tidak sesuai, atau berfungsi sebagian. Perlu perbaikan signifikan.
- **SK (Sangat Kurang):** Fitur gagal total, menghasilkan *error* fatal atau tidak berfungsi sama sekali.

Penilaian Keseluruhan:

(Berikan komentar umum mengenai kemudahan penggunaan, tampilan visual, dan fungsionalitas secara keseluruhan)

program sudah ok, mudah digunakan.

Rekomendasi: (Pilih salah satu)

- ☒ Aplikasi disetujui tanpa perubahan.
- ☐ Aplikasi disetujui dengan catatan perbaikan minor (lihat kolom Catatan/Komentar).
- ☐ Aplikasi perlu perbaikan signifikan sebelum disetujui (lihat kolom Catatan/Komentar).
- ☐ Aplikasi ditolak.

Tanda Tangan:
Tanggal: 10 / 11 / 2025

Nama Penguji (.....) Galonella

Gambar L7.4 (Lanjutan)

FORMULIR USER ACCEPTANCE TESTING (UAT)

Aplikasi : Dashboard Klasifikasi Tweet Gojek & Grab
 Nama Penguji : Darren Ferdian Tanggal Pengujian : 08 / Nov / 2025
 Pekerjaan : Admin HR

Petunjuk Pengujian:

1. Jalankan aplikasi dashboard sesuai instruksi.
2. Lakukan setiap skenario uji dalam tabel, bandingkan hasil aktual dengan hasil yang diharapkan.
3. Berikan Penilaian (✓) pada salah satu kolom: SB (Sangat Baik), B (Baik), C (Cukup), K (Kurang), atau SK (Sangat Kurang).
4. Wajib isi kolom Catatan/Komentar jika penilaian C, K, atau SK, atau jika ada bug dan saran.
5. Berikan rekomendasi keseluruhan di bagian akhir formulir.
6. Tanda tangani formulir setelah selesai.

No.	Halaman	Skenario Uji	Hasil yang Diharapkan	Penilaian					Catatan/ Komentar
				SB	B	C	K	SK	
1	Umum / Sidebar	Memuat Aplikasi & Navigasi Awal	Halaman 'Prediction' terbuka, sidebar tampil benar.	✓					aman
2	Umum / Sidebar	Navigasi antar menu	Pindah halaman antar menu (Prediction, Dataset, Dashboard, About) berhasil.	✓					aman
3	Sidebar	Unggah File Valid (sudah ber-label)	Pesan sukses muncul, data tampil di Dataset & Dashboard. (Alur pintas)	✓					aman
4	Sidebar	Unggah File Tidak Valid (Tipe .txt)	File ditolak / muncul error tipe file.	✓					aman
5	Sidebar	Cek Status Model (File .pkl ada)	Tampil status "Model Siap."	✓					aman
6	Prediction	Lihat Halaman Awal	Tampil panduan (expander), prediksi tunggal, dan prediksi batch.	✓					aman
7	Prediction	Prediksi Tunggal Valid	Hasil prediksi (Topic & Intention) dan probabilitas muncul.	✓					aman
8	Prediction	Prediksi Tunggal Kosong	Muncul pesan peringatan "Harap masukkan teks..."	✓					aman
9	Prediction	Prediksi Batch Invalid (Tanpa full_text)	Muncul pesan error "Kolom full_text tidak ditemukan".	✓					aman
10	Prediction	Prediksi Batch Valid & Unduh	Hasil prediksi batch (tabel, ringkasan) tampil & file CSV terunduh.	✓					aman
11	Dataset	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓					aman
12	Dataset	Akses halaman (Setelah unggah file)	Tampil pesan sukses, filter, statistik, dan tabel data.	✓					aman

Gambar L7. 5 Hasil User Acceptance Testing 5

13	Dataset	Filter Data (Merek, Topic, Intention)	Tabel & statistik ter-update sesuai filter.	✓						Aman
14	Dataset	Toggle "Tampilkan Semua"	Tabel menampilkan semua baris (saat aktif) / 20 baris (saat non-aktif).	✓						Aman
15	Dashboard	Akses halaman (Tanpa unggah file)	Tampil pesan info (arahan untuk unggah / ke menu "Prediction").	✓						Aman
16	Dashboard	Akses halaman (Setelah unggah file)	Tampil filter Merek, Dimensi, dan semua grafik (Bar, Pie, WC).	✓						Aman
17	Dashboard	Filter Merek & Dimensi	Visualisasi (Bar, Pie, WC) ter-update sesuai filter.	✓						Aman
18	About	Navigasi Tab	Halaman "About" tampil dengan 3 tab (Informasi, Evaluasi, Manual).	✓						Aman
19	About	(Tab Evaluasi) Filter Skenario	Hasil (Akurasi, Report, CM) ter-update sesuai skenario yang dipilih.	✓						Aman
20	About	(Tab Evaluasi) Download Report	File CSV Classification Report terunduh.	✓						Aman
21	About	(Tab Buku Manual) Download PDF	File PDF buku manual terunduh.	✓						Aman

Penjelasan Kolom Penilaian:

- **SB (Sangat Baik):** Fitur berfungsi sempurna, mudah digunakan, tampilan sangat baik.
- **B (Baik):** Fitur berfungsi sesuai harapan, mudah digunakan, ada saran perbaikan tampilan minor.
- **C (Cukup):** Fitur berfungsi, namun ada kesulitan penggunaan atau hasil/tampilan kurang optimal. Perlu perbaikan.
- **K (Kurang):** Fitur sulit digunakan, hasil tidak sesuai, atau berfungsi sebagian. Perlu perbaikan signifikan.
- **SK (Sangat Kurang):** Fitur gagal total, menghasilkan *error* fatal atau tidak berfungsi sama sekali.

Penilaian Keseluruhan:

(Berikan komentar umum mengenai kemudahan penggunaan, tampilan visual, dan fungsionalitas secara keseluruhan)

semua aman, aplikasi berjalan dengan baik

Rekomendasi: (Pilih salah satu)

- ☒ Aplikasi disetujui tanpa perubahan.
- ☐ Aplikasi disetujui dengan catatan perbaikan minor (lihat kolom Catatan/Komentar).
- ☐ Aplikasi perlu perbaikan signifikan sebelum disetujui (lihat kolom Catatan/Komentar).
- ☐ Aplikasi ditolak.

Tanda Tangan:

Tanggal: 08 / Nov / 2025

Parren

Nama Penguji (Parren Ferdian)

Gambar L7.5 (Lanjutan)

LAMPIRAN VIII
PROFIL VALIDATOR

Lekrey Jerel Jacob Laipiopa

Jakarta, 11740 | Lekrey.laipiopa29@gmail.com | +6282112747472 | [Linkedin](#)



SUMMARY

I'm a 7th-semester Informatics Engineering student at Tarumanagara University, currently interning as an AI Developer. I have a solid background in Data Analysis, Machine Learning, and Deep Learning, with hands-on experience in LLMs and RAG techniques. I am detail-oriented, proficient in Python and SQL, and passionate about developing innovative AI solutions. Eager to build a career in data and AI, I continually seek opportunities to enhance my skills and contribute to impactful projects

Personal Projects :

BCA Tiktok Comment Sentiment Analysis and Complaint Categorization (scraped 4500+ comments)

- Indonesian Stock Analysis and Forecast with LSTM (Long Short Term Memory) (842 Stocks)
- ETL (Extract , Transform , Load) Project : Web Scraping of Tokopedia Stores (scraping every product for competitor analysis)
- News Retrieval Augmented Generation

Certification & Training : [Huawei Certified Artificial Intelligence \(HCI-AI V3.0\)\(2023\)](#) , [Data Science Datacamp \(2023\)](#) , [Associate Data Scientist \(2023\)](#) , [Data Analysis Datacamp \(2022\)](#) , [Visualisasi Data Decoding Indonesia \(2022\)](#) , [Python Data Associate certificate \(2025\)](#)

Languages : Fluent in Bahasa , Intermediate in English

EXPERIENCE

PT Primeskills Edukasi Indonesia

AI Developer intern

December 2024 – Present

- Executed 5 AI projects, including the development of a virtual assistant leveraging OpenAI and Gemini to enhance user interaction.
- Redesigned and benchmarked new models by conducting comparative analyses on TTS and image generation models to optimize performance.
- Developed a comprehensive feedback feature to continuously improve model performance and elevate user experience.

EDUCATION

Universitas Tarumanagara

Teknik Informatika

June 2022 – Present

- **IPK :** 3.59 / 4.00
- **Mata Kuliah Relevan :** Big Data , Data Mining , Kalkulus , Aljabar Linear , Statistik , database , Algoritma Programming
- **Project :** Churn classification , Food Price Analysis In Malang

SMAN 94 Jakarta

Program Ilmu Pengetahuan Sosial

April 2019 – June 2022

SKILLS

- | | | |
|--------------------|-----------------|-------------------------------|
| • Python | • LLM | • Natural Language Processing |
| • SQL | • Data Analysis | • ETL |
| • Machine Learning | • Deep Learning | • Web Scraping |
| • Model Deployment | • RAG | • Public Speaking |
| • Forecasting | • Fullstack | |

Gambar L8. 1 Profil Validator 1



GABRIELLA ANGELENE

Psychologist

ABOUT ME

Psychology graduate passionate about guiding others and fostering self-awareness. Skilled in assessment, communication, and problem-solving. Currently pursuing a Master's in Professional Psychology with a focus on child clinical psychology.

EDUCATION

2017 - 2020

TARAKANITA SENIOR HIGH SCHOOL
High School in Social Sciences Major

EDUCATION

2020 - 2024

BUNDA MULIA UNIVERSITY

Bachelor of Psychology

- Honors: GPA: 3.4/4.0

EDUCATION

2025 - 2027

TARUMANAGARA UNIVERSITY

Professional of Psychology Program

- On going

WORK EXPERIENCE

2022 - now

HRD Manager

PT. Inti Vantage Transformio

- Contributing to providing training and consulting on human behavior related to the placement organizational positions at the Inti Vantage Transformio Foundation.
- Contribute to asking about obstacles during work and living life. And ask about their hope for their future next life.
- Monitor and evaluate the result of assessment.
- analysed and made a conclusion about the result of assessment. The result that are made are related to persons personality when they are in a situation that requires that person to meet other people, then is in a stressful situation and how his real personality is when he is not under pressure and does not have to meet many people.

September - November 2023

Assistant psychologist - Jakarta

Equipment & Logistic Division

- Contributing to providing training and consulting on human behaviour related to the placement organizational positions at the Smile Consulting Indonesia.
- Carry out psychological test measurement assessments, interviews, prepare reports on psychological test results.
- Create video content on Instagram, YouTube, LinkedIn.
- Become an assessment implementation team in schools and in the office.

EXPERTISE

Public Speaking

Microsoft Office

Problem solving

Leaderships

CONTACTS

✉ gaw3012@gmail.com


☎ +62 84211424172

📍 Jakarta, Indonesia


Gambar L8. 2 Profil Validator 2

LAMPIRAN IX

TAMPILAN ANTARMUKA HALAMAN PREDICTION



Gambar L9. 1 Tampilan Awal Halaman prediksi dengan Alur



Gambar L9. 2 Tampilan Halaman Prediksi (Prediksi Tunggal)

Prediksi Batch (Unggah File)

Unggah file data mentah (.csv/.xlsx). File harus memiliki kolom bernama `full_text`.

Pilih File Data Mentah

Drag and drop file here
Limit: 200MB per file • CSV, XLSX, XLS

gojek_tweet_1.csv 0.6MB

Tinjauan Data Mentah

	conversation_id_str	created_at	favorite_count	full_text	id_str	image_url
0	1939408171837393162	Mon, Jun 30 23:57:43 +0000 2025	0	@anomali_silal (@gongkol Aku kuliah dirantau kemana? jalan kaki skem+ mana kuli	1939835773391614314	None
1	1939835773391614314	Mon, Jun 30 23:56:55 +0000 2025	0	When lu naik gojek tapi abang gojek nya lebih mungil dari lu https://t.co/m2JRGYHw	1939835773391614314	https://pbs.twimg.com/media/G
2	1939835773391614314	Mon, Jun 30 23:55:49 +0000 2025	0	chat should i apply to grab/gojek buat mulangin yutnya yangsi tribute sparkie https:	1939835773391614314	https://pbs.twimg.com/media/G
3	193944052470391061	Mon, Jun 30 23:54:58 +0000 2025	0	@gojekindonesia OTW pake GoCar masukin kode promo [A : GOCARAJA] Ayo Ruten	1939835773391614314	None
4	193944052470391061	Mon, Jun 30 23:54:33 +0000 2025	0	@gojekindonesia OTW Pake GoCar masukin kode promo A. GOCARAJA #PakeGojekP	1939835773391614314	None

Informasi: Kolom `full_text` terdeteksi. (2,051 baris siap diproses)

Mulai Prediksi Batch

Tinjauan Hasil Prediksi Batch

	conversation_id_str	created_at	favorite_count	full_text	id_str	image_url
0	1939408171837393162	Mon, Jun 30 23:57:43 +0000 2025	0	@anomali_silal (@gongkol Aku kuliah dirantau kemana? jalan kaki skem+ mana kuli	1939835773391614314	None

© 2025 - Prototype Dashboard Analisis Ulasan

Gambar L9. 3 Tampilan Halaman Prediksi (Prediksi Batch)

Ringkasan Hasil Prediksi

Distribusi Topic yang Diprediksi

Proporsi Prediksi Topic

Proporsi Prediksi Intention

Unduh Hasil Prediksi Lengkap (csv)

Prediksi Selesai File Anda siap diunduh.


Langkah Selanjutnya: Unggah file yang baru saja Anda unduh pada sidebar (di menu 'Dataset' atau 'Dashboard') untuk divisualisasikan.

© 2025 - Prototype Dashboard Analisis Ulasan


Gambar L9. 4 Tampilan Halaman Prediksi (Ringkasan Hasil Prediksi)

LAMPIRAN X


TAMPILAN ANTARMUKA HALAMAN *DATASET*



Gambar L10. 1 Tampilan Halaman *Dataset* (Tanpa *Dataset*)




Gambar L10. 2 Tampilan Halaman *Dataset* (Dengan *Dataset*)




Gambar L10. 3 Tampilan Halaman *Dataset* (Data dan Informasi Kolom)

LAMPIRAN XI

TAMPILAN ANTARMUKA HALAMAN DASHBOARD



Gambar L11. 1 Tampilan Halaman Dashboard (Tanpa Data)




Gambar L11. 2 Tampilan Halaman Dashboard (Dengan Data)


Gambar L11. 3 Tampilan Halaman *Dataset* (WordCloud)

LAMPIRAN XII


TAMPILAN ANTARMUKA HALAMAN ABOUT




Gambar L12. 1 Tampilan Antarmuka Halaman About (Informasi Pengerjaan)




Gambar L12. 2 Tampilan Halaman About (Evaluasi)



Gambar L12. 3 Tampilan Halaman About (Confusion Matrix)




Gambar L12. 4 Tampilan Halaman Evaluation (Analisis Kesalahan Terbesar)




Gambar L12. 5 Tampilan Halaman About (Buku Manual)

LAMPIRAN XIII HASIL TURNITIN



Gambar L13. 1 Hasil Turnitin Skripsi 1



Gambar L13. 2 Hasil Turnitin Skripsi 2



Digital Receipt

This receipt confirms that Turnitin has received your submission. See details about your file below.

Submission author

535220129 hans

Assignment title

Laporan Akhir Skripsi

Submission title

BUKU SKRIPSI_535220129

File name

BUKU SKRIPSI_535220129.pdf

File size

8425158

Page count

201

Word count

25569

Character count

151809

Submission date

Dec 13, 2025, 5:22:48 AM UTC

Submission ID

trn:oid:::3618:124377981

Copyright 2025 Turnitin. All rights reserved.

Gambar L13. 3 Digital Receipt Turnitin

LAMPIRAN XIV

LINK GITHUB

Untuk melihat kode sumber dan dokumentasi lengkap terkait pembangunan Dashboard Analisis dan Klasifikasi Ulasan Konsumen Gojek dan Grab pada Twitter menggunakan metode Stacking Ensemble, kunjungi repositori GitHub berikut: <https://github.com/kuuntakiintee/Dashboard-Klasifikasi-Tweet-Gojek-Grab>

DAFTAR RIWAYAT HIDUP

Nama : Hans Santoso

NPM : 535220129

Tempat/tanggal lahir : Jakarta, 09 Oktober 2004

Alamat : Citra 3 EXT Blok B 14/16, Pegadungan, Kalideres,
Jakarta Barat, 11830

No. Telepon/HP : 08176580377

Alamat email : hanssantoso4@gmail.com

Riwayat Pendidikan :

- SD Pelita Kasih, Jl. Taman Palem Lestari No.1 Blok E9, RT.9/RW.6, Cengkareng Bar., Kecamatan Cengkareng, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11730, 2010 – 2016
- SMP Pelita Kasih, Jl. Taman Palem Lestari No.1 Blok E9, RT.9/RW.6, Cengkareng Bar., Kecamatan Cengkareng, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11730, 2016 – 2019
- SMA Pelita Kasih, Jl. Taman Palem Lestari No.1 Blok E9, RT.9/RW.6, Cengkareng Bar., Kecamatan Cengkareng, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11730, 2019 – 2022
- Program Studi Teknik Informatika Fakultas Teknologi Informasi Universitas Tarumanagara, Letjen S. Parman St No.1, RT.6/RW.16, Tomang, Grogol petamburan, Jakarta Barat, Jakarta 11440, 2022 – Sekarang

Riwayat Pekerjaan:

- IT Tech/ Full Stack Developer Intern: QBIT (PT Vanz Inovatif Teknologi), Desember – Juli 2025